Análisis exploratorio de datos (EDA)

Juan Miguel Velandia García

Oscar Mauricio Parra Folleco

Maestría en Inteligencia Artificial, Universidad Espíritu Santo.

Proyecto Integrador en Inteligencia Artificial.

Dra. Alexandra Jacqueline Arciniegas Coral

04 de abril de 2026

Resumen

El presente documento detalla el Análisis Exploratorio de Datos (EDA, por sus siglas en inglés: Exploratory Data Analysis) realizado sobre el dataset "Dataset Dog and DogDef Balanced 03abril2026", destinado al entrenamiento de un modelo de visión artificial basado en la arquitectura YOLOv8 (You Only Look Once). El objetivo principal es evaluar la calidad, distribución y relaciones intrínsecas de las anotaciones de las cajas delimitadoras (bounding boxes). A través del análisis de 1,366 anotaciones, se constató un balance adecuado entre las clases dog y defecating-dog (proporción 1.18:1), una alta integridad de los datos sin valores nulos ni duplicados, y la presencia de 27 valores atípicos específicos en la relación de aspecto para la clase dog. Estos hallazgos permiten establecer una línea base robusta para la posterior configuración de los anchors y el modelado predictivo.

Introducción

En los flujos de trabajo modernos de Machine Learning, especialmente en tareas de visión artificial como la detección de objetos, la calidad de los datos de entrenamiento determina fundamentalmente el rendimiento de los algoritmos. El Análisis Exploratorio de Datos (EDA) permite descubrir patrones subyacentes, detectar anomalías y probar supuestos iniciales antes de la fase de modelado. Este proyecto aborda el análisis del dataset "Smartpet", compuesto por imágenes etiquetadas para identificar perros y su comportamiento específico (defecando). Mediante un análisis univariado y bivariado de las dimensiones geométricas de las bounding boxes, se busca diagnosticar el estado del conjunto de datos e identificar posibles desafíos que el modelo YOLOv8 deberá afrontar durante su entrenamiento.

Marco Teórico

La detección de objetos en imágenes ha evolucionado significativamente con la introducción de Redes Neuronales Convolucionales (CNN) de una sola etapa. La arquitectura YOLO (You Only Look Once), en su versión v8, reformula el problema de detección como un problema de regresión sobre tensores divididos espacialmente (Redmon et al., 2016). Para que estos modelos converjan correctamente, requieren que las anotaciones geométricas (bounding boxes) estén normalizadas entre 0 y 1, representando coordenadas relativas al centro del objeto, su ancho y alto.

El Análisis Exploratorio de Datos (EDA), formalizado por John Tukey (1977), es una filosofía que promueve la investigación de los datos antes de aplicar inferencias estadísticas o modelos complejos. En el contexto de visión por computadora, el EDA sobre anotaciones se centra en la distribución de clases, la escala espacial de los objetos (área) y las proporciones morfológicas (relación de aspecto) (Zheng et al., 2021).

Metodología

Descripción del Dataset

El conjunto de datos, denominado "DOG.v3i.yolov8", está almacenado en Google Drive y estructurado en subdirectorios de imágenes y etiquetas de texto plano, cumpliendo con el estándar de anotación de YOLO. La conformación del dataset fue realizada con la ayuda de la herramienta Roboflow Universe, eligiendo un dataset público de posturas de perros al momento de excretar (clase dog-defecation) y otro dataset público para detección de perros (clase dog), los cuales fueron fusionados posterior a la limpieza y la generación de imágenes adicionales mediante la técnica de data augmentation sobre la clase dog-defecation para asegurar un mejor balance en el dataset definitivo con un número final de imagenes de 1216 (Train: 865 imágenes, Valid: 236 imágenes, Test: 115 imágenes), donde 740 instancias corresponden a la clase 1 denominada dog y 626 a la clase 0 denominada defecating-dog, con un total de 1366 anotaciones tipo bounding boxes compatibles con YOLO.

Figura 1

Vista general del dataset DOG.v3i.yolov8 y distribución de particiones

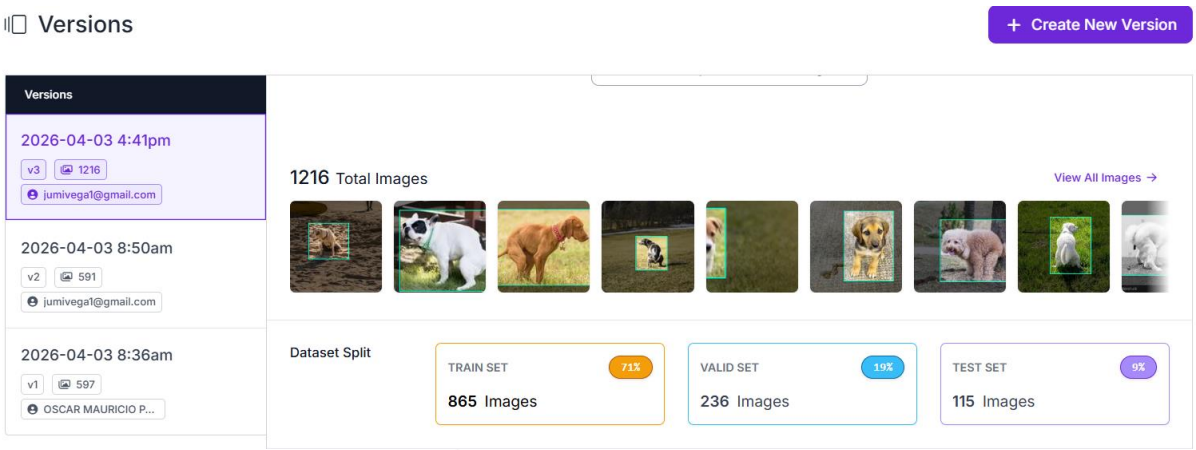

Nota. La figura presenta la interfaz de Roboflow correspondiente a la versión consolidada del dataset *DOG.v3i.yolov8*, mostrando un total de 1,216 imágenes distribuidas en los subconjuntos de entrenamiento (865 imágenes, 71%), validación (236 imágenes, 19%) y prueba (115 imágenes, 9%)

Procesamiento de Datos

Se extrajeron las coordenadas (x_center, y_center, width, height) de los archivos .txt y se transformaron en un DataFrame de Pandas. Se generaron características derivadas como el área (producto de ancho por alto) y el aspect_ratio (ancho sobre alto).

Modelos Utilizados

Aunque esta fase es puramente exploratoria, la estructura de datos está optimizada para la implementación de un modelo YOLOv8.

Configuración Experimental

El análisis se ejecutó en el entorno de Google Colab utilizando librerías como Pandas para estructuración, y Seaborn/Matplotlib para la visualización estadística de distribuciones y correlaciones.

Implementación Completa EDA

Comprensión del Dataset

El dataset utilizado contiene anotaciones provenientes de la ruta /content/drive/MyDrive/Proyecto Integrador MIA/DataSet/Dataset Dog and DogDef Balanced 03abril2026/DOG.v3i.yolov8. Contiene imágenes de perros y perros en defecación.

Tabla 1

Descripción General del Dataset Analizado

Aspecto	Descripción
Formato del dataset	YOLOv8 con etiquetas en archivos .txt y archivo data.yaml
Particiones detectadas	train, valid y test
Número de clases	2
Clases identificadas	defecating-dog; dog
Unidad de análisis del EDA	Anotación individual (bounding box)
Cantidad de imagenes	1216 imagenes
Registros válidos	Se procesaron un total de 1,366 anotaciones geométricas (bounding boxes).
Propósito analítico	Caracterizar la calidad, distribución y relaciones geométricas de las anotaciones antes del modelado

Nota. La tabla resume las características estructurales del dataset utilizado en el análisis exploratorio, incluyendo su formato, particiones, número de clases y unidad de análisis. Se evidencia que el conjunto de datos cumple con el estándar YOLOv8 y contiene un total de 1,366 anotaciones válidas, lo que permite realizar un análisis estadístico representativo previo al modelado

Número de Variables

El conjunto consolidado cuenta con 9 variables.

Tabla 2

Variables analizadas y tipología

Variable	Tipo	Descripción
image_filename	Texto	Nombre del archivo de imagen asociado a la anotación
class_id	Categórica discreta	Identificador numérico de la clase
has_annotations	Booleana	Indicador de presencia de anotación
x_center	Numérica continua	Coordenada x normalizada del centro de la caja
y_center	Numérica continua	Coordenada y normalizada del centro de la caja
width	Numérica continua	Anchura relativa de la bounding box
height	Numérica continua	Altura relativa de la bounding box
area	Numérica continua derivada	Área relativa de la caja (width × height)
aspect_ratio	Numérica continua derivada	Relación ancho/alto de la caja

Nota. La tabla presenta las variables utilizadas en el análisis exploratorio, clasificadas según su tipo y descripción funcional. Se incluyen tanto variables originales del dataset como variables derivadas (área y relación de aspecto), fundamentales para el análisis geométrico de las bounding boxes en tareas de detección de objetos.

Este dataset se utilizará para alimentar un algoritmo de detección de objetos, por lo que la integridad de estas coordenadas espaciales es vital.

Revisión de la Calidad de los Datos

Se realizó una inspección exhaustiva de la integridad referencial y de valores de las coordenadas:

- Valores faltantes: 0 registros nulos detectados en las columnas.

- Valores duplicados: 0 filas duplicadas completas.
- Formatos incorrectos / Valores Inconsistentes: 0 coordenadas fuera del rango normalizado esperado [0, 1].
- No hay imágenes vacías ni archivos de etiquetas sin correspondencia.

Interpretación: La calidad del dataset en su ingesta es óptima. Los procesos de etiquetado y exportación conservaron la fidelidad de las estructuras esperadas por la arquitectura YOLO, mitigando el impacto de error en tiempo de modelado.

Estadísticas Descriptivas

Se consolidaron las medidas de tendencia central y dispersión para las variables numéricas clave de las cajas delimitadoras.

Tabla 3

Estadísticas descriptivas de las variables geométricas

Métrica	Width	Height	Area	Aspect Ratio
Conteo	1366	1366	1366	1366
Media	0.5479	0.5986	0.3514	0.9883
Desv. Estándar	0.2157	0.2139	0.2121	0.4487
Mínimo	0.0571	0.0745	0.0058	0.1869
Percentil 25%	0.3870	0.4401	0.1811	0.6921
Mediana (50%)	0.5517	0.6111	0.3172	0.9261
Percentil 75%	0.7100	0.7690	0.4948	1.1532
Máximo	1.0000	1.0000	0.9725	3.2380

Nota. La tabla muestra las medidas de tendencia central y dispersión de las variables geométricas de las bounding boxes. La cercanía entre medias y medianas en width y height sugiere distribuciones relativamente simétricas, mientras que el área presenta valores mínimos bajos que evidencian la presencia de objetos pequeños. La relación de aspecto indica predominancia de formas cercanas a lo cuadrado, con algunos valores extremos que reflejan variabilidad morfológica

Análisis de Distribuciones

Según las métricas evidenciadas en las gráficas KDE del notebook, el comportamiento es el siguiente:

- Ancho Relativo (width): La distribución es bimodal, presentando picos de densidad entre 0.3-0.4 y 0.7-0.8. Existen dos agrupaciones predominantes que sugieren la captura de perros en diferentes escalas de profundidad.
- Alto Relativo (height): Comportamiento bimodal similar al ancho. Los picos en 0.4-0.5 y 0.7-0.8 denotan variaciones de postura.
- Área (area): Muestra asimetría positiva (sesgada a la derecha). La mayor concentración de datos se ubica por debajo de 0.5.
- Relación de Aspecto (aspect_ratio): Exhibe un pico prominente cercano a 1 (objetos cuadrados) con una cola que se prolonga fuertemente hacia la derecha.

Figura 2

Distribución de width, height, area y aspect_ratio mediante histogramas y curvas KDE

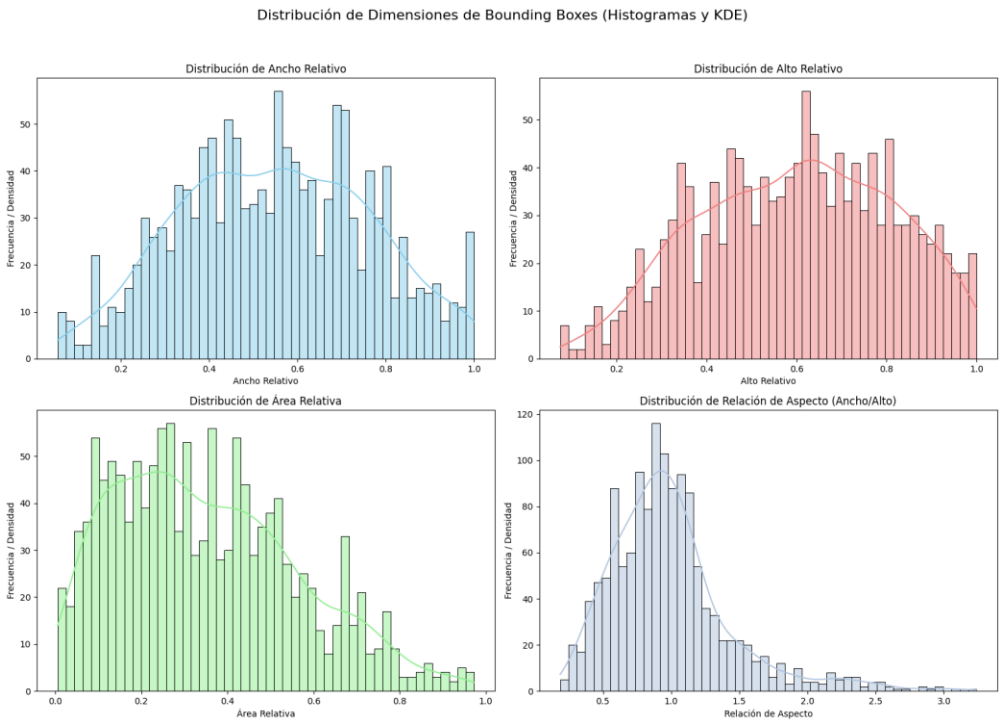

Nota. La figura muestra la distribución de las variables geométricas mediante histogramas y curvas de densidad (KDE), utilizando las librerías Seaborn y Matplotlib. Se identifican patrones bimodales en width y height, así como una distribución asimétrica en el área y una concentración de valores cercanos a 1 en la relación de aspecto, lo que refleja la diversidad de escalas y formas presentes en el dataset

Identificación de Valores Atípicos (Outliers)

Utilizando el criterio del Rango Intercuartílico (IQR 1.5x) de forma general en las coordenadas crudas, no se reportaron valores anómalos. No obstante, al realizar el filtrado cruzado por clases morfológicas, la variable aspect_ratio (Relación de aspecto) registró 27 outliers en la clase dog.

Tabla 4

Outliers cuantificados por clase según el método IQR (1.5x)

Variable	Dog	Defecating-dog
area	0	0
aspect_ratio	27	9

Nota. La tabla presenta la cantidad de valores atípicos identificados por clase utilizando el método del rango intercuartílico (IQR). Se observa que la variable aspect_ratio concentra la mayor cantidad de outliers, especialmente en la clase dog, lo que sugiere la existencia de variaciones morfológicas relevantes que podrían llegar a impactar el entrenamiento del modelo.

Impacto en el modelo: Estos valores extremos (tales como relaciones de 3.2) representan objetos inusualmente anchos u horizontalmente alargados. Esto podría representar una distorsión visual o perros acostados muy perfilados. Se decide mantenerlos en primera instancia, ya que, si son genuinos, su eliminación podría perjudicar la capacidad del modelo para generalizar estas posturas, pero requerirán el diseño de cajas de anclaje (anchors) especializados.

Figura 3

Boxplots de las dimensiones de bounding boxes para la identificación visual de outliers

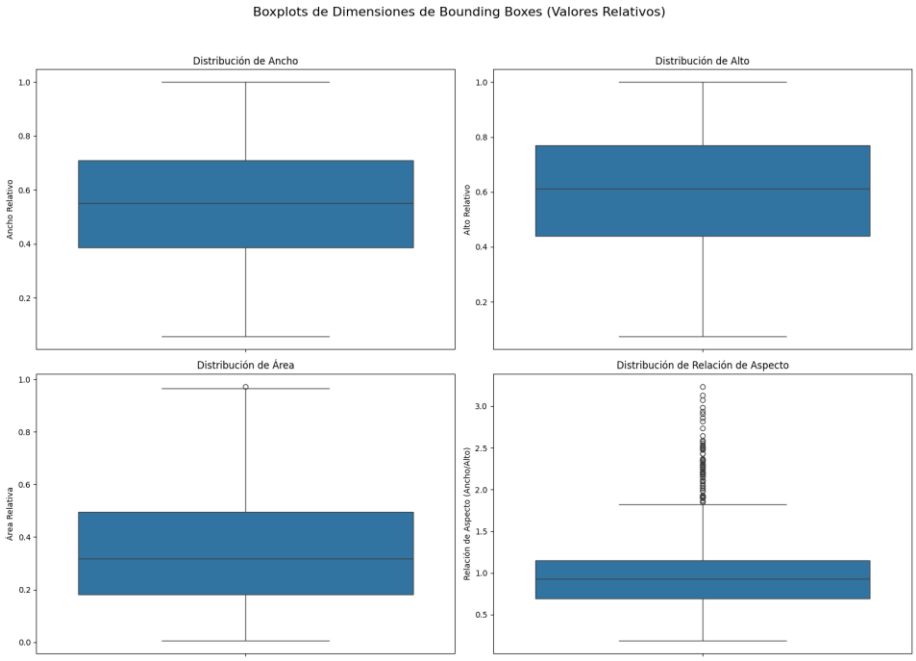

Nota. La figura presenta diagramas de caja para las variables geométricas, permitiendo identificar la presencia de valores atípicos y la dispersión de los datos. Se observa una mayor variabilidad en la relación de aspecto, lo que confirma la existencia de outliers previamente identificados mediante el método IQR.

Figura 4

Scatterplots usados para examinar combinaciones inusuales entre dimensiones geométricas

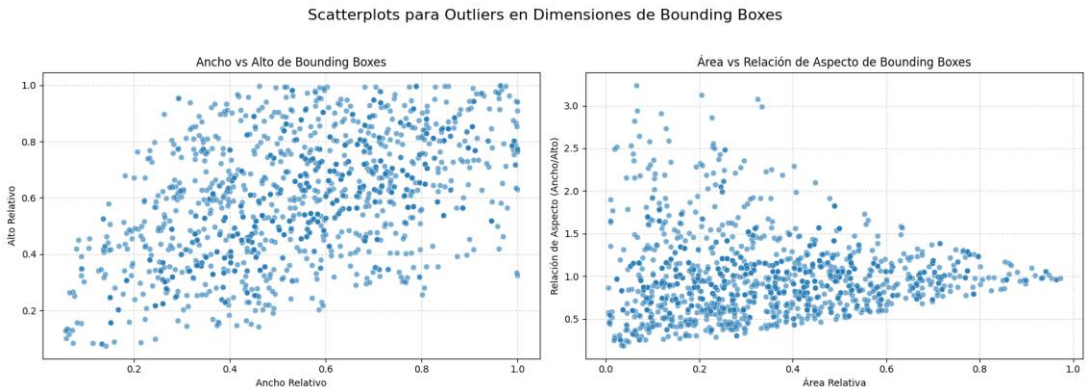

Nota. La figura ilustra la relación entre pares de variables geométricas mediante diagramas de dispersión. Se evidencian patrones de agrupamiento y posibles combinaciones inusuales entre dimensiones, útiles para identificar comportamientos atípicos en las bounding boxes.

Diseñamos e incluimos en el notebook de Google Colab anexo y base para el presente informe, una celda a partir de la cual visualizamos y listamos los outliers detectados, siendo inicialmente 35 para la clase dog. A partir de esta referencia analizamos uno a uno los outliers y decidimos retirar 6 imágenes con sus anotaciones, dado que en efecto no se corresponden al mismo conjunto de imágenes de la clase en cuestión y podrían complejizar la fase de modelado.

Figura 5

Uno de los seis outliers retirados del dataset

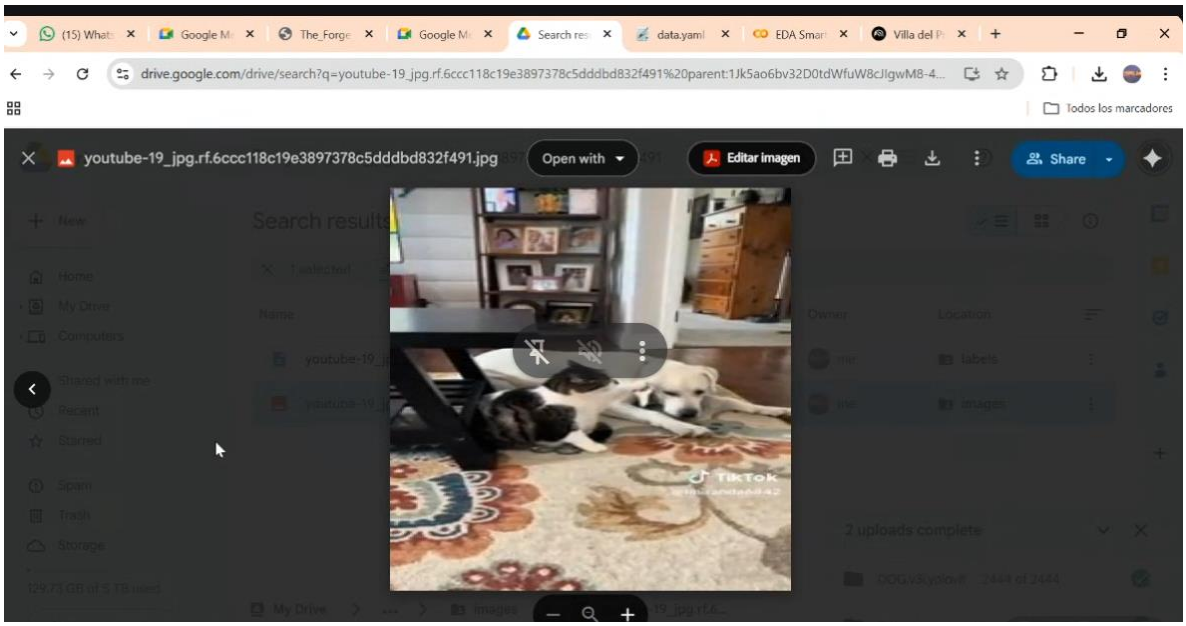

Nota. El gato en primer plano, incluso después del perro, este último siendo el objetivo, puede complejizar las fases de modelado y fue retirado del dataset.

Por otra parte decidimos mantener las restantes 27 imágenes catalogadas como outliers dado que al analizarlas se corresponden con el conjunto correcto de imágenes pero sus bounding boxes eran atípicos o se alejaban de las métricas promedio de los demás.

Figura 6

Uno de los 27 outliers mantenido en el dataset

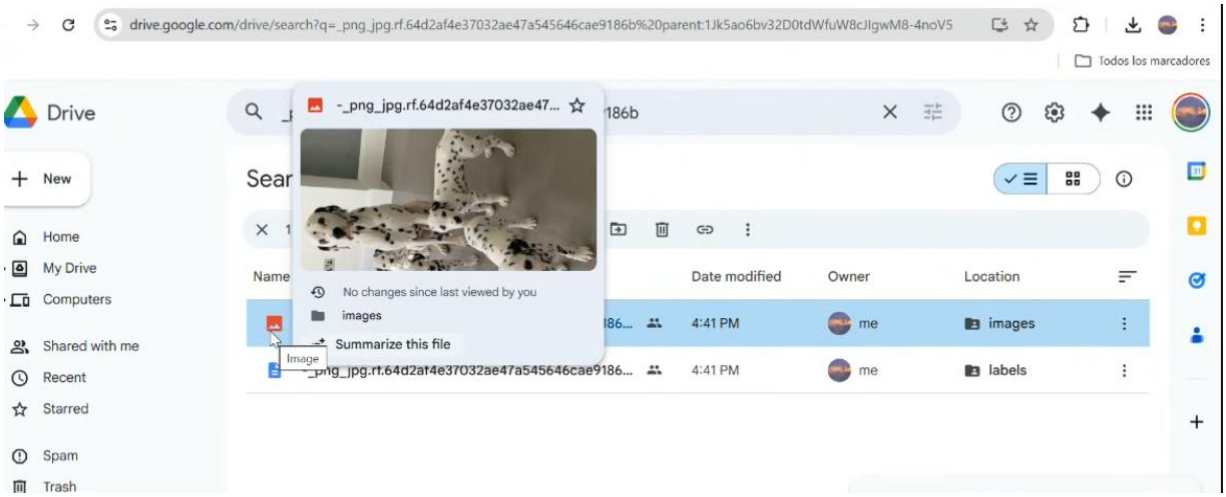

Nota. La imagen identificada como outlier se corresponde de manera legítima con la clase dog sin embargo al trazar los bounding boxes y anotaciones su relación de aspecto se aleja del promedio de los demás, sin embargo decidimos mantenerla como un elemento importante para enseñarle al modelo a generalizar en la fase de entrenamiento.

Análisis de Correlaciones

La matriz de correlación expuso las siguientes relaciones lineales significativas:

- Width vs height: Correlación positiva moderada-alta (0.507). A medida que el perro es más ancho, tiende a ser más alto, mostrando escalabilidad uniforme.
- Width vs área: Correlación positiva muy alta (0.866).
- Height vs área: Correlación positiva muy alta (0.825).
- Height vs aspect_ratio: Correlación negativa (-0.456). Es biológicamente coherente; a mayor altura relativa, la relación (ancho/alto) disminuye, haciendo que el bounding box se alargue verticalmente.
- Área vs aspect_ratio: Prácticamente nula (-0.006), lo que indica independencia ortogonal.

Figura 7

Mapa de calor de correlaciones entre las dimensiones de las bounding boxes

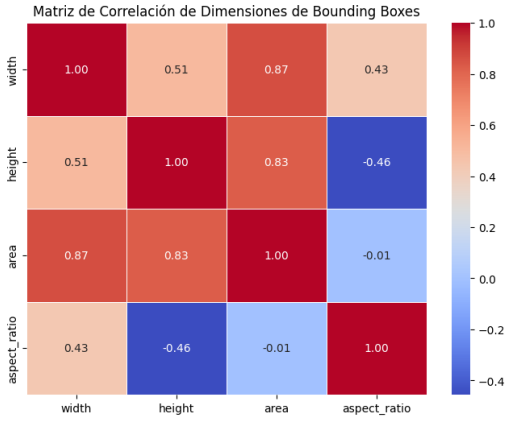

Nota. La figura muestra la matriz de correlación entre las variables geométricas. Se identifican correlaciones positivas fuertes entre width, height y area, así como una relación negativa moderada entre height y aspect_ratio, lo que confirma coherencia estructural en las anotaciones del dataset.

Análisis de Variables Categóricas

El conteo de frecuencias arrojó:

- Clase 0 (defecating-dog): 626 instancias (45.83% del total).
- Clase 1 (dog): 740 instancias (54.17% del total).

Figura 8

Distribución de clases en el dataset

Nota. La figura presenta la distribución de frecuencias de las clases del dataset. Se observa un balance adecuado entre las categorías dog y defecating-dog, con una proporción cercana a 1:1, lo que favorece el entrenamiento del modelo al haber aplicado técnicas de balanceo.

Interpretación del Balance: La proporción entre la clase mayoritaria y la minoritaria es de 1.18:1. Las clases están intrínsecamente balanceadas, lo que es el escenario ideal y erradica la necesidad actual de metodologías de corrección severas como Oversampling o Weighted Loss Functions.

Relaciones Entre Variables

La relación directa entre variables categóricas e independientes, visualizada a través de las gráficas bi-variadas (Pairplots), denota superposiciones en los espacios bidimensionales de width y height entre ambas clases. Esto sugiere que el tamaño por sí solo no discriminará el comportamiento (defecando vs. no defecando); el modelo dependerá de la extracción profunda de texturas espaciales y rasgos posturales proporcionados por el mapa de características de la red CNN.

Figura 9

Pairplot de Variables geométricas discriminado por clase

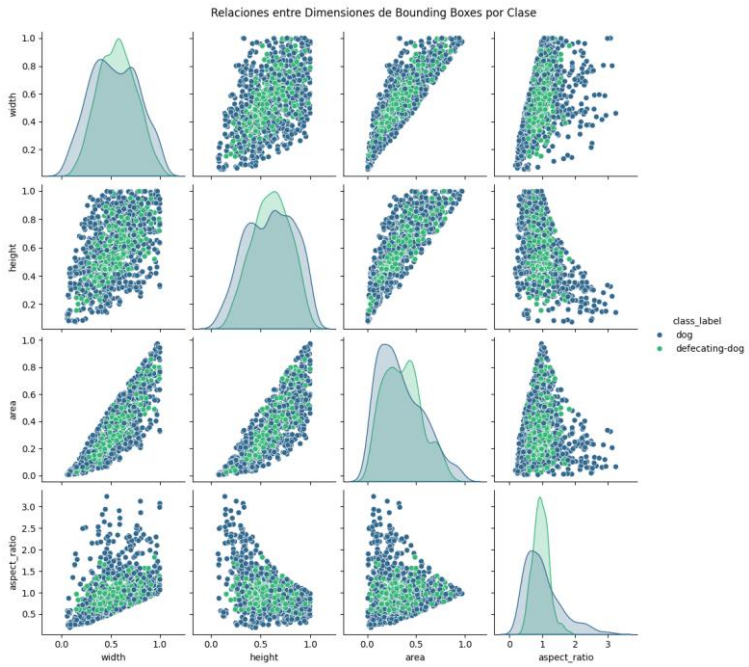

Nota. La figura muestra las relaciones bivariadas entre variables geométricas diferenciadas por clase. Se observa superposición entre ambas categorías en los espacios de width y height, lo que indica que la discriminación del comportamiento dependerá de características más complejas que el tamaño, como patrones espaciales y posturales

Identificación de Problemas para el Modelado

- Valores Faltantes / Ruido: Desafío mitigado. La limpieza estructural fue completa.
- Desbalance de Clases: No representa un problema, la tasa 1.18:1 es óptima.
- Morfologías Extremas: La existencia de 27 outliers morfológicos en la relación de aspecto de la clase dog obliga a que los hiperparámetros de anchor boxes de YOLOv8 deban recalcularse o ajustarse automáticamente (AutoAnchor) para evitar falsos negativos en proporciones inusuales.

Resultados

Se concluyó con éxito un DataFrame validado de 1,366 registros que ha superado pruebas de integridad estructural de datos. La visualización extrajo métricas consistentes de dispersión sin revelar fallas de anotación sistemáticas (bounding boxes rotas o nulas). El cálculo de matrices correlacionales confirmó la proporcionalidad espacial esperada del objeto a segmentar.

Análisis y Discusión

Al interpretar conjuntamente las distribuciones bimodales de alto y ancho, el análisis sugiere fuertemente la recolección de las imágenes bajo dos distribuciones focales predominantes (planos cerrados vs planos medios/generales). Dado que la detección precisa depende de los anclajes y la invariabilidad de escala, la dispersión del área hasta mínimos de 0.0058 confirma la inclusión de casos donde el perro está a grandes distancias. Esta diversidad de escala es beneficiosa para prevenir el sobreajuste (overfitting) a un tamaño de objeto específico.

Conclusiones

La exploración estadística de las anotaciones valida la viabilidad y alta madurez del dataset "Smartpet" para la detección de objetos. La robustez en la calidad (ausencia de valores faltantes y errores de formato) acelera directamente el ciclo de experimentación. El

balance casi ecuánime entre las categorías facilita un proceso de entrenamiento en el cual la red neuronal se puede centrar completamente en diferenciar la morfología del comportamiento y no en contrarrestar sesgos numéricos.

Veintisiete de los outliers detectados en la clase dog, fueron conservados dado que corresponden a imágenes legítimas para la clase y elemento a detectar aún cuando las dimensiones de sus bounding boxes sean atípicos en relación de aspecto a la luz de las estadísticas descriptivas.

Recomendaciones

Auto-Anchoring

Se recomienda activar el recálculo automático de anchor boxes previo a compilar YOLOv8, de modo que el algoritmo capture la asimetría dictada por los 27 outliers de relaciones de aspecto extremas.

Ángulo de visión de las cámaras de los conjuntos residenciales.

El dataset constituido debe ser enriquecido con imágenes adicionales de las dos clases: dog y defecating-dog, tomadas con cámaras en ángulo de visión negativo como un número importante de CCTVs ven y capturan el mundo en los conjuntos cerrados, lo cual permitiría un mayor desempeño del modelo en las fases posteriores.

Data Augmentation

Implementar algoritmos de Mosaic o MixUp para robustecer la generalización frente a los casos con el área delimitadora más pequeña (0.0058).

Referencias

Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once: Unified, real-time object detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 779–788. https://doi.org/10.1109/CVPR.2016.91

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

Zheng, Z., Wang, P., Liu, W., Li, J., Ye, R., & Ren, D. (2020). Distance-IoU loss: Faster and better learning for bounding box regression. *Proceedings of the AAAI Conference on Artificial Intelligence*, *34*(07), 12993–13000. https://doi.org/10.1609/aaai.v34i07.6999