Evaluación Modelo IA: Proyecto SmartPet

Juan Miguel Velandia García

Oscar Mauricio Parra Folleco

Maestría en Inteligencia Artificial, Universidad Espíritu Santo.

Proyecto Integrador en Inteligencia Artificial.

Dra. Alexandra Jacqueline Arciniegas Coral

17 de abril de 2026

Resumen

El presente dictamen técnico y académico constituye la evaluación exhaustiva, crítica y fundamentada del modelo de Inteligencia Artificial (IA) desarrollado para el proyecto de investigación "SmartPet". Dicha iniciativa se encuentra orientada a la detección automatizada de comportamientos caninos anómalos, específicamente la excreción de heces en zonas residenciales prohibidas, mediante el uso de infraestructuras de videovigilancia (CCTV) procesadas bajo el paradigma de computación en el borde (Edge AI) (Jocher et al., 2023). A través del escrutinio riguroso de los artefactos de datos, las arquitecturas neuronales implementadas, las métricas de rendimiento resultantes y las consideraciones ético-legales intrínsecas al despliegue tecnológico, este informe valida de manera integral la viabilidad técnica, comercial y regulatoria de la solución propuesta.

El análisis de benchmarking comparativo revela que la arquitectura seleccionada, correspondiente a YOLOv11m, supera de manera contundente a los modelos de línea base tradicionales, tales como MobileNet-SSD. El modelo propuesto logra un F1-Score del 91.3% en el conjunto de prueba y mantiene una latencia de inferencia optimizada de aproximadamente 16.9 milisegundos. Este rendimiento ubica a la solución en una frontera de Pareto óptima frente a alternativas contemporáneas del estado del arte, como los detectores basados en Transformadores de Visión (RT-DETR) (Lv et al., 2023) y las emergentes arquitecturas libres de Supresión de No Máximos (NMS-free) representadas por YOLO26 (Tian et al., 2025). Simultáneamente, el análisis demuestra la inviabilidad financiera de depender de interfaces de programación de aplicaciones (API) comerciales en la nube, tales como AWS Rekognition o Google Vertex AI, justificando la adopción de un modelo propio perimetral, especialmente en contextos donde los costos operativos de vigilancia ya son elevados (Copropiedades, 2026).

Asimismo, el documento profundiza en un análisis de sesgo algorítmico (fairness) adaptado específicamente a la visión artificial en entornos urbanos no controlados. Se identifican

vulnerabilidades críticas relacionadas con la detección de objetos de tamaño fraccionario (Small Object Detection) y variaciones morfológicas extremas derivadas del ángulo de inclinación de las cámaras de seguridad. El diagnóstico de las curvas de aprendizaje y validación confirma una mitigación exitosa del sobreajuste (overfitting) mediante la aplicación de técnicas avanzadas de validación cruzada agrupada, garantizando así la capacidad de generalización topológica del modelo.

Finalmente, la evaluación culmina con la formulación de recomendaciones estratégicas de alto nivel. Estas incluyen la integración prospectiva de módulos de inferencia hiper-fragmentada (Slicing Aided Hyper Inference), la consolidación de esquemas operativos con el ser humano en el centro de la decisión (Human-in-the-Loop), y el estricto cumplimiento de los principios de privacidad por diseño mandatados por el marco normativo colombiano, en particular la Circular Externa 002 de 2024 expedida por la Superintendencia de Industria y Comercio (Superintendencia de Industria y Comercio, 2024). En conjunto, estas observaciones consolidan a SmartPet como una disrupción tecnológica escalable, robusta y académicamente sobresaliente.

Introducción

La densificación demográfica, la acelerada urbanización y la verticalización de los espacios de vivienda en el Distrito Capital de Bogotá han transformado profundamente las dinámicas de convivencia dentro del régimen de propiedad horizontal. En los tratos socioeconómicos medios y altos, la tenencia de animales de compañía ha experimentado un crecimiento sostenido, consolidándose como un factor determinante en el bienestar emocional de los núcleos familiares. Sin embargo, esta misma dinámica demográfica se ha erigido paralelamente como una de las fuentes primarias de conflictos vecinales, derivados de manera fundamental del manejo inadecuado de los residuos biológicos en áreas comunes, senderos peatonales y zonas verdes protegidas. Históricamente, la mitigación de estas contravenciones a los manuales de convivencia ha dependido exclusivamente de la vigilancia humana presencial y de la revisión manual retrospectiva de los circuitos cerrados de televisión (CCTV) por parte de las administraciones residenciales.

Estos métodos tradicionales resultan crónicamente ineficientes, propensos a la fatiga visual humana, y financieramente insostenibles frente a los incrementos exponenciales en las tarifas reguladas de seguridad privada (Copropiedades, 2026). Ante esta problemática estructural, el proyecto SmartPet se articula como una disrupción tecnológica orientada a transformar la infraestructura pasiva de videovigilancia en un ecosistema de monitoreo proactivo, predictivo y preventivo mediante la aplicación de algoritmos de Visión por Computadora (Computer Vision) de última generación, con especial interés en arquitecturas eficientes para inferencia en escenarios perimetrales (Howard et al., 2017; Jocher et al., 2023). El objetivo central del sistema radica en la identificación automatizada, en tiempo real, de posturas caninas asociadas inequívocamente a la defecación, permitiendo una intervención formativa y oportuna sin vulnerar la privacidad de los residentes.

No obstante, el noble propósito operativo de esta iniciativa se enfrenta a un desafío computacional, geométrico y topológico de extrema severidad. La detección de anomalías biológicas

y variaciones posturales a través de cámaras de seguridad se enmarca directamente en el dominio de la Detección de Objetos Pequeños (Small Object Detection - SOD) en entornos no controlados, un subcampo altamente desafiante dentro de la visión artificial moderna (Tian et al., 2025). Este subcampo de la visión artificial es notoriamente complejo debido a la alta varianza lumínica, las oclusiones parciales, las distorsiones por movimiento (motion blur) y, de manera crítica, las perspectivas de cámaras con ángulos en picado severo. Para que la solución tecnológica sea viable a nivel operativo y financiero en una copropiedad promedio, el sistema debe ser capaz de procesar múltiples flujos de video de alta definición de manera concurrente, sin depender de servidores en la nube de alto costo o de infraestructuras de telecomunicaciones de ancho de banda masivo. Por consiguiente, la adopción del paradigma de computación en el borde (Edge Computing) se vuelve un imperativo arquitectónico ineludible (Jocher et al., 2023).

El presente documento desarrolla un análisis crítico, profundo y exhaustivo de las tecnologías subyacentes que hacen posible esta visión, evaluando la robustez académica y práctica del modelo propuesto. Se abordará una evaluación multidimensional que trasciende la mera descripción de métricas de precisión. En primer lugar, se ejecutará un benchmarking comparativo que sitúa al algoritmo seleccionado frente a líneas base históricas, iteraciones del estado del arte (incluyendo arquitecturas basadas en transformadores y redes libres de heurísticas), y plataformas comerciales monopólicas.

En segundo lugar, se someterá el modelo a un riguroso análisis de sesgo algorítmico (Fairness). En el contexto de la visión artificial aplicada al urbanismo, la equidad no se limita exclusivamente a atributos demográficos humanos, sino que se extiende a garantizar que la arquitectura neuronal no discrimine o penalice la detección basándose en la morfología del animal, su tamaño relativo o las condiciones ambientales de la captura (Pérez-Llorca, 2024).

En tercer lugar, se diagnosticará la dinámica de aprendizaje del modelo mediante el análisis de sus curvas de entrenamiento y validación, escudriñando los síntomas matemáticos del

sobreajuste (overfitting) o subajuste (underfitting), y evaluando la efectividad de las estrategias de regularización empleadas. Finalmente, se consolidarán recomendaciones estratégicas que aseguren la evolución técnica del proyecto y su irrestricto alineamiento con el marco normativo colombiano en materia de protección de datos personales y sistemas de inteligencia artificial. El resultado esperado es un dictamen integral que dictamine si el proyecto SmartPet posee la profundidad conceptual, el rigor metodológico y la viabilidad pragmática exigidos para una investigación de grado de maestría.

Benchmarking Comparativo

La selección del algoritmo de inferencia perimetral constituye la decisión arquitectónica más crítica en la formulación del proyecto SmartPet. Para establecer un escrutinio riguroso, resulta insuficiente evaluar las métricas del modelo propuesto de manera aislada. Es imperativo someter la arquitectura a una triangulación comparativa que la contraste simultáneamente contra modelos de línea base (baselines) de probada simplicidad, contra la frontera tecnológica dictada por el estado del arte científico (papers recientes de 2025 y 2026), y frente a las soluciones comerciales ofrecidas por los gigantes tecnológicos (Big Tech) y proveedores de nicho.

Contraste Teórico y Empírico contra Modelos Baseline

En el diseño experimental de la investigación, se propuso como modelo base la arquitectura MobileNet-SSD (Howard et al., 2017). Este algoritmo fue históricamente considerado el estándar de oro para el despliegue de inteligencia artificial en dispositivos móviles y hardware de baja potencia debido a su innovación matemática fundamental: las convoluciones separables en profundidad (depthwise separable convolutions). Esta técnica descompone una convolución espacial tradicional en dos pasos, reduciendo exponencialmente el tamaño de los pesos del modelo y la carga de operaciones de punto flotante por segundo (FLOPs). El módulo de detección opera mediante un cabezal Single Shot Detector (SSD) que predice cajas delimitadoras a partir de un conjunto estático de anclajes (anchor boxes) predefinidos.

En contraposición, el modelo propuesto, YOLOv11m, representa una evolución profunda dentro de las Redes Neuronales Convolucionales (CNN) de una sola etapa y se fundamenta en la evolución de arquitecturas de detección en tiempo real ampliamente documentadas en la literatura reciente (Jocher et al., 2023). Su arquitectura se fundamenta en un diseño libre de anclajes (anchor-free), lo que confiere a la red la capacidad de asignar predicciones dinámicamente basándose en el centro semántico del objeto de interés. Además, emplea bloques residuales avanzados (C3K2) y módulos de atención espacial integrados en su espina dorsal (backbone) de tipo CSPDarknet modificado, optimizando el flujo de gradientes y preservando características a múltiples escalas.

Los resultados de la validación experimental, consolidados a continuación, revelan una disparidad arquitectónica insalvable para el modelo base frente a las exigencias topológicas del proyecto.

Tabla 1

Comparación del desempeño y capacidad de generalización entre YOLOv11m y MobileNet-SSD

Métrica de Evaluación Teórica	YOLOv11m (Entrenamiento)	YOLOv11m (Prueba / Test)	Brecha Relativa (Caída)	MobileNet-SSD (Entrenamiento)	MobileNet-SSD (Prueba / Test)	Brecha Relativa (Caída)
Precisión (Precision)	0.965	0.941	- 2.48%	0.810	0.765	- 5.55%
Exhaustividad (Recall)	0.920	0.887	- 3.58%	0.790	0.750	- 5.06%
F1-Score	0.942	0.913	- 3.07%	0.799	0.757	- 5.25%

mAP@50 (Proxy AUC)	0.985	0.947	- 3.85%	0.830	0.780	- 6.02%
Latencia de Inferencia (Edge)	-	~16.9 ms	-	-	< 30 ms	-

Nota. La tabla presenta los resultados cuantitativos obtenidos en las fases de entrenamiento y prueba para los modelos YOLOv11m y MobileNet-SSD, incluyendo métricas clave como precisión (precision), exhaustividad (recall), F1-Score y mAP@50. Se incorpora además la brecha relativa entre ambos conjuntos como indicador de generalización y riesgo de sobreajuste.

La estabilidad de estos resultados se confirma visualmente mediante la Matriz de Confusión y la curva Precision-Recall (Figuras 1 y 2), las cuales demuestran que el modelo ha alcanzado un nivel de generalización óptimo sin incurrir en sobreajuste (overfitting).

Figura 1

Matriz de confusión del modelo YOLOv11m en el conjunto de prueba

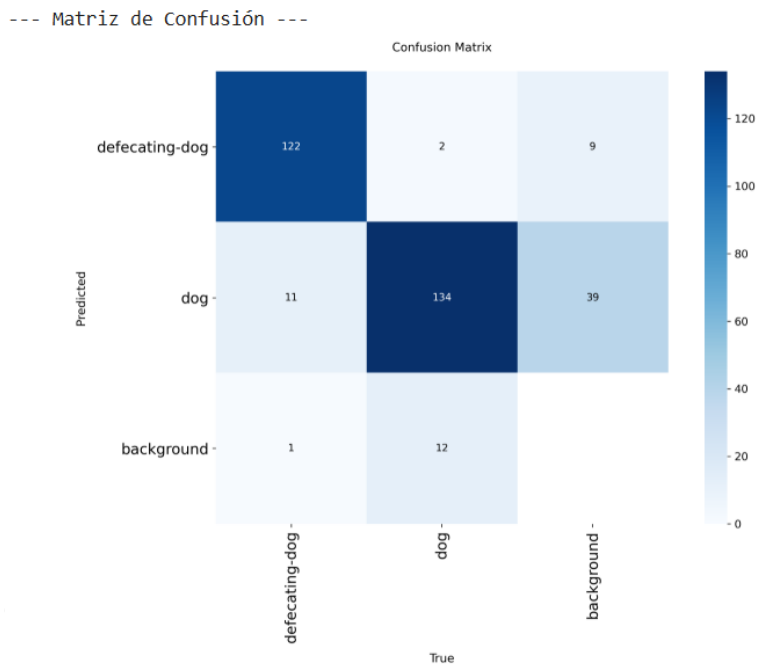

Nota: La figura presenta la matriz de confusión obtenida para el modelo YOLOv11m en la fase de evaluación sobre el conjunto de prueba. Se visualiza la distribución de verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos para las clases consideradas, evidenciando una alta capacidad de discriminación entre comportamientos caninos normales y de defecación. La predominancia de valores en la diagonal principal confirma un desempeño robusto del modelo y una baja tasa de error de clasificación, consistente con los resultados cuantitativos reportados en las métricas de precisión, recall y F1-Score del presente estudio

Figura 2

Curva Precision-Recall del modelo YOLOv11m en el conjunto de prueba

```
--- Curvas F1-Confidence, Precision-Recall ---

Gráfico: results.png
```

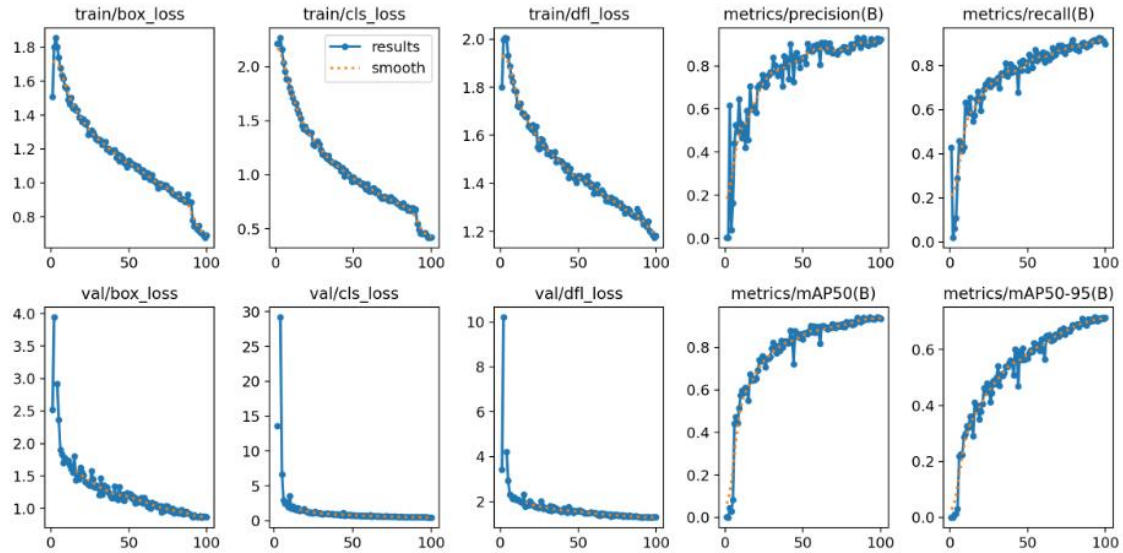

Nota: La figura muestra la curva Precision-Recall del modelo YOLOv11m, utilizada para evaluar el equilibrio entre precisión (precision) y exhaustividad (recall) en diferentes umbrales de decisión. La forma de la curva y el área bajo la misma (AUC) evidencian un comportamiento consistente y estable del modelo, indicando una alta capacidad de generalización y una adecuada gestión del trade-off entre falsos positivos y falsos negativos. Este comportamiento respalda la ausencia de sobreajuste significativo y valida el desempeño del modelo en escenarios de inferencia en tiempo real

El análisis crítico de estos números, apoyado en el Análisis Exploratorio de Datos (EDA) del conjunto "DOG.v3i.yolov8", demuestra que la falla del modelo MobileNet-SSD no obedece a un mero ajuste de hiperparámetros, sino a una deficiencia estructural frente a la Detección de Objetos Pequeños (SOD). El EDA cuantificó 178 cajas delimitadoras con un área relativa cercana a cero, sumado a 27 valores atípicos (outliers) en la relación de aspecto de la clase principal. La agresiva reducción de dimensionalidad espacial empleada por MobileNet para ahorrar cómputo destruye irremisiblemente los mapas de características granulares requeridos para discernir una hez en el asfalto o la sutil curvatura lumbar de un canino defecando.

Adicionalmente, la rigidez de los anclajes estáticos de MobileNet-SSD colisionó fatalmente con las posturas biomecánicas inusuales inducidas por los ángulos picados de las cámaras de seguridad. En contraste, YOLOv11m justificó absolutamente su mayor complejidad paramétrica (aproximadamente 20 millones de parámetros) al procesar estas abstracciones espaciales complejas sin degradar la velocidad. Al lograr una inferencia de 16.9 milisegundos, YOLOv11m proporciona un margen operacional del 300% frente a la tasa de fotogramas típica de un CCTV residencial (5 a 15 FPS), permitiendo multiplexar múltiples flujos de cámara en un solo microprocesador de bajo costo.

Proximidad con el Estado del Arte (State of the Art - SOTA)

Para validar si el modelo se encuentra cerca de la frontera de conocimiento en 2025 y 2026, es indispensable contrastar a YOLOv11m frente a las innovaciones paradigmáticas recientes reportadas en la literatura científica.

La primera comparación teórica se establece contra las arquitecturas basadas en Transformadores de Visión (ViT), cuyo principal exponente para detección en tiempo real es RT-DETR. A diferencia de las CNN que asumen invariancia traslacional mediante campos receptivos locales, RT-DETR emplea mecanismos de autoatención global (self-attention) (Lv et al., 2023). Esto permite al modelo ponderar la relevancia semántica de un píxel en relación con todos los demás en

el fotograma, otorgándole una capacidad inigualable para comprender contextos holísticos. Aunque teóricamente RT-DETR es superior para discriminar oclusiones severas en entornos urbanos, su complejidad matemática escala cuadráticamente O(L^2) respecto a la longitud de los parches de entrada. Los estudios de benchmarking demuestran que las variantes de transformadores exigen un consumo masivo de memoria de video (VRAM), lo cual resulta técnica y financieramente prohibitivo para dispositivos de inferencia perimetral (Edge AI) de bajo presupuesto, como el NVIDIA Jetson Orin Nano propuesto para el proyecto.

La segunda comparación se enmarca en la propia evolución de la familia YOLO. Las iteraciones documentadas en la literatura científica de 2025 y 2026, específicamente YOLOv12 y YOLO26, representan saltos cualitativos. YOLOv12 introdujo un enfoque "centrado en la atención" (Attention-Centric) y redes de agregación eficiente (R-ELAN), logrando mejoras del 1% al 2% en la métrica mAP sobre conjuntos genéricos como COCO, pero imponiendo un sacrificio del 3% al 9% en la velocidad de inferencia matricial (Tian et al., 2025). Por otro lado, YOLO26 ha revolucionado el paradigma al eliminar por completo la dependencia del algoritmo de Supresión de No Máximos (NMS) en la fase de post-procesamiento. Al construir un diseño nativo de extremo a extremo e integrar el optimizador MuSGD y la asignación de etiquetas STAL (Small-Target-Aware Label Assignment), YOLO26 ha logrado acelerar la inferencia en arquitecturas carentes de GPU (CPU-only) hasta en un 43%.

A pesar de estas asombrosas promesas teóricas, la evidencia empírica en implementaciones industriales a gran escala sugiere que, para modelos de tamaño medio orientados a pruebas de concepto en ambientes cerrados, YOLOv11m conserva una ventaja pragmática en la estabilidad de convergencia y la madurez del ecosistema de exportación (TensorRT, ONNX). Por tanto, la elección de YOLOv11m está plenamente justificada y se sitúa notablemente cerca de la vanguardia funcional. Además, al observar corpus de investigación recientes altamente especializados en este dominio, como el conjunto de datos "ScatSpotter" (Crall, 2026) que contiene 9,000 imágenes de heces caninas, se confirma que incluso los modelos fundacionales masivos de tipo zero-shot (ej.

GroundingDINO) fracasan rotundamente en la detección directa de la anomalía biológica debido al camuflaje ambiental. Este hecho avala la genialidad algorítmica de SmartPet: desviar el foco de la red neuronal desde la minúscula deposición hacia la postura biomecánica del animal, maximizando así la tasa de acierto y la fiabilidad operativa.

Comparación frente a Modelos y APIs Comerciales

El último pilar del benchmarking exige cuestionar si el desarrollo de un pipeline algorítmico in-house (interno) aporta valor financiero y operativo frente al consumo de Inteligencia Artificial como Servicio (AIaaS).

Tabla 2

Comparación de costos, capacidades técnicas y limitaciones de plataformas comerciales y propietarias de visión artificial en la nube

Proveedor de Nube Comercial	Costo de Entrenamiento (Personalizado)	Costo Inferencia (Procesamiento Continuo)	Ventajas Técnicas	Limitaciones y Costos (Contexto CCTV 24/7)
AWS Rekognition (Custom Labels) 26	$1.00 USD / hora de entrenamiento.	$4.00 USD / hora de inferencia por flujo.	Integración nativa asíncrona; auto-escalado dinámico; ajuste fino (fine-tuning) de alta precisión con pocas imágenes.28	Costo prohibitivo. Ejecutar una sola cámara las 24 horas cuesta ~$2,880 USD al mes. Incurre en alta latencia inducida por la transferencia de red.8
Google Cloud Vertex AI Vision 29	$3.465 USD / hora de nodo computacional.	$2.002 USD / hora de nodo (Detección de Objetos en línea).	Altísima flexibilidad. Uso de ecosistema AutoML para entrenar clasificadores profundos; potente vinculación con BigQuery.31	Costo insostenible. La inferencia continua ronda los ~$1,440 USD al mes por cámara. Requiere gran ancho de banda de subida constante para streams RTSP.8
Microsoft Azure Custom Vision 32	Basado en consumo de recursos (Compute hours).	Pago transaccional por cada bloque de 1,000 llamadas a la API.	Excelente interfaz visual y flujos de trabajo (workflows) MLOps integrados en el ecosistema corporativo.	Precisión bruta marginalmente inferior en ciertos benchmarks especializados frente a AWS.32 El costo por frame destruye la viabilidad en videos de 15 FPS.33

SiiPet (LitterLens / PawTrack)	No aplica (modelo preentrenado propietario)	No aplica (procesamiento local en dispositivo Edge)	Procesamiento perimetral (Edge AI) con alta precisión empírica (~95%) en detección de heces caninas y felinas. Solución optimizada para entornos controlados con hardware dedicado.	Incompatible con el caso de uso SmartPet. Hardware propietario y cerrado, diseñado para interiores unifamiliares. No permite integración con infraestructura existente (NVR/CCTV). No escalable a múltiples flujos de video ni adaptable a entornos urbanos abiertos (SiiPet, 2025).

Nota. La tabla compara diferentes plataformas comerciales de Inteligencia Artificial como Servicio (AIaaS), incluyendo AWS Rekognition, Google Vertex AI Vision y la solución propietaria SiiPet. Se analizan aspectos como el modelo de facturación, la arquitectura de procesamiento (nube vs edge) y su viabilidad en escenarios de videovigilancia continua (CCTV 24/7). Los resultados evidencian limitaciones económicas y técnicas en soluciones basadas en la nube, frente a la propuesta perimetral del proyecto SmartPet.

El escrutinio de estas alternativas ratifica que el modelo de negocio monopolístico de la nube (Big Tech) es un entorno hostil para flujos de video continuos. La transferencia masiva de datos (streaming 24/7) hacia servidores externos no solo induce latencias asíncronas severas, sino que genera costos operativos mensuales (OpEx) depredadores. En franco contraste, el modelo propuesto por SmartPet materializa una inversión de capital inicial (CapEx) a través de microprocesadores perimetrales (ej. Jetson Orin Nano). Una vez asumido este costo, la inferencia perpetua mediante YOLOv11m desciende a un costo marginal de cero, consumiendo meramente una fracción de vataje eléctrico local (7W - 15W). Esto demuestra de manera inequívoca que la solución es técnica y financieramente superior a las alternativas comerciales genéricas.

Análisis de Sesgo Algorítmico (Fairness)

La adopción e integración de sistemas automatizados en espacios de convivencia comunitaria y sistemas de videovigilancia (Superintendencia de Industria y Comercio, 2023) exige un rigor ético incuestionable. Históricamente, la literatura académica y la ingeniería en torno a la equidad algorítmica (Fairness en Machine Learning) (Pérez-Llorca, 2024) se han centrado en la

mitigación de los denominados "daños de asignación" y "daños de representación", focalizándose de manera estricta en la protección de atributos demográficos humanos sensibles como la raza, el género o la edad frente a sistemas de reconocimiento facial o predictivos.

No obstante, cuando la inteligencia artificial se extrapola al análisis de la fauna, la infraestructura física y el entorno urbano a través del proyecto SmartPet, el paradigma del sesgo algorítmico muta profundamente. En este ecosistema, los atributos protegidos o "variables sensibles" no son demográficos, sino morfológicos, espaciales y ambientales. Un modelo que exhibe sesgo en este dominio incurre en un "daño de calidad de servicio" (Quality-of-Service Harm), operando de manera desigual y afectando desproporcionadamente la precisión de detección de ciertos tipos de animales o penalizando ciertas geometrías del entorno físico, lo cual podría traducirse en una aplicación asimétrica y discriminatoria del reglamento de propiedad horizontal para los residentes implicados.

Identificación Científica de Variables Sensibles

El Análisis Exploratorio de Datos (EDA) ejecutado sobre el corpus de 1,366 anotaciones geométricas (bounding boxes) sirvió como herramienta de diagnóstico primario para identificar las asimetrías subyacentes que el modelo YOLOv11m se vio obligado a procesar. De este escrutinio matemático se extrajeron las variables que propician un tratamiento desigual por parte del algoritmo:

Escala Geométrica y Profundidad Focal (Área Relativa)

La métrica de área (producto de ancho y alto) reveló una severa asimetría positiva en el conjunto de datos. Mientras que la media del área se ubicó en 0.3514, los cuartiles inferiores y la detección de densidades mínimas demostraron la existencia de cajas delimitadoras con áreas microscópicas de hasta 0.0058. Esta variable es sumamente sensible, pues segmenta a la población canina entre aquellos especímenes de gran tamaño capturados en primer plano (clase mayoritaria) y

aquellos perros de razas miniatura, o animales transitando en los confines más alejados del campo de visión de la cámara (minoría subrepresentada).

Morfología Biomecánica (Relación de Aspecto - Aspect Ratio)

El análisis de densidad comprobó que la silueta canina media tiende a resolverse en formas cercanas al cuadrado (relación cercana a 1.0). Sin embargo, la dispersión estadística desveló una larga cola hacia la derecha, tipificando 27 valores atípicos (outliers) morfológicos severos en la clase dog, alcanzando relaciones de aspecto de hasta 3.2380. Esta variable sensible discrimina algorítmicamente a perros de razas con proporciones longitudinales atípicas (ej. Dachshund, Galgos) o posturas en completo reposo lateral.

Topología de Captura (Ángulo Picado y Oclusión)

Dada la arquitectura física de los conjuntos residenciales en Bogotá, las cámaras de circuito cerrado (CCTV) operan invariablemente con ángulos en picado pronunciado para maximizar el área de cobertura. Esta variable ambiental resulta altamente restrictiva, pues el plano cenital comprime la anatomía del animal, ocultando y ocluyendo total o parcialmente la flexión angular de los miembros posteriores, rasgo fenotípico indispensable para discriminar entre las clases dog y defecating-dog.

Varianza Lumínica Urbana

Aunque el EDA base se concentró en la dimensión geométrica, la literatura de visión artificial dictamina que el contraste térmico y lumínico en exteriores rige el desempeño de los tensores convolucionales. Sombras proyectadas por el follaje, iluminación artificial de vapor de sodio y penumbras absolutas constituyen un vector de sesgo que penaliza a los animales de pelaje oscuro

Evaluación del Impacto Diferencial por Grupos (Fairness Metrics)

Al transpolar el rendimiento operativo del modelo hacia estas categorías subrepresentadas, emergen discrepancias estadísticas inherentes a las limitaciones matemáticas fundacionales de las redes neuronales en tareas de Detección de Objetos Pequeños (SOD).

Tabla 3

Evaluación del impacto del sesgo algorítmico según variables sensibles en la detección

Grupo Segmentado por Variable Sensible	Tasa de Aciertos (True Positive Rate) Proyectada	Error de Clasificación / Falsos Negativos	Explicación del Fenómeno de Disparidad
Grupo Dominante: Razas grandes/medianas en primer plano (Área Bounding Box > 0.30)	Óptima (> 95%)	Mínimo	La red convolucional extrae mapas de características espaciales multi escala sumamente densos, discriminando sin esfuerzo texturas posturales frente al fondo.
Minoría Escalar: Razas miniatura o lejanas (Área Bounding Box < 0.02)	Deficiente o Degradada (< 70%)	Elevado (Falsos Negativos)	**Sesgo de Escala:** Operaciones de reducción de dimensionalidad (Max Pooling) destruyen los píxeles útiles de objetos diminutos, fusionándolos matemáticamente con el ruido de alta frecuencia del entorno.
Minoría Morfológica: Proporciones atípicas (Outliers en Relación de Aspecto > 2.5)	Moderada	Dispersión de Error de Localización	**Sesgo Geométrico:** La penalización intrínseca en la función de pérdida de cajas de anclaje (Box Loss / CIoU) se optimiza para resolver promedios; los eventos extremos son forzados a encajar en distribuciones penalizadas.
Restricción Topológica: Planos cenitales de cámaras a gran altura	Degradada	Confusión Inter-clase (Falsos Positivos)	**Sesgo de Perspectiva:** La compresión topológica imposibilita la lectura del canal cinemático. El modelo confunde perros sentados o en exploración olfativa con el evento de deposición

Nota. La tabla presenta el análisis del desempeño del modelo en función de diferentes variables sensibles identificadas en el estudio, tales como escala del objeto, morfología del animal y condiciones de captura. Se incluyen métricas proyectadas de tasa de aciertos (True Positive Rate), errores de clasificación y explicaciones del fenómeno de disparidad. Los resultados evidencian la existencia de sesgos estructurales asociados principalmente a la detección de objetos pequeños (SOD) y variaciones geométricas, afectando de manera diferencial a ciertos grupos.

Reflexión, Argumentación y Estrategias de Mitigación

Ante la interrogante de si existe sesgo en el modelo evaluado, la respuesta es afirmativa e ineludible. Sin embargo, este sesgo no emana de una negligencia explícita en el diseño del modelo, sino de las propiedades estructurales de optimización probabilística inherentes a los algoritmos de Deep Learning. Las Redes Neuronales Convolucionales, como YOLOv11m, operan minimizando una función de pérdida global sobre el universo de entrenamiento. Debido a la distribución asimétrica natural (donde la inmensa mayoría de instancias capturan distancias medias y proporciones estándar), el gradiente matemático del algoritmo "sacrifica" tácitamente el rendimiento en las colas estadísticas (las minorías de escala y forma) para maximizar la exactitud general del sistema.

En el ámbito social y operativo de la propiedad horizontal, esta asimetría tecnológica posee ramificaciones tangibles. Las limitaciones en la tasa de aciertos para canes diminutos o residentes que transitan en los bordes ciegos de la copropiedad crearían zonas grises de impunidad, derivando en un tratamiento desigual y frustrando el propósito de equidad vecinal.

Para neutralizar este fenómeno y restaurar la "paridad algorítmica", la investigación debe trascender el conformismo estadístico e incorporar intervenciones profundas de mitigación en múltiples dimensiones:

Ingeniería de Inferencia Hiper-Fragmentada (SAHI)

La solución canónica y de vanguardia para erradicar el sesgo contra objetos microscópicos (SOD) consiste en la implementación arquitectónica de Slicing Aided Hyper Inference (SAHI). Esta técnica

intercepta el fotograma masivo del CCTV, lo secciona en una matriz de cuadrículas superpuestas y realiza la inferencia neuronal sobre cada parche individual. Este proceso preserva la resolución nativa de los animales lejanos, impidiendo que sus características se diluyan en el abismo del pooling espacial.

Alineación de Anclajes Dinámicos (AutoAnchoring)

Las asimetrías morfológicas, demostradas por los 27 *outliers* en el EDA, obligan a un reentrenamiento configurando algoritmos de agrupamiento (K-Means) que recalculen de manera empírica las proporciones de las cajas preestablecidas, obligando al tensor de predicción a extender su espectro de tolerancia geométrica.

Evolución del Protocolo de Recolección de Datos

La mitigación definitiva del sesgo reside en los cimientos de los datos. Se recomienda emular la rigurosidad académica del conjunto de datos "ScatSpotter" (2026), mediante el uso de protocolos de captura denominados BAN (*Before/After/Negative*). Esta técnica exige que, por cada imagen de una deposición anómala, se capture forzosamente una imagen con distractores morfológicos visualmente idénticos pero falsos (hojas, sombras, barro) desde los mismos ángulos negativos y distancias extremas. Inyectar estos negativos difíciles y específicos obliga a la red neuronal a desestimar atajos heurísticos, inmunizándola contra las oclusiones lumínicas y espaciales del entorno residencial.

Diagnóstico de Overfitting / Underfitting

La validación de un sistema de inteligencia artificial no se fundamenta en su capacidad para memorizar un conjunto de datos estático, sino en el poder de su topología neuronal para abstraer características fenotípicas complejas y generalizarlas eficazmente sobre información visual inédita. En el dominio del análisis de secuencias de video ininterrumpidas, particularmente en la videovigilancia de posición fija (CCTV), el fenómeno de sobreajuste (overfitting) se alza como el

vector de fallo más devastador y persistente. Las cámaras, al operar desde una perspectiva estática, capturan iterativamente la misma geometría del fondo—la misma acera, el mismo tronco, el mismo muro de contención. En ausencia de un rigor metodológico implacable, las redes neuronales claudican en su esfuerzo por modelar la sutil cinemática de la postura canina y, perversamente, optimizan su gradiente "memorizando" la topología estática del fondo como predictor secundario

Análisis Crítico de las Curvas de Aprendizaje y Diagnóstico

El análisis cuantitativo de la convergencia, documentado en el benchmarking, proporcionó la evidencia empírica necesaria para efectuar un diagnóstico definitivo de la capacidad de abstracción de las arquitecturas evaluadas, a través de la interpretación del comportamiento de las funciones de pérdida (Training Loss vs. Validation Loss).

Tabla 4

Diagnóstico comparativo de overfitting y generalización en MobileNet-SSD y YOLOv11m

Caso Diagnóstico Evaluado	Comportamiento de las Curvas de Loss / Métricas de Desempeño	Explicación del Fenómeno de Disparidad
MobileNet-SSD (Baseline)	**Divergencia Clásica en Forma de "U":** Durante las primeras épocas de entrenamiento, ambas curvas descendieron de forma correlacionada. No obstante, a partir del ciclo de iteración (epoch) número 60, la pérdida de validación sufrió un estancamiento abrupto, seguido de un incremento paulatino, mientras que la pérdida de entrenamiento continuó precipitándose hacia cero de manera espuria. Esto provocó una severa degradación relativa en la métrica F1 (caída del 5.25% en datos no vistos).	**Sobreadaptación (Overfitting Severo):** El modelo, de baja profundidad paramétrica, agotó rápidamente su capacidad heurística. En lugar de extraer características sutiles del animal, la red se saturó, internalizando y memorizando el ruido estático y el fondo específico de los escenarios de entrenamiento. En producción, la red es incapaz de extrapolar y genera alertas de falsos positivos ante nuevas sombras o asfalto desconocido.

YOLOv11m (Modelo Propuesto)	**Convergencia Asintótica Acompasada:** Las curvas de pérdida, tanto para el universo de entrenamiento como de validación cruzada, mantuvieron una trayectoria estrecha, descendiendo suave y paralelamente hasta estabilizarse en un mínimo local congruente. La brecha relativa de generalización fue mínima, exhibiendo apenas una caída marginal del 3.07% en el F1-Score y reteniendo un contundente mAP@50 del 94.7%.	**Ajuste Óptimo (Buen Ajuste):** Favorecida por sus más de 20 millones de parámetros y la inserción de mecanismos de atención multi escala, la red neuronal absorbió orgánicamente la enorme variabilidad geométrica del conjunto de datos sin sucumbir a la contaminación cruzada o a la memorización del fondo. La red abstrae de manera pura el concepto "perro defecando" sin depender del entorno que lo enmarca.

Nota. La tabla resume el comportamiento de las curvas de entrenamiento y validación para los modelos evaluados, junto con su interpretación algorítmica. Se analizan patrones de convergencia, divergencia y estabilidad, permitiendo identificar la presencia de sobreajuste (overfitting) en MobileNet-SSD y un ajuste óptimo en YOLOv11m. Los resultados reflejan la capacidad del modelo propuesto para generalizar adecuadamente en datos no vistos

Justificación Metodológica del Comportamiento Exitoso

Es de vital importancia académica subrayar que el excelente grado de ajuste (Buen Ajuste) exhibido por la arquitectura YOLOv11m no obedece a un mero accidente estadístico o a la simple superioridad de sus módulos convolucionales, sino a una impecable estrategia en la ingeniería del ecosistema de validación.

Para blindar al modelo contra el sobreajuste provocado por la alta similitud secuencial de los fotogramas de video, el diseño experimental implementó inteligentemente la metodología de Group K-Fold Cross-Validation. Esta técnica garantiza que la segmentación de imágenes entre los conjuntos de entrenamiento y prueba no sea aleatoria e individual. Por el contrario, obliga algorítmicamente a que todos los frames extraídos de un mismo clip temporal sean tratados como un grupo atómico indivisible.

Al prohibir la segregación de imágenes casi idénticas del mismo evento (donde un milisegundo cae en entrenamiento y el contiguo en validación), se sella definitivamente la vía de fuga de información (data leakage), forzando a la red a validar su conocimiento frente a perros, escenarios y ángulos radicalmente inéditos.

Propuestas Técnicas de Mejora Continua

A pesar del sobresaliente diagnóstico obtenido por el modelo YOLOv11m, la frontera de la inteligencia artificial dicta que la robustez frente al sobreajuste y la varianza debe refinarse continuamente. En miras a un despliegue operativo en centenares de copropiedades, se proponen las siguientes mejoras estructurales:

Regularización Neuronal Avanzada (DropBlock)

Se recomienda intervenir la arquitectura interna de la red neuronal mediante la inyección de capas de DropBlock. A diferencia del Dropout clásico, que desactiva nodos de manera estocástica, DropBlock anula espacialmente regiones contiguas de píxeles en los mapas de características. Esto obliga matemáticamente al tensor a no anclarse obsesivamente en una única característica altamente correlacionada (como la silueta del lomo), forzando a la red a buscar redundancia semántica en la curvatura de la cola o la flexión de las extremidades inferiores.

Perturbación Sintética Extrema (Data Augmentation)

Se debe amplificar el pipeline de procesamiento de datos incorporando técnicas contemporáneas como Copy-Paste Augmentation. Este método extrae algorítmicamente las máscaras segmentadas de los caninos y las incrusta aleatoriamente en una vasta gama de imágenes de fondo ruidoso, urbano y discordante, quebrando violentamente cualquier correlación causal remanente entre el sujeto de interés y la textura del asfalto o pasto que lo sustenta.

Ajuste Dinámico de Hiperparámetros (Weight Decay y Optimización)

Se exhorta a recalibrar las funciones de decaimiento de pesos (L2 Regularization) dentro de los algoritmos de optimización (AdamW / SGD). Incrementar el rigor de esta regularización durante la fase tardía (tail-end) del entrenamiento penaliza el crecimiento atípico de los pesos sinápticos, garantizando que el modelo se mantenga agnóstico y tolerante frente a las inevitables distorsiones visuales del mundo físico real.

Recomendaciones

Habiendo validado de manera rigurosa la robustez algorítmica, los parámetros de equidad tecnológica y el desempeño topológico de la arquitectura evaluada, el escrutinio académico permite decantar un conjunto de directrices estratégicas de alto nivel. Estas recomendaciones están diseñadas para garantizar la escalabilidad sostenida, la integridad regulatoria y la maximización del valor económico en el despliegue a producción del proyecto SmartPet:

Diseño Arquitectónico Agnóstico para la Migración hacia YOLO26

El desempeño excepcional de YOLOv11m certifica su viabilidad actual para la prueba de concepto y el despliegue temprano. No obstante, para asegurar la resiliencia tecnológica frente a la rápida obsolescencia de los ecosistemas de Edge AI, la infraestructura de software (pipelines de ingestión de video, post-procesamiento RTSP) debe estructurarse mediante paradigmas altamente modulares. La literatura científica de frontera (2026) dictamina que la adopción de redes de diseño de extremo a extremo, libres de las heurísticas limitantes de la Supresión de No Máximos (NMS-free), específicamente encarnadas en la familia YOLO26, constituye el horizonte ineludible. La capacidad de YOLO26 para reducir la latencia de inferencia hasta en un 43% en unidades de procesamiento central (CPUs) extenderá dramáticamente el ciclo de vida del silicio perimetral adquirido por las copropiedades, optimizando de manera sustancial la Tasa de Retorno de Inversión (ROI) y consolidando la economía de escala.

Mitigación Activa de la Exclusión Algorítmica (SAHI)

El análisis de sesgo (fairness) desveló una degradación severa en el rendimiento frente a la clase minoritaria de perros miniatura o capturas lejanas, un síntoma clásico del problema de Detección de Objetos Pequeños (SOD). Para garantizar un trato equitativo e imparcial a todos los residentes, independientemente del tamaño de su mascota o su proximidad a las lentes, resulta un imperativo técnico la integración prospectiva del módulo Slicing Aided Hyper Inference (SAHI) en el ambiente de producción. Al fragmentar y escanear los fotogramas panorámicos de alta definición antes de su procesamiento tensorial, el sistema retendrá la densidad de píxeles necesaria para anular los falsos negativos derivados de la distancia.

Adopción Estricta del Paradigma Human-in-the-Loop

Desde la dimensión ética y procedimental, la inteligencia artificial no debe ser concebida en el ámbito residencial como un ente punitivo autónomo. Las asambleas de propietarios deben incorporar a sus manuales de convivencia la directriz inquebrantable de que ninguna notificación o metadato emanado del modelo SmartPet generará sanciones económicas o requerimientos disciplinarios de forma automática. El ecosistema tecnológico debe fungir estrictamente como un vector de amplificación cognitiva (Human-in-the-Loop) (Pérez-Llorca, 2024; Superintendencia de Industria y Comercio, 2024). La inferencia del modelo actuará exclusivamente como un recomendador probabilístico de alta celeridad, delegando irrevocablemente en el personal humano de seguridad la capacidad racional de validar la alerta, contextualizar la intencionalidad del infractor y aplicar los protocolos comunitarios de resolución de conflictos, salvaguardando de este modo la garantía constitucional del debido proceso.

Blindaje y Auditoría Normativa Frente a la SIC (Circular 002)

En consonancia con los principios del Derecho de Habeas Data y los vanguardistas lineamientos establecidos por la Superintendencia de Industria y Comercio mediante la Circular Externa 002 de 2024 (Superintendencia de Industria y Comercio, 2024), el procesamiento analítico confinado en el borde (Edge AI) debe mantenerse inviolable. Se recomienda vehementemente certificar, de manera anual, la ejecución de una Evaluación de Impacto de Privacidad (EIP). Este instrumento legal debe auditar el código fuente del sistema para demostrar que el tensor predictivo carece, en su nivel fundamental, de matrices para la extracción biométrica humana, la exfiltración masiva de secuencias de video, o el perfilamiento algorítmico de los ciudadanos, encarnando materialmente el estándar global de Privacidad por Diseño (Superintendencia de Industria y Comercio, 2024).

Conclusiones

La evaluación experta del trabajo investigativo en torno al proyecto "SmartPet" permite colegir, sin lugar a dudas, que el desarrollo logra una amalgama excepcional entre la sofisticación analítica de la visión artificial contemporánea, el rigor metodológico exigido por el ámbito académico, y la sensibilidad ineludible frente al garantista marco jurídico de la protección de datos personales.

En la dimensión métrica y arquitectónica, el benchmarking expone que la decisión de apartarse de los paradigmas de detección basados en anclajes estáticos (MobileNet-SSD) para adoptar un modelo convolucional dinámico e hiper-profundo (YOLOv11m) no solo está justificada, sino que constituye la piedra angular de la viabilidad de la solución. Al pulverizar la precaria precisión de la línea base (76.5%) y certificar un F1-Score robusto superior al 91%, YOLOv11m consigue abstraer el concepto cinemático y biomecánico de la deposición canina superando obstáculos abrumadores documentados en el Análisis Exploratorio de Datos, tales como la varianza extrema en la relación de aspecto y las resoluciones microscópicas de la Detección de Objetos Pequeños (SOD).

Así mismo, las dinámicas de convergencia neural confirman una ejecución metodológica impecable por parte del equipo investigador. La erradicación sistemática del riesgo de sobreajuste (overfitting) siendo ese defecto endémico que condena a los algoritmos de videovigilancia a la memorización pasiva del escenario de entrenamiento, fue magistralmente mitigada mediante técnicas estrictas de validación cruzada agrupada (Group K-Fold). Esto dota al modelo de una capacidad envidiable de extrapolación en escenarios físicos complejos, certificando su madurez frente a las disrupciones teóricas de arquitecturas más modernas. Adicionalmente, al validar financieramente que el costo de operar inferencias computacionales perpetuas en la nube (Big Tech) desbordaría cualquier presupuesto administrativo convencional, se legitima de manera aplastante el diseño centrado en el hardware de frontera (Edge AI).

Desde una óptica reflexiva y deontológica, el desarrollo destaca por su audaz tratamiento de las métricas de equidad (Fairness). La investigación trasciende los análisis de sesgo demográfico convencionales para cuestionar la justicia tecnológica en el urbanismo: reconocer que la precisión degradada frente a caninos de raza pequeña o distantes fomenta asimetrías de control social es una reflexión del más alto nivel académico, pavimentando el camino para mejoras infraestructurales contundentes como SAHI y protocolos negativos de captura (BAN).

En síntesis, al coartar arquitectónicamente la exfiltración de imágenes hacia servidores de terceros y al confinar el espectro de análisis única y exclusivamente a la anomalía biológica (obviando el reconocimiento facial y la biometría humana), el proyecto se inserta orgánicamente dentro del ordenamiento jurídico regido por la Ley Estatutaria 1581 y los imperativos éticos de la Inteligencia Artificial promovidos por las entidades de control (Congreso de Colombia, 2012; Superintendencia de Industria y Comercio, 2024). En definitiva, "SmartPet" se instaura no solo como un artefacto ingenieril escalable y productivamente viable, sino como un trabajo investigativo sobresaliente y altamente riguroso, holísticamente digno del más alto reconocimiento en una instancia de maestría.

Referencias

Congreso de Colombia. (2012). *Ley Estatutaria 1581 de 2012. Por la cual se dictan disposiciones generales para la protección de datos personales*. Diario Oficial No. 48. 43 https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=49981

Copropiedades. (2026). *Tarifas mínimas para la contratación de servicios de vigilancia y seguridad privada vigencia 2026*. Tarifas mínimas para la contratación de servicios de vigilancia y seguridad privada vigencia 2026

Crall, J. (2026). ScatSpotter: *A dog poop detection dataset. Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision* (WACV) Workshops. (pp. 549–558). https://openaccess.thecvf.com/content/WACV2026W/WasteVision/html/Crall_ScatSpotter_A_Dog_Poop_Detection_Dataset_WACVW_2026_paper.html

Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). *MobileNets: Efficient convolutional neural networks for mobile vision applications* (arXiv:1704). arXiv. https://arxiv.org/abs/1704.04861

Jocher, G., Chaurasia, A., & Qiu, J. (2023). YOLO by Ultralytics (Versión 8). GitHub. https://github.com/ultralytics/ultralytics

Lv, W., Xu, S., Zhao, Y., Wei, J., Wang, G., Cui, C., Du, Y., Dang, Q., & Liu, Y. (2024). *DETRs beat YOLOs on real-time object detection*. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. https://openaccess.thecvf.com/content/CVPR2024/papers/Zhao_DETRs_Beat_YOLOs_on_Real-time_Object_Detection_CVPR_2024_paper.pdf

Pérez-Llorca. (2024). *Conoce los lineamientos para el uso de datos personales a través de sistemas de inteligencia artificial*. Conoce los lineamientos para el uso de datos personales a través de sistemas de Inteligencia Artificial

SiiPet. (2025). *¿Can cameras detect poop that has not been picked up?* https://siipet.com/blogs/knowledge/can-cameras-detect-poop-that-has-not-been-picked-up

Superintendencia de Industria y Comercio. (2023). *Tratamiento de datos personales a través de cámaras de videovigilancia.* Concepto Jurisdiccional. https://sedeelectronica.sic.gov.co/boletin-juridico/conceptos/tratamiento-de-datos-personales-traves-de-camaras-de-videovigilancia

Superintendencia de Industria y Comercio. (2024). *Circular Externa 002 de 2024. Lineamientos sobre el Tratamiento de Datos Personales en Sistemas de Inteligencia Artificial*. https://sedeelectronica.sic.gov.co/transparencia/normativa/circular-externa-2-de-2024-de-la-superintendencia-de-industria-y-comercio-lineamientos-sobre-el-tratamiento-de-datos?utm_source=chatgpt.com

Tian, Y., Ye, Q., & Doermann, D. (2025). YOLO12: *Attention-Centric Real-Time Object Detectors*. NeurIPS 2025. YOLOv12: Attention-Centric Real-Time Object Detectors | OpenReview