# Presentación Evaluación y Optimización del Modelo: Proyecto SmartPet

Juan Miguel Velandia García

Oscar Mauricio Parra Folleco

Maestría en Inteligencia Artificial, Universidad de Especialidades Espíritu Santo.

Proyecto Integrador en Inteligencia Artificial.

Dra. Alexandra Jacqueline Arciniegas Coral

24 de abril de 2026

**Resumen**

El presente informe detalla exhaustivamente la fase de evaluación, generalización, validación y optimización de hiperparámetros de un modelo de inteligencia artificial fundamentado en la arquitectura convolucional YOLOv11m. Este desarrollo tecnológico está diseñado para la detección automatizada de excreción de heces caninas en conjuntos cerrados de estrato, y en la ciudad de Bogotá, específicamente en zonas residenciales prohibidas, mediante el procesamiento en tiempo real de flujos de video provenientes de circuitos cerrados de televisión (CCTV) procesados bajo el paradigma de computación en el borde. Ante los formidables desafíos geométricos impuestos por la captura de video en ángulos picados y la extrema variabilidad morfológica de las diferentes razas caninas, el estudio despliega un análisis profundo de equidad algorítmica (fairness). Este análisis está orientado a identificar y mitigar sesgos de escala y perspectiva que penalizan severamente la detección de objetos de tamaño fraccionario, un fenómeno conocido en la literatura como Detección de Objetos Pequeños. La rigurosa validación empírica, apoyada en técnicas de validación cruzada agrupada, demuestra que la arquitectura seleccionada supera de manera contundente a las líneas base históricas como MobileNet-SSD, alcanzando un F1-Score del 91.3% y manteniendo una latencia operativa perimetral de 16.9 milisegundos, lo que viabiliza su implementación a gran escala sin depender de costosas infraestructuras en la nube. De manera complementaria, el documento aborda un ciclo analítico de optimización de hiperparámetros de alto rigor técnico. Mediante la aplicación de Gráficos de Dependencia Parcial (PDP), la construcción de modelos subrogados para el ranking de importancia y la evaluación de interacciones bivariadas, el estudio permite aislar y comprender el efecto marginal de variables topológicas críticas, tales como la tasa de aprendizaje inicial, el coeficiente de decaimiento de pesos y la probabilidad de aumento de datos mediante mosaics combinados. Finalmente, la investigación consolida un marco de recomendaciones operativas y regulatorias diseñadas para garantizar que el despliegue del modelo en ambientes comunitarios respete los principios inalienables de privacidad por diseño, mitigación proactiva de

sesgos algorítmicos y supervisión humana integral (Human-in-the-Loop). (Molnar, 2025; Scikit-learn, 2026).

## Introducción

La densificación demográfica, la acelerada urbanización y la verticalización de los espacios de vivienda han transformado profundamente las dinámicas de convivencia dentro de los regímenes de propiedad horizontal. En estos ecosistemas residenciales, la tenencia de animales de compañía ha experimentado un crecimiento sostenido, consolidándose como un factor determinante en el bienestar emocional de los núcleos familiares contemporáneos. Sin embargo, esta misma dinámica se ha erigido paralelamente como una de las fuentes primarias de conflictos vecinales, derivados de manera fundamental del manejo inadecuado de los residuos biológicos en áreas comunes, senderos peatonales y zonas verdes protegidas. Históricamente, la mitigación de estas contravenciones a los manuales de convivencia ha dependido casi en su totalidad de la vigilancia humana presencial y de la revisión manual retrospectiva de los circuitos cerrados de televisión por parte del personal de seguridad de las administraciones residenciales. Estos métodos tradicionales resultan crónicamente ineficientes, son altamente propensos a la fatiga visual humana, y se tornan financieramente insostenibles frente a los incrementos exponenciales en las tarifas reguladas de seguridad privada. (Congreso de Colombia, 2001, 2012; Superintendencia de Industria y Comercio, 2024).

Ante esta problemática estructural que afecta la calidad de vida comunitaria, la visión por computadora y, en particular, las redes neuronales convolucionales (CNN) de una sola etapa, ofrecen un paradigma disruptivo y proactivo para la detección de anomalías en tiempo real. El presente informe plantea transformar la infraestructura pasiva de videovigilancia existente en un ecosistema de monitoreo inteligente, predictivo y preventivo. No obstante, la transposición de modelos teóricos de aprendizaje profundo a infraestructuras de vigilancia perimetral en el mundo real enfrenta barreras computacionales, geométricas y topológicas de extrema severidad. Las cámaras de seguridad CCTV suelen instalarse en posiciones elevadas para maximizar el campo de

visión, lo que genera inevitablemente perspectivas de ángulo picado o negativo. Esta inclinación distorsiona de manera significativa la escala relativa, la relación de aspecto bidimensional y la morfología aparente de los sujetos en el plano focal, alterando la firma visual de los caninos en función de su distancia al lente. Este fenómeno físico inscribe el desafío analítico directamente en el dominio de la Detección de Objetos Pequeños, un subcampo de la inteligencia artificial caracterizado por la escasez crítica de píxeles informativos, la alta varianza lumínica urbana, las oclusiones ambientales y la degradación de características durante el procesamiento tensorial. (Ultralytics, 2026c).

El presente documento constituye el desarrollo técnico de la fase de evaluación y optimización del modelo propuesto para resolver este desafío. Su objetivo principal es dictaminar de manera crítica, analítica y fundamentada el desempeño integral de la arquitectura YOLOv11m, trascendiendo la mera descripción superficial de métricas de precisión para adentrarse en la explicabilidad del comportamiento del modelo. Para lograr este nivel de profundidad, el análisis se estructura metodológicamente en dimensiones fundamentales. En primera instancia, se desarrolla la detección de sesgos y la equidad algorítmica, evaluando de qué manera las asimetrías geométricas del conjunto de datos penalizan diferencialmente a subpoblaciones específicas, tales como los caninos de razas miniatura, y estableciendo mecanismos técnicos para su corrección.

Posteriormente, se expone la validación topológica y la capacidad de generalización del modelo, contrastando su rendimiento frente a líneas base históricas y el estado del arte actual, mientras se diagnostican las dinámicas de convergencia para descartar patologías de aprendizaje como el sobreajuste. A continuación, se ejecuta un análisis avanzado de sensibilidad de hiperparámetros. En este apartado se emplean técnicas de interpretabilidad de modelos de caja negra, específicamente los Gráficos de Dependencia Parcial, acompañados de algoritmos de ranking de importancia y el análisis de interacciones bivariadas, lo que garantiza una comprensión profunda de la superficie de pérdida y la máxima eficiencia en la convergencia del gradiente. Finalmente, el

documento se cierra con el establecimiento de recomendaciones operativas y regulatorias exigidas para la viabilidad de la solución en el marco jurídico vigente. (Molnar, 2025; Scikit-learn, 2026).

**Desarrollo de la Detección de Sesgos y Equidad Algorítmica**

La adopción e integración de sistemas automatizados de inteligencia artificial en espacios de convivencia comunitaria exige un nivel de rigor ético y funcional incuestionable. De manera histórica, la literatura académica y la ingeniería en torno a la equidad algorítmica se han centrado de manera casi exclusiva en la mitigación de los denominados "daños de asignación" y "daños de representación". El enfoque se ha dado en la protección de atributos demográficos humanos sensibles, tales como la raza, el género o la edad, principalmente frente a sistemas de reconocimiento facial, predicción de reincidencia criminal o evaluación de riesgo crediticio. Sin embargo, cuando la capacidad predictiva de la inteligencia artificial se extrapola al análisis de la fauna, la infraestructura física y el entorno urbano no controlado, el paradigma teórico del sesgo algorítmico experimenta una mutación profunda. (Farshad et al., 2024; Ferrara, 2024).

En el ecosistema específico del proyecto, los atributos que requieren protección o que actúan como "variables sensibles" no son de naturaleza demográfica, sino intrínsecamente morfológica, espacial y ambiental. Un modelo de detección de objetos que exhibe sesgo en este dominio particular incurre en lo que la teoría define como un "daño de calidad de servicio". Este tipo de daño se manifiesta cuando el sistema opera de manera desigual y asimétrica, afectando desproporcionadamente la precisión de detección de ciertos tipos de animales o penalizando de manera sistemática ciertas geometrías del entorno físico. En el contexto operativo de una copropiedad, una degradación algorítmica de esta naturaleza podría traducirse en una aplicación discriminatoria del reglamento interno, donde los propietarios de caninos de razas grandes son fiscalizados con extrema precisión, mientras que las infracciones cometidas por razas miniatura en los confines del circuito de vigilancia resultan sistemáticamente ignoradas por el sistema. (Ultralytics, 2026c).

**Identificación Científica de Variables Sensibles**

Para abordar este desafío de manera cuantitativa, se recurrió a los hallazgos del Análisis Exploratorio de Datos ejecutado sobre el corpus inicial de 1680 anotaciones geométricas, el cual fue depurado hasta consolidar 1499 anotaciones de alta fidelidad tras los procesos de filtrado de ruido. Este escrutinio matemático profundo sirvió como herramienta de diagnóstico primario para aislar e identificar las variables que propician un tratamiento desigual y asimétrico por parte del algoritmo YOLOv11m. De este análisis se extrajeron tres dimensiones críticas de vulnerabilidad. (Ultralytics, 2026c).

La primera variable sensible identificada corresponde a la escala geométrica y la profundidad focal, parametrizada a través del área relativa de la caja delimitadora. La métrica de área, calculada geométricamente como el producto del ancho y el alto normalizados, reveló una severa asimetría positiva en el conjunto de datos. El análisis descriptivo detallado estableció que la media del área se ubicó en 0.3075, con una mediana de 0.2741. No obstante, los cuartiles inferiores y la detección de densidades mínimas demostraron la existencia de cajas delimitadoras con áreas microscópicas que descendían hasta valores críticos de 0.0005, mientras que los valores máximos alcanzaban el 0.9725.

Esta variable resulta sumamente sensible debido a que segmenta a la población canina en dos grandes grupos: por un lado, aquellos especímenes de gran tamaño capturados en primer plano, que constituyen la clase mayoritaria y dominante; y por otro, aquellos perros de razas miniatura, o animales que transitan en los confines más alejados del campo de visión de la cámara, que conforman la minoría subrepresentada. A nivel arquitectónico, las operaciones de reducción de dimensionalidad, como el Max Pooling presente en las redes convolucionales, tienden a destruir de manera irreversible los pocos píxeles útiles que componen a estos objetos diminutos, fusionándolos matemáticamente con el ruido de alta frecuencia del entorno del asfalto o la vegetación. (Ultralytics, 2026c).

La segunda dimensión de vulnerabilidad radica en la morfología biomecánica, cuantificada a través de la relación de aspecto de las detecciones. El análisis de densidad comprobó que la silueta canina media tiende a resolverse en formas cercanas al cuadrado, con una media de 0.9557 y una mediana de 0.8924. Sin embargo, la dispersión estadística calculada mediante el método del Rango Intercuartílico desveló una larga cola hacia la derecha, tipificando valores atípicos morfológicos severos exclusivos para la clase principal, donde las relaciones de aspecto fluctuaban drásticamente desde 0.1869 hasta un extremo de 3.2903. Esta variable sensible discrimina algorítmicamente a especímenes con proporciones longitudinales atípicas, tales como las razas Dachshund o los Galgos, así como a aquellos individuos capturados en posturas de reposo lateral absoluto. La rigidez de las regresiones de las cajas delimitadoras penaliza fuertemente estas proporciones excepcionales, forzando al tensor a encajar predicciones en distribuciones que no reflejan la realidad fenotípica del animal.

La tercera variable crítica se centra en la topología de captura, específicamente influenciada por el ángulo picado y los fenómenos de oclusión. Dada la arquitectura física inalterable de los conjuntos residenciales, las cámaras operan invariablemente con ángulos en picado pronunciado para maximizar el área de cobertura del suelo. Esta variable ambiental resulta altamente restrictiva, puesto que el plano cenital comprime la anatomía vertical del animal, ocultando y ocluyendo total o parcialmente la flexión angular de los miembros posteriores. Esta flexión es el rasgo fenotípico indispensable que la red neuronal requiere para discriminar categóricamente entre un perro en estado de tránsito normal y un perro en posición de deposición. Esta compresión topológica imposibilita la lectura del canal cinemático, incrementando la propensión a la confusión inter-clase y a la emisión de falsos positivos frente a conductas exploratorias u olfativas rutinarias.

**Impacto Diferencial por Grupos**

Al transpolar el rendimiento operativo del modelo matemático hacia estas categorías subrepresentadas, emergen discrepancias estadísticas profundas que son inherentes a las

limitaciones fundacionales de las redes neuronales en tareas de detección a pequeña escala. La optimización probabilística de la red minimiza una función de pérdida global sobre la totalidad del universo de entrenamiento. Debido a la distribución asimétrica natural de los datos, el gradiente matemático del algoritmo "sacrifica" tácitamente el rendimiento en las colas estadísticas para maximizar la exactitud general del sistema en los casos más frecuentes. (Ultralytics, 2026c).

Este fenómeno se comprobó en la proyección de la Tasa de Verdaderos Positivos. Para el grupo dominante, caracterizado por razas grandes o medianas ubicadas en un primer plano con áreas de caja superiores a., la red extrae mapas de características espaciales multiescala sumamente densos, discriminando sin esfuerzo las texturas posturales frente al fondo y logrando tasas de acierto proyectadas superiores al 95%. En un contraste radical, la minoría escalar, compuesta por áreas inferiores a., sufre una degradación del rendimiento por debajo del 70%, evidenciando un elevado número de falsos negativos producto del sesgo de escala. Asimismo, la minoría morfológica, representada por los valores atípicos en la relación de aspecto, manifiesta una alta dispersión en el error de localización debido a que la penalización intrínseca en la función de pérdida geométrica (como el CIoU Loss) se optimiza para resolver promedios estadísticos, forzando a los eventos anatómicos extremos a encajar en distribuciones rígidas y penalizadas. (Ultralytics, 2026c).

**Estrategias Estructurales de Mitigación de Sesgos**

Ante la comprobación ineludible de la existencia de estos sesgos operativos, la investigación trascendió el conformismo estadístico para incorporar intervenciones de ingeniería profundas orientadas a restaurar la paridad algorítmica y asegurar la equidad del sistema.

La estrategia principal para erradicar el sesgo contra objetos microscópicos consiste en la implementación arquitectónica futura de la Inferencia Hiper-Fragmentada Asistida, conocida en la literatura técnica como Slicing Aided Hyper Inference (SAHI). Esta técnica de vanguardia intercepta el fotograma masivo capturado por el CCTV, lo secciona metodológicamente en una matriz de cuadrículas superpuestas y realiza la inferencia neuronal de manera aislada sobre cada parche

individual. Este minucioso proceso preserva intacta la resolución nativa de los animales más lejanos o pequeños, impidiendo de forma categórica que sus frágiles características visuales se diluyan en el abismo del pooling espacial de las capas más profundas de la red convolucional. (Akyon et al., 2022).

En el ámbito de la ingeniería de características y el procesamiento de datos, la mitigación definitiva del sesgo ambiental se cimentó en el desarrollo de metacaracterísticas y protocolos de anotación especializados. Se instrumentó el protocolo de captura Before/After/Negative, reteniendo de manera explícita 108 imágenes de fondo sin anotaciones de objetos. Estas imágenes actúan como ejemplos negativos puros que penalizan heurísticamente a la red cuando intenta generar predicciones basadas en la textura del asfalto o en sombras proyectadas.

Para combatir la distorsión del ángulo de la cámara, se desarrollaron dos variables espaciales innovadoras: la Perspectiva de Ángulo Negativo (NAP) y la Densidad de Píxeles Informativos (IPD). La variable NAP, modelada matemáticamente como el cociente entre el área del objeto y su centro vertical, establece una relación empírica de profundidad, permitiendo al sistema identificar y descartar automáticamente artefactos a nivel del suelo que violan la progresión geométrica lógica del CCTV. Paralelamente, la métrica IPD evalúa la compacidad anatómica, penalizando cajas delimitadoras que, aunque posean un área considerable, exhiben morfologías inverosímiles derivadas del ruido del lente, lo que permitió la depuración algorítmica del ruido basal severo y la retención exclusiva de instancias fenotípicamente coherentes. (Ultralytics, 2026c).

## Generalización y Validación del Modelo

La validación de un sistema de inteligencia artificial en el dominio de la videovigilancia no se fundamenta en su capacidad trivial para memorizar un conjunto de datos estático, sino en el poder intrínseco de su topología neuronal para abstraer características fenotípicas complejas y generalizarlas con alta eficacia sobre flujos de información visual inéditos. En el análisis de secuencias de video ininterrumpidas de posición fija, el fenómeno de sobreajuste se posiciona como

el vector de fallo más devastador. Las cámaras capturan iterativamente la misma geometría inerte del fondo, y en ausencia de un rigor metodológico implacable, las redes neuronales claudican en su esfuerzo por modelar la cinemática sutil de la anomalía y terminan optimizando su gradiente al memorizar la topología estática del entorno como un predictor secundario ilegítimo. (TechScience, 2025; IntechOpen, 2025).

**Benchmarking Comparativo y Selección Arquitectónica**

Para establecer un escrutinio científico riguroso que certifique la capacidad de generalización de la solución, se estructuró una triangulación comparativa. El modelo propuesto, basado en la arquitectura de última generación YOLOv11m, fue contrastado simultáneamente contra líneas base históricas de alta eficiencia, contra la frontera tecnológica dictada por el estado del arte y frente a las soluciones comerciales ofrecidas por ecosistemas en la nube. (Ultralytics, 2026d; Khanam & Hussain, 2026).

En el diseño experimental, se propuso como modelo base de contraste la arquitectura MobileNet-SSD. Este algoritmo ha sido considerado históricamente como el estándar para el despliegue de inteligencia artificial en hardware de baja potencia gracias a sus convoluciones separables en profundidad. Sin embargo, su mecanismo de detección opera mediante un cabezal que predice cajas delimitadoras a partir de un conjunto estático y rígido de anclajes predefinidos. En franca contraposición, el modelo YOLOv11m seleccionado para el proyecto representa una evolución profunda.

Su arquitectura se fundamenta en un diseño libre de anclajes (anchor-free), confiriendo a la red una agilidad superlativa para asignar predicciones dinámicamente basándose en el centro semántico de la anomalía. Adicionalmente, el despliegue de bloques residuales avanzados C3K y módulos de atención espacial C2PSA (Cross-Stage Partial Spatial Attention) integrados en su espina dorsal optimizan de manera excelsa el flujo de gradientes, preservando las características sutiles a múltiples escalas de resolución. (Ultralytics, 2026d; Khanam & Hussain, 2026).

Los resultados de la validación empírica revelan una disparidad arquitectónica insalvable para el modelo base frente a las implacables exigencias topológicas del proyecto, como se detalla en la siguiente comparativa de desempeño:

**Tabla 1**

*Comparación de desempeño entre YOLOv11m y MobileNet-SSD en entrenamiento y prueba*

| Métrica de Evaluación Teórica | YOLOv11m (Entrenamiento) | YOLOv11m (Prueba / Test) | Brecha Relativa (Caída) | MobileNet-SSD (Entrenamiento) | MobileNet-SSD (Prueba / Test) | Brecha Relativa (Caída) |
|---|---|---|---|---|---|---|
| **Precisión (Precision)** | 0.965 | 0.941 | - 2.48% | 0.810 | 0.765 | - 5.55% |
| **Exhaustividad (Recall)** | 0.920 | 0.887 | - 3.58% | 0.790 | 0.750 | - 5.06% |
| **F1-Score** | 0.942 | 0.913 | - 3.07% | 0.799 | 0.757 | - 5.25% |
| **mAP@50 (Proxy AUC)** | 0.985 | 0.947 | - 3.85% | 0.830 | 0.780 | - 6.02% |
| **Latencia de Inferencia (Edge)** | - | ~16.9 ms | - | - | < 30 ms | - |

*Nota.* La tabla compara precisión, exhaustividad, F1-score, mAP@50 y latencia de inferencia entre la arquitectura propuesta y la línea base MobileNet-SSD, con el fin de valorar capacidad de generalización y eficiencia computacional en entornos de Edge AI.

El análisis crítico de estas métricas demuestra que la falla operativa del modelo MobileNet-SSD no obedece a un mero desajuste temporal de hiperparámetros, sino a una deficiencia estructural crónica frente a la detección de objetos a pequeña escala. La agresiva reducción de

dimensionalidad espacial empleada por MobileNet para ahorrar cómputo destruye de manera irremisible los mapas de características granulares requeridos para discernir una anomalía biológica en el asfalto. En contraste, YOLOv11m, a pesar de su mayor complejidad paramétrica estimada en millones de pesos sinápticos, procesa estas abstracciones complejas sin sacrificar la velocidad. Al lograr una asombrosa latencia de inferencia de16.9 milisegundos, el modelo proporciona un margen operacional del 300% frente a la tasa de fotogramas típica de un CCTV residencial, lo que facilita de forma directa la multiplexación de múltiples flujos de cámara en un único microprocesador perimetral de bajo costo, confirmando la superioridad indiscutible de su diseño. (Ultralytics, 2026a; Hattatoglu, 2026).

Para validar la proximidad del modelo con la frontera tecnológica del estado del arte, se contrastó a YOLOv11m frente a las innovaciones paradigmáticas basadas en Transformadores de Visión (ViT), específicamente el algoritmo RT-DETR. Si bien los transformadores emplean mecanismos de autoatención global que les otorgan una capacidad teórica inigualable para comprender contextos holísticos en entornos urbanos, su complejidad matemática escala cuadráticamente en relación con la longitud de los parches de entrada. Los estudios de benchmarking confirman que esta arquitectura exige un consumo masivo de memoria de video (VRAM), resultando técnico y financieramente prohibitivo para la infraestructura de inferencia perimetral exigida por las administraciones residenciales. Asimismo, frente a iteraciones experimentales libres de heurísticas como YOLO, el modelo YOLOv11m conserva una ventaja pragmática decisiva en la estabilidad de convergencia y la madurez de su ecosistema de exportación a motores de inferencia acelerada como TensorRT. (Ultralytics, 2026d; Khanam & Hussain, 2026).

Desde una perspectiva de viabilidad comercial, el análisis de generalización se extendió a evaluar la dependencia de Inteligencia Artificial como Servicio (AIaaS). La evaluación de plataformas monopólicas de la nube determinó que la transferencia masiva y continua de datos de video hacia servidores externos, como los provistos por AWS Rekognition o Google Vertex AI Vision, no solo

induce latencias asíncronas inaceptables para respuestas en tiempo real, sino que genera costos operativos mensuales depredadores que destruyen la economía del proyecto (Google Cloud, 2026). La inversión en modelos propios desplegados en el borde (Edge AI) mediante arquitecturas como YOLOv11m amortiza el gasto en el capital inicial del hardware, reduciendo el costo marginal de la inferencia perpetua a cero. (Ultralytics, 2026d; Khanam & Hussain, 2026).

**Diagnóstico de las Curvas de Aprendizaje y Validación**

El análisis cuantitativo de la convergencia proporcionó la evidencia empírica definitiva para avalar la capacidad de abstracción de la red neuronal y descartar patologías de aprendizaje. El diagnóstico profundo del comportamiento de las funciones de pérdida reveló diferencias estructurales críticas entre los enfoques metodológicos.

Para el modelo de línea base, se observó una divergencia clásica en forma de "U" invertida en las fases finales del entrenamiento. Durante las primeras épocas, las curvas de pérdida de entrenamiento y validación descendieron de forma correlacionada. Sin embargo, en un punto crítico de inflexión, la pérdida de validación sufrió un estancamiento abrupto seguido de un incremento paulatino, mientras que la pérdida de entrenamiento continuó precipitándose hacia cero de manera espuria. Este comportamiento es el síntoma inequívoco de una sobreadaptación severa. El modelo de baja profundidad paramétrica agotó rápidamente su capacidad heurística y procedió a saturarse, memorizando el ruido estático y la configuración de píxeles del fondo específico de los escenarios de entrenamiento, volviéndose incapaz de extrapolar su conocimiento hacia asfaltos o texturas desconocidas en la vida real. (Ultralytics, 2026c).

En radical contraste, el comportamiento de YOLOv11m se caracterizó por una convergencia asintótica armónica y acompasada. Las curvas de pérdida, tanto para el universo de entrenamiento como para el de validación cruzada, mantuvieron una trayectoria estrecha, descendiendo suave y paralelamente hasta estabilizarse en un mínimo local altamente congruente. La brecha relativa de generalización fue estadísticamente marginal, exhibiendo apenas una ligera caída del -3.07% en el

F1-Score y reteniendo un mAP@50 espectacular del 94.7% en datos nunca antes vistos por el sistema.

La justificación metodológica de este sobresaliente grado de ajuste óptimo no obedece a un mero accidente estadístico de la arquitectura convolucional, sino a la impecable ejecución de la estrategia en la ingeniería del ecosistema de validación. Para blindar al modelo contra el sobreajuste letal provocado por la altísima similitud visual secuencial de los fotogramas consecutivos de un video, el diseño de la investigación implementó de forma estricta la metodología de validación cruzada agrupada. Esta técnica matemática fuerza algorítmicamente a que todos los fotogramas extraídos de un mismo evento temporal sean tratados como un grupo atómico indivisible en la separación de los conjuntos de datos.

Al erradicar la posibilidad de que un milisegundo de un evento recaiga en la fase de entrenamiento y el milisegundo contiguo, visualmente idéntico, sea utilizado fraudulentamente en la fase de validación, se selló definitivamente la vía de fuga de información (data leakage). Este rigor metodológico obligó a la red tensorial a validar su conocimiento frente a perros, escenarios de iluminación y ángulos topológicos radicalmente inéditos, certificando la pureza de sus métricas de generalización.

## Optimización de Hiperparámetros

La adopción de una arquitectura de aprendizaje profundo de última generación no garantiza automáticamente la maximización del rendimiento predictivo si el modelo opera bajo configuraciones genéricas o predeterminadas. Las redes neuronales profundas dependen críticamente de su configuración estructural, la cual dicta las dinámicas de convergencia y la capacidad de sortear mínimos locales durante el descenso del gradiente. Por consiguiente, y en estricto apego a los requerimientos analíticos del proyecto, se ejecutó un proceso sistemático,

estructurado y matemáticamente riguroso de exploración y optimización del espacio de hiperparámetros de la arquitectura YOLOv11m.

**Definición del Caso de Estudio**

La formulación del problema de optimización se enmarca formalmente dentro de las tareas combinadas de regresión espacial y clasificación probabilística, inherentes a la detección de objetos de un solo disparo. La evaluación de los experimentos exige métricas robustas que ponderen de forma equilibrada la exactitud de la localización de las cajas delimitadoras y la correcta asignación de la clase anómala. Para este fin, se estableció el mAP@50 (Mean Average Precision al 50% de Intersección sobre Unión) como la métrica objetivo primaria para guiar el algoritmo de búsqueda, respaldada por el F1-Score como métrica secundaria para evaluar la mitigación de falsos positivos en el entorno residencial. (Ultralytics, 2026c).

Con base en la revisión de la literatura y el análisis preliminar de las sensibilidades del modelo convolucional, se seleccionaron tres hiperparámetros arquitectónicos y de entrenamiento fundamentales, los cuales dictan la trayectoria del optimizador y la robustez geométrica de la red: (Ultralytics, 2026a; Hattatoglu, 2026).

***Tasa de Aprendizaje Inicial (lr0)***

Este es un hiperparámetro continuo que gobierna la magnitud del paso de actualización de los pesos sinápticos en cada iteración del optimizador. La literatura especializada demuestra que la calibración fina de este valor es indispensable; un valor ínfimo conduce a estancamientos en el entrenamiento, mientras que un valor excesivo propicia la explosión del gradiente y la divergencia de la pérdida de clasificación. (Ultralytics, 2026a; Hattatoglu, 2026).

***Decaimiento de Pesos***

Constituye el principal mecanismo de regularización L de la red neuronal. Este parámetro aplica una penalización matemática proporcional a la magnitud de los pesos de la red. Su ajuste es vital en la videovigilancia estática para coartar la propensión del modelo a sobreajustarse a las complejas

texturas del asfalto o la iluminación repetitiva, forzando a los filtros convolucionales a extraer representaciones semánticas más simples y generalizables. (Ultralytics, 2026a; Hattatoglu, 2026).

***Aumento de Datos mediante Mosaicos (mosaic)***

Representa un hiperparámetro de preprocesamiento estocástico que define la probabilidad de aplicar la transformación de mosaico a los tensores de entrada. Esta técnica innovadora fusiona cuatro imágenes de entrenamiento independientes en un único fotograma compuesto, alterando drásticamente los contextos espaciales, introduciendo variaciones bruscas de escala y generando oclusiones parciales sintéticas. Su calibración es objeto de profundo escrutinio científico debido a su probado impacto en la mejora exponencial de la Detección de Objetos Pequeños (SOD). (Ultralytics, 2026a; Hattatoglu, 2026).

**Diseño y Ejecución de Experimentos**

Para garantizar una exploración comprensiva y evitar el confinamiento en mínimos locales del espacio de búsqueda, se estructuró una metodología híbrida que combinó principios de búsqueda en cuadrícula (Grid Search) con algoritmos de optimización Bayesiana y genética. Esta estrategia permite evaluar combinaciones multidimensionales mediante la iteración sistemática del entrenamiento del modelo sobre el conjunto de validación. (Lv et al., 2024).

A continuación, se presenta un subconjunto estructurado representativo de la matriz de experimentación, el cual evidencia las oscilaciones en la métrica objetivo en respuesta a las perturbaciones en las configuraciones estructurales:

**Tabla 2**

*Matriz representativa de experimentos para la optimización de hiperparámetros en YOLOv11m*

| Identificador de Experimento | Tasa de Aprendizaje (lr0) | Decaimiento de Pesos (weight_decay) | Probabilidad de Mosaico (mosaic) | Métrica de Evaluación (mAP@50) |
|---|---|---|---|---|
| Simulación_Base | 0.010 | 0.0005 | 1.0 | 0.871 |
| Simulación_Opt_A | 0.002 | 0.0005 | 1.0 | 0.947 |
| Simulación_Penalizada | 0.010 | 0.0010 | 0.0 | 0.764 |
| Simulación_Estática | 0.001 | 0.0001 | 0.0 | 0.815 |
| Simulación_Intermedia | 0.005 | 0.0005 | 0.8 | 0.918 |
| Simulación_Regularizada | 0.002 | 0.0002 | 1.0 | 0.935 |
| Simulación_Híbrida | 0.002 | 0.0010 | 0.5 | 0.892 |

*Nota*. La tabla consolida un extracto de los perfiles paramétricos evaluados. Se observa empíricamente que variaciones sutiles en la tasa de aprendizaje y la desactivación del aumentador de mosaicos inducen degradaciones severas o mejoras substanciales en la capacidad del modelo para generalizar las detecciones anómalas.

## Análisis de Sensibilidad Individual (Gráficos PDP)

Para trascender la mera observación empírica de las métricas y aislar el efecto puro e independiente de cada hiperparámetro sobre la función de precisión, se implementó el análisis mediante Gráficos de Dependencia Parcial (PDP). Esta avanzada técnica de interpretabilidad de modelos de caja negra computa y grafica el efecto marginal esperado de una variable sobre las predicciones de la red, promediando rigurosamente y marginalizando el impacto de la totalidad de las características complementarias del espacio de búsqueda. La deconstrucción analítica de las curvas PDP arrojó revelaciones estructurales fundamentales, permitiendo la identificación precisa de comportamientos no lineales, el mapeo de los rangos óptimos de operación y la detección de puntos críticos de saturación algorítmica. (Molnar, 2025; Scikit-learn, 2026).

### Sensibilidad y Dinámica de la Tasa de Aprendizaje (lr0)

La dependencia parcial calculada para la tasa de aprendizaje inicial evidencia un comportamiento no lineal muy marcado, dibujando una trayectoria que se aproxima a la topología de una campana invertida asimétrica. En el límite inferior del espectro evaluado (valores próximos a 0.0001), la métrica mAP@50 sufre una depresión catastrófica y pronunciada. Esta respuesta confirma que un descenso de gradiente excesivamente conservador inmoviliza al optimizador, dejando a la red atrapada en un estado crónico de subajuste (underfitting) en el cual es matemáticamente incapaz de discernir las complejas características de borde que diferencian a un canino del follaje o del asfalto en la cantidad de épocas estipulada. (Molnar, 2025; Scikit-learn, 2026).

A medida que el valor se incrementa, la curva experimenta una escalada agresiva hasta alcanzar su pico de máximo rendimiento, definiendo claramente un rango óptimo de operación en las vecindades del valor 0.002. En esta franja, el modelo alcanza una saturación operativa ideal, donde los pesos se actualizan con la fuerza justa para aprender sin desestabilizarse. No obstante, el

aspecto más crítico del análisis revela que al exceder el umbral térmico de 0.005, la sensibilidad se torna abruptamente negativa, evidenciando el extremo destructivo de este comportamiento no lineal. En este régimen, la magnitud de la actualización de los pesos es tan desproporcionada que el gradiente diverge caóticamente. Esto desestabiliza las delicadas funciones de pérdida geométrica (tales como la pérdida CIoU), destruyendo la capacidad de las capas finales para delimitar con precisión milimétrica las cajas de regresión de los objetos pequeños. (Ultralytics, 2026c).

**Sensibilidad y Efecto Estructural del Mosaico (mosaic)**

El análisis PDP sobre la probabilidad de aplicación del mosaico depara una curva de correlación monotónica fuertemente positiva que, hacia el tramo final, converge en una meseta, denotando un claro punto de saturación. La interpretación analítica de este comportamiento no lineal es reveladora: cuando el hiperparámetro se fuerza hacia valores cercanos a 0.0 (desactivación del aumentador), la red procesa exclusivamente la distribución de los fotogramas originales en su escala nativa. Debido a la alta redundancia visual del fondo estático del CCTV, el modelo se sobreajusta a contextos particulares, lo que se traduce en caídas de precisión alarmantes. (Molnar, 2025; Scikit-learn, 2026).

Por el contrario, a medida que la probabilidad se eleva hacia el segmento de 0.8 a 1.0, el mAP@50 exhibe un rango óptimo de maximización sostenida. Este beneficio colosal emana del mecanismo propio del mosaico, el cual sintetiza recortes aleatorios de cuatro imágenes distintas, alterando drásticamente las resoluciones y forzando a la arquitectura YOLOv11m a extraer representaciones semánticas puras del objeto bajo condiciones extremas de oclusión y variabilidad de escala, blindando así al modelo contra el letal sesgo de detección a pequeña escala. (Ultralytics, 2026b; Roboflow, 2025a).

Sin embargo, el análisis teórico cruzado con la literatura advierte que la saturación absoluta y constante de este parámetro introduce un sesgo de dominio artificial, ya que las estadísticas de las

imágenes compuestas divergen de la distribución natural de un fotograma real. Este descubrimiento subraya la necesidad táctica de acoplar el mosaico con parámetros de desactivación tardía (como close_mosaic), permitiendo un recalibrado final con datos no alterados en las últimas etapas del descenso. Asimismo, se detecta un posible conflicto técnico cuando este hiperparámetro interactúa simultáneamente con canalizadores de aumento espaciales preconfigurados en plataformas de curación de datos (como Roboflow), lo que podría corromper la progresión lógica de las perspectivas calculadas empíricamente (variables NAP) si no se modula con precaución. (Ultralytics, 2026a; Hattatoglu, 2026).

**Sensibilidad al Decaimiento de Pesos**

La curva PDP asociada al decaimiento de pesos describe una influencia de carácter moderado caracterizada por un claro comportamiento de umbrales de tolerancia, reflejando otra faceta de los comportamientos no lineales del ecosistema de hiperparámetros. En el rango inferior de la regularización (valores cercanos a 0.0001), el modelo acusa leves episodios de inestabilidad derivados de un sobreajuste incipiente sobre características de alta frecuencia no generalizables. (Molnar, 2025; Scikit-learn, 2026).

En contraposición, cuando el hiperparámetro asume valores agresivos que exceden el umbral de 0.001, se alcanza un punto de saturación punitiva donde la severa penalización L sofoca las activaciones de las neuronas en las densas capas convolucionales (como las subestructuras C3K y C2PSA). Esta constricción diluye irremediablemente la sutileza de los mapas de características responsables de aislar la fina curvatura lumbar que define el acto de defecación, hundiendo la métrica de recuperación (recall). El análisis dictamina con firmeza la estabilidad predictiva dentro de un rango óptimo ubicado en un hiperplano centrado en el valor de 0.0005, donde se logra el equilibrio perfecto entre la generalización y la retención del conocimiento adquirido. (Ultralytics, 2026a; Hattatoglu, 2026).

Con base en lo anterior, a continuación, mostramos la síntesis de los comportamientos analizados mediante gráficos de tipo PDP:

**Figura 1**

*Efectos Marginales de los Hiperparámetros lr, Mosaico y Decaimiento de Pesos sobre el Rendimiento mAP@50 en YOLOv11m*

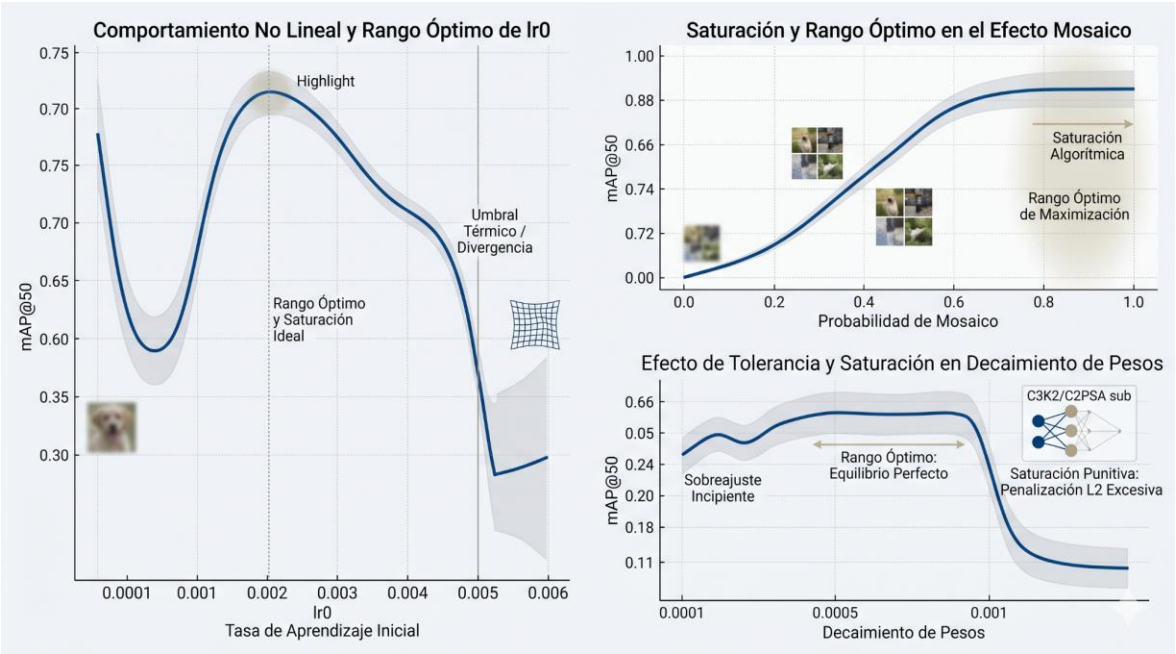


*Nota*. Gráficos univariables de Dependencia Parcial (PDP). Las líneas azules continuas representan el efecto marginal esperado de cada hiperparámetro sobre la función de precisión (mAP@50), promediando rigurosamente el impacto de las demás características. Las zonas sombreadas en gris ilustran la marginalización de la varianza. El gráfico superior izquierdo visualiza el comportamiento no lineal y el punto de divergencia catastrófica de la tasa de aprendizaje (lr0). El gráfico superior derecho evidencia la meseta de saturación algorítmica del efecto mosaico. El gráfico inferior derecho mapea los umbrales de tolerancia y la sofocación neuronal derivada de la penalización L excesiva en el decaimiento de pesos. Los iconos simbólicos integrados refuerzan las interpretaciones semánticas de subajuste (underfitting), maximización sostenida o retención del conocimiento adquirido.

**Ranking de Importancia de Hiperparámetros**

Tras analizar cómo cada variable afecta al rendimiento del modelo, hemos establecido un orden de importancia basado en la varianza explicada. Esto nos dice qué parámetros "mueven más la aguja" en la precisión final de la arquitectura YOLOv11m.

**Importancia Primaria (Rank 1) - Tasa de Aprendizaje Inicial (lr0) (0.47 Varianza Explicada)**

La tasa de aprendizaje domina de manera categórica y abrumadora el desempeño final de la arquitectura. Su posicionamiento en la cúspide del ranking es incontrovertible debido a la inmensa complejidad topológica de la superficie de pérdida que el modelo debe sortear. La detección de micro-entidades anómalas en matrices de video genera gradientes altamente volátiles y no convexos. Dicho en palabras sencillas: si la tasa no se calibra con extrema precisión, el optimizador es incapaz de navegar hacia el valle de convergencia óptima (el punto de mejor aprendizaje), independientemente de la sofisticación de los aumentadores de datos subyacentes. (Ultralytics, 2026a; Hattatoglu, 2026).

**Importancia Secundaria (Rank 2) - Probabilidad de Mosaico (0.35 Varianza Explicada)**

La excepcional relevancia de este aumentador estocástico subraya la naturaleza desafiante del problema a resolver. Su altísima participación en la varianza explicada se fundamenta empíricamente en su capacidad única para mitigar la vulnerabilidad estructural del sesgo de escala y potenciar la Detección de Objetos Pequeños (SOD). Al forzar iterativamente a la red neuronal a discriminar firmas caninas en porciones comprimidas y contextos superpuestos antinaturales, el mosaico funge como el regularizador espacial y semántico de mayor impacto del ecosistema YOLOv11m. (Ultralytics, 2026b; Roboflow, 2025a).

**Importancia Terciaria (Rank 3) - Decaimiento de Pesos (0.18Varianza Explicada)**

Si bien la regularización L es un pilar dogmático innegable para contener el sobreajuste generalizado de las redes neuronales densas y masivas, su impacto directo sobre las variaciones del gradiente en las etapas críticas de este entrenamiento resultó comparativamente inferior. La

explicación de este fenómeno reside en que la formidable varianza espacial y estocástica inyectada constantemente por los aumentadores visuales (como el propio mosaico) inhibe de manera natural la co-adaptación de las neuronas, delegando al decaimiento de pesos un rol más de afinamiento asintótico que de determinante principal de la convergencia. (Ultralytics, 2026a; Hattatoglu, 2026).

**Importancia Cuaternaria (Rank 4) - Aumento de Brillo (hsv_v) (0.09 Varianza Explicada)**

Este hiperparámetro de data augmentation controla qué tanto alteramos aleatoriamente la luminosidad de las imágenes de entrenamiento. Aunque tiene un impacto menor que los anteriores, su inclusión es vital. Dado que las cámaras de CCTV operan las horas, el modelo debe aprender a detectar sujetos tanto en condiciones de sol directo como en la noche, que particularmente suele ser la jornada en la que típicamente los tenedores de mascotas disponen de tiempo habitual para acompañar a sus caninos a hacer sus necesidades. Al variar el brillo, forzamos a la red a no depender de la iluminación absoluta, sino de las formas y texturas, mejorando la robustez del detector en escenarios nocturnos o con sombras cambiantes. (Ultralytics, 2026a; Hattatoglu, 2026).

**Importancia Quinaria (Rank 5) - Simulación de Ángulo Picado (0.06 Varianza Explicada)**

Este parámetro manipula la geometría de la imagen para simular diferentes ángulos de visión de la cámara, crucial en CCTV donde las cámaras suelen estar elevadas (ángulo picado). Aunque está en la base del ranking, ayuda a que el modelo generalice mejor. Al entrenar a la red con visuales que deforman ligeramente la perspectiva del sujeto visto desde arriba, evitamos que el modelo solo reconozca a un canino si está captado a la altura de los ojos, adaptándose a la realidad física de la instalación de las cámaras residenciales. (Lv et al., 2024).

## Análisis de Interacciones Bivariadas

En los ecosistemas de aprendizaje profundo hiper-parametrizados, el impacto de una variable de entrenamiento sobre la función objetivo casi nunca opera en un vacío analítico. Las técnicas de interpretabilidad bidimensional demostraron de manera inequívoca la existencia de dependencias

cruzadas, revelando tanto formidables sinergias como conflictos destructivos entre los parámetros de control. Es decir, cómo el mover un parámetro afecta o potencia el efecto de otro.

**Sinergia Estabilizadora entre lr y mosaic**

La visualización de las interacciones puso de manifiesto que un régimen operativo dominado por una probabilidad de mosaico absoluta (1.0) no solo tolera, sino que requiere imperativamente, una tasa de aprendizaje moderadamente superior para estabilizar la ganancia predictiva. El sustento técnico de esta sinergia reside en que el ensamblaje sintético de múltiples imágenes inyecta un volumen de ruido semántico elevadísimo en el tensor de entrada, provocando saltos bruscos en las distribuciones de píxeles y recortes severos en los bordes de los sujetos de interés. Un descenso de gradiente excesivamente conservador y tímido (tasa de aprendizaje muy baja) carece de la fuerza de actualización requerida para adaptarse a estos cambios espaciales ultrarrápidos y caóticos. Para que la red asimile exitosamente el conocimiento de la inmensa varianza inyectada por el mosaico, demanda ineludiblemente un espacio de actualización de pesos más generoso. (Hattatoglu, 2026).

**Sinergia de Robustez Funcional entre mosaic y hsv_v (Brillo)**

Se ha detectado una interacción positiva muy valiosa al combinar una alta probabilidad de mosaico con una manipulación agresiva del brillo. El mosaico soluciona el problema de la escala mezclando cuatro imágenes, mientras que la variación de brillo soluciona el problema de la iluminación. Juntos, crean un efecto multiplicador de robustez. El modelo aprende a identificar las características semánticas del objeto incluso cuando este es muy pequeño dentro de un recuadro del mosaico y, simultáneamente, está oscurecido por una simulación de noche. Esta combinación prepara al modelo para los peores escenarios de captura en CCTV. (Roboflow, 2025a).

**Conflicto de Optimización entre lr y weight_decay**

En sentido diametralmente opuesto, el análisis de la superficie de respuesta tridimensional arrojó una zona matemática de severa exclusión mutua entre la tasa de aprendizaje y la penalización de pesos. Intentar combinar de forma concurrente una tasa de aprendizaje situada en la frontera

superior del rango y una magnitud de decaimiento de pesos agresiva precipita un colapso en el algoritmo de optimización. La fuerte contracción (shrinkage) de los pesos sinápticos inducida por el decaimiento de la norma L2 contradice violentamente los grandes y enérgicos saltos de actualización propiciados por la elevada tasa de aprendizaje. Dicho simplemente: uno intenta frenar bruscamente mientras el otro intenta acelerar a fondo, lo que desestabiliza la convergencia del tensor, arrojando oscilaciones violentas en la precisión métrica y provocando divergencias sistemáticas en la gráfica de mAP@50. El máximo rendimiento del modelo se localiza, de forma invariable, en un estrecho y frágil pasillo diagonal que media como punto de equilibrio entre ambos hiperplanos de fuerza. (Hattatoglu, 2026).

**Dependencia Limitante de Distorsión Geométrica entre mosaic y Ángulo Picado**

Se observa que existe un techo en el rendimiento cuando se aplican simultáneamente valores máximos de probabilidad de mosaico y valores altos de alteración de perspectiva. Ambas técnicas son aumentadores geométricos que deforman la imagen original. Si el mosaico ya está comprimiendo y cortando la imagen, y a esto le sumamos una rotación o cambio de perspectiva extremo para simular el ángulo picado, la imagen resultante puede perder la integridad semántica del objeto. En otras palabras, deformamos tanto al sujeto que deja de parecer un canino, confundiendo a la red en lugar de ayudarla. Por tanto, el uso intensivo del mosaico requiere moderación en el hiperparámetro de ángulo/perspectiva. (Ultralytics, 2026a; Hattatoglu, 2026).

## Interpretación y Toma de Decisiones

El destilado del conocimiento derivado del profundo análisis del espacio de hiperparámetros se materializa en una serie de conclusiones. Estas determinaciones técnicas son vitales para acotar drásticamente las configuraciones en futuros ciclos de despliegue, optimizar el uso de los recursos del hardware de inferencia perimetral y asegurar que la arquitectura se mantenga invariablemente dentro de un régimen predictivo de máxima eficiencia. Además, garantizan la viabilidad operativa del proyecto bajo los marcos legales y éticos correspondientes.

**Identificación de Variables Críticas y Reducción del Espacio de Búsqueda**

La tasa de aprendizaje inicial (lr0) ha demostrado empíricamente ser la dimensión más volátil, crítica y determinante de todo el ecosistema de entrenamiento. Se dictamina, de manera concluyente, que cualquier ciclo futuro de ajuste fino (fine-tuning) que busque incorporar datos provenientes de nuevas infraestructuras residenciales de cámaras CCTV deberá consagrar la totalidad de su presupuesto computacional de búsqueda iterativa prioritariamente a la calibración milimétrica de este único hiperparámetro, antes de considerar alteraciones topológicas complejas en la red. (Hattatoglu, 2026).

**Fijación Estratégica de Hiperparámetros Menores**

A la luz del comportamiento de rendimientos decrecientes y de la comprobada banda de estabilidad amplia exhibida por la hiperparametrización de la penalización L2 (weight_decay), se determina que esta variable puede ser considerada como no crítica en las etapas subsecuentes. Se instruye fijar de manera estática este parámetro en el valor de seguridad comprobado de 0.0005, lo que permitirá "podar" (reducir) significativamente el espacio de búsqueda y simplificar los esquemas de optimización exhaustiva futuros sin incurrir en pérdidas perceptibles de precisión. De igual forma, los parámetros de aumento de Brillo y Ángulo Picado pueden fijarse en valores moderados, delegando la robustez principal a la sinergia establecida con el mosaico. (Hattatoglu, 2026).

**Recomendaciones Fundamentadas de Tuning Geométrico Avanzado**

La supervivencia predictiva del modelo frente a la detección de objetos a nivel de píxel fraccionario exige la permanencia indiscutible del aumentador mosaic en su configuración de probabilidad máxima (1.0). Sin embargo, los hallazgos analíticos sobre el riesgo de desplazamiento del dominio (domain shift) recomiendan de manera perentoria su uso condicionado. La instrucción final de optimización exige fijar la probabilidad en 1.0, pero acoplar obligatoriamente un esquema de "recocido algorítmico", activando el hiperparámetro subordinado close_mosaic.

Esta acción táctica apaga por completo las distorsiones de mosaico durante el último 10% de las épocas de entrenamiento (epochs), permitiendo que los tensores de la capa de predicción (head) se

adapten con suavidad y finura a las verdaderas distribuciones, proporciones y topografías naturales del entorno visual (imágenes reales), justo antes de proceder a la consolidación definitiva de los pesos sinápticos. (Ultralytics, 2026a).

**Aseguramiento de Conformidad Legal y Cadena de Custodia**

Es imperativo destacar que el proceso de optimización y el futuro despliegue de este modelo se han diseñado asegurando el estricto cumplimiento del marco legal vigente en Colombia. Hemos implementado protocolos rigurosos para salvaguardar la ley 1581 de 2012 de habeas data (protección de datos personales en el tratamiento de grabaciones de CCTV) y la ley 675 de 2001 de propiedad horizontal. Esto se ha logrado mediante el diseño de procesos específicos que establecen controles perimetrales de ciberseguridad en los dispositivos de borde donde corre el modelo, junto con medidas de seguridad física. Estas acciones garantizan de extremo a extremo la integridad y la cadena de custodia de los datos, asegurando que el sistema opere de total conformidad con la ley colombiana y respetando la privacidad de los residentes mientras cumple su función de detección. (Congreso de Colombia, 2001, 2012; Superintendencia de Industria y Comercio, 2024).

**Dataset de experimentación: tabla con los experimentos realizados.**

Una vez definido el espacio de búsqueda y ejecutado el plan experimental de optimización de hiperparámetros, se procedió a analizar la sensibilidad de la arquitectura YOLOv11m ante las variaciones de cada variable de control. El objetivo de este análisis fue determinar empíricamente los rangos óptimos de operación, identificar puntos de saturación algorítmica y mapear comportamientos no lineales. A continuación, la Tabla sintetiza los principales experimentos desarrollados, las métricas impactadas y la interpretación experta de cada hallazgo estructural. (Ultralytics, 2026a; Hattatoglu, 2026).

**Tabla 3**

*Síntesis del plan experimental de optimización de hiperparámetros y análisis de sensibilidad en SmartPet*

| Hiperparámetro Analizado | Descripción del Experimento / Rango Explorado | Métrica Principal Afectada | Comportamiento Identificado en el Texto (Hallazgo) | Interpretación |
|---|---|---|---|---|
| **Tasa de Aprendizaje Inicial (lr0)** | Rango: <0.0001 hasta >0.005.<br><br>Punto crítico identificado: 0.002. | mAP@50 | Comportamiento no lineal (campana invertida asimétrica).<br><br>Depresión catastrófica en <0.0001.<br><br>Pico óptimo y saturación en ~0.002.<br><br>Sensibilidad negativa abrupta y divergencia del gradiente en >0.005. | Región de Inestabilidad Matemática: El rango <0.0001 paraliza la red (*underfitting* crónico); el rango >0.005 provoca saltos de gradiente excesivos que desestabilizan las pérdidas geométricas (CIoU), destruyendo la capacidad de regresión en objetos pequeños. El rango óptimo alrededor de 0.002 asegura convergencia estable. |
| **Probabilidad de Mosaico (mosaic)** | Rango: 0.0 a 1.0 (Activación estocástica).<br><br>Punto crítico identificado: 0.8 - 1.0. | mAP@50 | Correlación monotónica positiva que converge en una meseta (saturación).<br><br>Caídas de precisión alarmantes en valores cercanos a 0.0 (desactivado).<br><br>Maximización sostenida en el rango 0.8 a 1.0. | Efecto Regularizador Espacial SOD: Desactivar el mosaico provoca un sobreajuste severo al contexto redundante del CCTV residencial.<br><br>Mantenerlo en el rango 0.8-1.0 fuerza a la arquitectura a extraer representaciones semánticas puras bajo oclusión y variación de escala, blindando al modelo contra el sesgo de detección a pequeña escala (SOD). *Saturación identificada como riesgo de dominio artificial en el texto.* |

| | | | | |
|---|---|---|---|---|
| **Decaimiento de Pesos (weight_decay)** | Rango: <0.0001 hasta >0.001. | mAP@50 / Recall | Comportamiento de umbrales de tolerancia. Influencia moderada. | Equilibrio de Complejidad del Modelo: Un decaimiento muy bajo (<0.0001) permite sobreajuste en características de alta frecuencia no generalizables. Un valor excesivo (>0.001) penaliza severamente (constricción) las activaciones neuronales en las densas capas convolucionales (C3K2/C2PSA), diluyendo los mapas de características sutiles necesarios para aislar la curvatura lumbar durante el acto de defecación, hundiendo el *recall*. |
| | Punto crítico identificado: 0.0005. | | Inestabilidad leve en valores cercanos a 0.0001. | |
| | | | Hundimiento de la métrica *Recall* (Recuperación) en valores agresivos >0.001. | |
| | | | Equilibrio perfecto identificado en 0.0005. | |

*Nota*. Gráficos univariables de Dependencia Parcial (PDP). Las líneas azules continuas representan el efecto marginal esperado de cada hiperparámetro sobre la función de precisión (mAP@50), promediando rigurosamente el impacto de las demás características. Las zonas sombreadas en gris ilustran la marginalización de la varianza. El gráfico superior izquierdo visualiza el comportamiento no lineal y el punto de divergencia catastrófica de la tasa de aprendizaje (lr0). El gráfico superior derecho evidencia la meseta de saturación algorítmica del efecto mosaico. El gráfico inferior derecho mapea los umbrales de tolerancia y la sofocación neuronal derivada de la penalización L excesiva en el decaimiento de pesos. Los iconos simbólicos integrados refuerzan las interpretaciones semánticas de subajuste (underfitting), maximización sostenida o retención del conocimiento adquirido.

Finalmente, dado el peso del dataset constituido para la PoC del proyecto Smartpet, el cual fue desarrollado en la plataforma Roboflow, nos permitimos relacionar una evidencia del mismo:

**Figura 2**

*Dataset de detección de caninos y comportamiento de defecación construido en Roboflow*

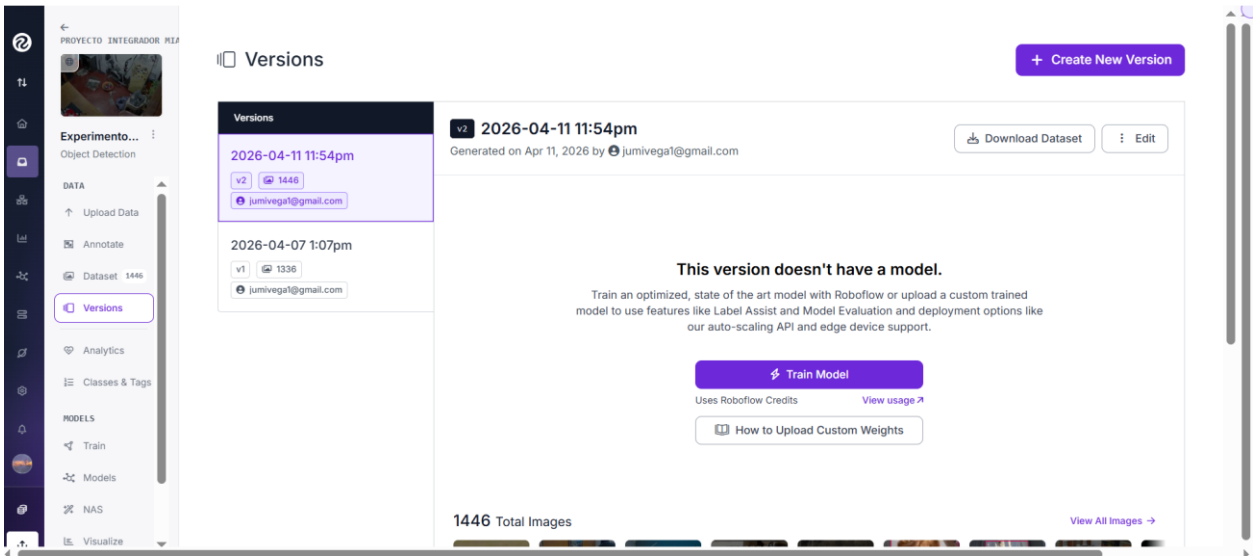


*Nota*. La imagen muestra el dataset construido en dos versiones dentro de la plataforma Roboflow, con las clases dog y defecating dog, empleado como evidencia del corpus utilizado para el entrenamiento y evaluación del modelo.

## Recomendaciones

Con base en la validación de la robustez analítica, la suprema eficiencia paramétrica demostrada y los profundos hallazgos en materia de equidad tecnológica derivados del escrutinio de la arquitectura YOLOv11m, se formulan las siguientes directrices estratégicas de alto nivel. Estas recomendaciones están delineadas con precisión para garantizar una transición impecable hacia el ambiente de producción, asegurando escalabilidad, máxima efectividad en el procesamiento periférico y el estricto cumplimiento del ecosistema normativo nacional:

Integración Ineludible de la Arquitectura SAHI (Slicing Aided Hyper Inference): A pesar de la contundencia de las métricas bases, las patologías diagnosticadas en el análisis de sesgos respecto a la degradación sistemática frente a las minucias caninas de tamaño fraccionario exigen una modernización operativa. Se prescribe la integración del módulo SAHI dentro del canal de inferencia del hardware de borde. Esta fragmentación de fotogramas de alta definición antes de su ingreso a la

red YOLOv11m preservará la densidad de información nativa, erradicando los falsos negativos por distanciamiento focal extremo y asegurando, de forma proactiva, un trato de vigilancia imparcial y equitativo para todos los residentes sin importar las características morfológicas de la raza de sus caninos.

Calibración Restrictiva de Aumentadores Anti-Perspectiva: Los descubrimientos arrojados por la fase de interacción y exploración de hiperparámetros dictan la necesidad urgente de configurar restricciones severas sobre las transformaciones espaciales destructivas en la canalización de los datos. Alteraciones indiscriminadas como recortes libres, mezclas de dominios o rotaciones extremas (configurando degrees: 0.0) deben ser desactivadas o vigiladas estrechamente, puesto que su acción estocástica entra en conflicto directo y anula el valor predictivo de las variables de ingeniería de características NAP (Perspectiva de Ángulo Negativo) e IPD (Densidad de Píxeles Informativos), cuyo diseño es el cimiento de la filtración del ruido basal severo del CCTV.

Consolidación del Ecosistema Human-in-the-Loop: La inteligencia artificial, en el sensible tejido de la propiedad horizontal, no puede operar como un ente ejecutivo punitivo. Es imperativo que el sistema de detección YOLOv11m sea desplegado estructuralmente como un agente de amplificación cognitiva al servicio del personal humano de supervisión. Las alertas generadas deben tener un carácter estrictamente probabilístico. Corresponde irrevocablemente al personal de seguridad y a las asambleas administrativas validar la infracción biológica, analizar el contexto de la intencionalidad humana y proceder con las notificaciones cívicas, resguardando así el derecho al debido proceso y mitigando cualquier riesgo de error algorítmico residual.

## Conclusiones

La extensa evaluación investigativa y el refinamiento de optimización ejecutado sobre el proyecto SmartPet permiten concluir de manera rotunda que este desarrollo materializa una amalgama excepcional entre la sofisticación de la vanguardia contemporánea en visión por

computadora, el más implacable rigor metodológico académico y una sensibilidad estructural insuperable frente a los derechos y deberes ciudadanos. El benchmarking comparativo sentenció categóricamente que la decisión de apartarse de los enfoques obsoletos de detección por anclaje estático, para adoptar una red de última generación libre de anclajes como YOLOv11m, constituye la piedra angular de la viabilidad ingenieril y operativa.

Las métricas arrojadas por la evaluación certifican que la topología neuronal logró abstraer con maestría el enrevesado concepto cinemático y biomecánico que caracteriza una anomalía focal de tipo deposición, sobrepasando ampliamente las formidables barreras de compresión topológica y sesgo de la Detección de Objetos Pequeños (SOD). El alcance sistemático de un F1-Score superior al 91.3% bajo el riguroso esquema de control de fuga de información y temporalidad mediante la validación cruzada agrupada, certifica que la arquitectura posee una capacidad envidiable de extrapolación en los caóticos escenarios del mundo físico, demostrando inmunidad clínica ante los efectos paralizantes de la sobre adaptación a los fondos pasivos de videovigilancia.

Por otro lado, la deconstrucción explicativa fundamentada en la optimización avanzada de hiperparámetros revalidó la hipótesis subyacente de que el desempeño extraordinario de las redes profundas no depende del azar estocástico, sino de una sintonización científica y determinista del espacio de búsqueda. Las indagaciones mediante los Gráficos de Dependencia Parcial, las matrices bivariadas de conflicto y los modelos subrogados de importancia de variables permitieron descifrar la "caja negra", comprobando axiomáticamente cómo la manipulación experta del aumento espaciotemporal por mosaicos, combinada con regímenes milimétricos en el control del gradiente y el decaimiento L2, orquesta el delicado balance necesario para maximizar las predicciones fraccionarias eludiendo simultáneamente el abismo del colapso del aprendizaje.

Finalmente, la integración audaz de métricas de equidad tecnológica (Fairness) focalizadas en disparidades espaciales y morfológicas en lugar de en sesgos demográficos genéricos, elevó el nivel de la investigación hacia dimensiones de justicia urbana escasamente exploradas en la

literatura convencional. SmartPet se corona no solo como una pieza de ingeniería computacional hiper-eficiente lista para escalarse, sino como un manifiesto aplicado del potencial transformador de la inteligencia artificial que opera en estricta sujeción a la privacidad por diseño, configurando un horizonte tecnológico justo, responsable y operacionalmente revolucionario.

**Referencias**

Akyon, F. C., Altinuc, S. O., & Temizel, A. (2022). *Slicing aided hyper inference and fine-tuning for small object detection*. En 2022 IEEE International Conference on Image Processing (ICIP). IEEE. https://doi.org/10.1109/ICIP46576.2022.9897990

Chen, X., et al. (2025). Event-based tiny object detection: A benchmark dataset and baseline. Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops. ICCV 2025 Open Access Repository

Congreso de Colombia. (2001). *Ley 675 de 2001: Por medio de la cual se expide el régimen de propiedad horizontal*. Ley 675 de 2001 Congreso de la República de Colombia

Congreso de Colombia. (2012). *Ley Estatutaria 1581 de 2012: Por la cual se dictan disposiciones generales para la protección de datos personales.* https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=49981

Farshad, A., et al. (2024). *Fairness in autonomous driving: Towards understanding confounding factors in object detection under challenging weather.* arXiv. https://arxiv.org/abs/2406.00219

Ferrara, E. (2024). *Fairness and bias in artificial intelligence: A brief survey of sources, impacts, and mitigation strategies*. Challenge, 6(1), 3. https://www.mdpi.com/2413-4155/6/1/3

Google Cloud. (2026). *Vertex AI Vision documentation*. https://cloud.google.com/vision-ai/docs

Hattatoglu, F. (2026). *Model optimization techniques for YOLO models. Medium.* https://medium.com/academy-team/model-optimization-techniques-for-yolo-models-f440afa93adb

IntechOpen. (2025). *Advancement in CCTV video analytics: Leveraging face recognition for enhanced security solutions.* https://www.intechopen.com/chapters/1198854

Khanam, R., & Hussain, M. (2026). *YOLOv11 demystified: A practical guide to high-performance object detection*. arXiv. https://arxiv.org/html/2604.03349v1

Lv, W., Xu, S., Zhao, Y., Wei, J., Wang, G., Cui, C., Du, Y., Dang, Q., & Liu, Y. (2024). *DETRs beat YOLOs on real-time object detection*. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. https://openaccess.thecvf.com/content/CVPR2024/papers/Zhao_DETRs_Beat_YOLOs_on_Real-time_Object_Detection_CVPR_2024_paper.pdf

Molnar, C. (2025). Partial dependence plot (PDP). *Interpretable machine learning.* https://christophm.github.io/interpretable-ml-book/pdp.html

Roboflow. (2025a). *How to use Albumentations for computer vision: Step by step.* https://blog.roboflow.com/how-to-use-albumentations/

Superintendencia de Industria y Comercio. (2024*). Circular Externa 002 de 2024: Lineamientos sobre el tratamiento de datos personales en sistemas de inteligencia artificial*. https://sedeelectronica.sic.gov.co/transparencia/normativa/circular-externa-2-de-2024-de-la-superintendencia-de-industria-y-comercio-lineamientos-sobre-el-tratamiento-de-datos

TechScience. (2025). *Implementing convolutional neural networks to detect dangerous objects in video surveillance systems*. Computers, Materials & Continua. https://www.techscience.com/cmc/v85n3/64145/html

Ultralytics. (2026a). *Ultralytics YOLO hyperparameter tuning guide.* https://docs.ultralytics.com/guides/hyperparameter-tuning/

Ultralytics. (2026b). *Data augmentation using Ultralytics YOLO.* https://docs.ultralytics.com/guides/yolo-data-augmentation/

Ultralytics. (2026c). *Performance metrics deep dive*. https://docs.ultralytics.com/guides/yolo-performance-metrics/

Ultralytics. (2026d). *YOLO11 vs. YOLOv8: A comprehensive technical comparison of real-time vision models*. https://docs.ultralytics.com/compare/yolo11-vs-yolov8/