Workshop Simulación de Escenarios Críticos del Proyecto SmartPet

Juan Miguel Velandia García

Oscar Mauricio Parra Folleco

Maestría en Inteligencia Artificial, Universidad de Especialidades Espíritu Santo

Proyecto Integrador en Inteligencia Artificial

Dra. Alexandra Jacqueline Arciniegas Coral

24 de abril de 2026

Resumen

Este documento desarrolla el Workshop Simulación de Escenarios Críticos para SmartPet a partir de una línea base ya consolidada en tres entregables previos: formulación SMART del problema, preparación y curación del dataset, y evaluación del modelo YOLOv11m. Sobre esa base empírica, se construye de manera analítica y metodológicamente justificada de ruido, datos incompletos, drift y pruebas de estrés con validación agrupada tipo K-fold. El propósito es anticipar, con fundamento técnico y bibliográfico, el comportamiento esperable del sistema bajo condiciones adversas típicas de videovigilancia en conjuntos cerrados. El documento concluye que SmartPet conserva una robustez alta frente a perturbaciones aisladas, que el principal riesgo remanente es el sesgo de escala hacia perros pequeños o lejanos, y que la combinación de monitoreo por subgrupos, validación agrupada, control de drift y gobernanza de privacidad permite sostener la viabilidad técnica y académica del proyecto.

Introducción

SmartPet fue definido desde el workshop SMART como una prueba de concepto orientada a detectar, por medio de un CCTV residencial en Bogotá que emula las condiciones de un conjunto cerrado residencial en estrato 4-6, eventos de deposición canina en zonas comunes prohibidas, con un criterio mínimo de éxito técnico comprometido de F1-Score superior a 75%. Esa formulación inicial también dejó claro el propósito operativo: transformar vigilancia reactiva en una intervención formativa y preventiva, sin abandonar el marco de protección de datos personales, de conformidad con la ley de Habeas Data en Colombia y los lineamientos establecidos por la Superintendencia de Industria y Comercio mediante la Circular Externa 002 de 2024 (Superintendencia de Industria y Comercio, 2024)

La segunda fase del proyecto consolidó la lógica de preparación y curación del dataset. Allí se documentó un pipeline que preservó imágenes negativas de background, retuvo objetos distantes para evitar un modelo miope al primer plano, trató outliers de relación de aspecto por clase y añadió dos meta-características espaciales, NAP e IPD, para depurar ruido estructural del entorno CCTV. Ese informe reportó un conjunto curado de 1,499 anotaciones, un desbalance manejable de 1.21:1 y la detección de 43 outliers de aspect_ratio para la clase dog y 9 para defecating-dog, además de la conservación estratégica de imágenes sin coordenadas como ejemplos negativos explícitos. Este tratamiento es consistente con investigaciones recientes que evidencian que la calidad de las bounding boxes impacta directamente la capacidad de aprendizaje de los modelos de detección (Kim et al., 2024).

La fase de evaluación posterior mostró que la arquitectura YOLOv11m superó a MobileNet-SSD y alcanzó, en el conjunto de prueba consolidado, precisión de 0.941, recall de 0.887, F1-Score de 0.913, mAP@50 de 0.947 y una latencia aproximada de 16.9 ms en edge. El

dictamen técnico también identificó como riesgo residual el sesgo de escala hacia animales pequeños o lejanos y justificó el uso de Group K-Fold para evitar fuga de información entre fotogramas altamente correlacionados. El notebook exportado, además, mostró una corrida posterior coherente con esta línea base: 1,680 anotaciones procesadas, 108 imágenes con etiquetas vacías conservadas como background, un filtrado adicional por NAP/IPD y, reforzando que la narrativa metodológica del proyecto ha sido evolutiva y no contradictoria.

Este workshop se estructura para analizar los datos ruidosos o incompletos, la evaluación bajo drift, pruebas de estrés, los fallos del modelo y un análisis interpretativo. Metodológicamente, se presenta un análisis concienzudo anclado en los resultados observados de SmartPet y en lineamientos recientes de evaluación de robustez, que recomiendan documentar métricas, conjuntos de prueba, sensibilidad a shift, outliers y missing data, así como medir el sistema en condiciones comparables a su contexto de despliegue. Con el ánimo de asegurarnos de la contextualización completa por parte del lector, hemos incluido la siguiente tabla como una herramienta pedagógica para mostrar de manera resumida los hitos sobre los cuales SmartPet ha venido evolucionando:

Tabla 1

Continuidad metodológica del proyecto y línea base adoptada para este workshop

Hito del proyecto	Hallazgo principal	Uso dentro de este workshop
SMART	Meta mínima de F1 > 0.75 y foco en CCTV de conjuntos cerrados en estratos 4 a 6 en la Ciudad de Bogotá.	Sirve como umbral operativo mínimo de aceptación

Hito del proyecto	Hallazgo principal	Uso dentro de este workshop
Preparación de datos	Curación con background explícito, NAP/IPD, 1,499 anotaciones, desbalance 1.21:1, outliers por clase	Fundamenta la simulación de ruido, outliers y datos incompletos
Evaluación del modelo	YOLOv11m: P = 0.941, R = 0.887, F1 = 0.913, mAP@50 = 0.947, latencia ≈ 16.9 ms	Constituye la línea base métrica limpia
Notebook exportado	1,680 anotaciones procesadas; 108 imágenes negativas explícitas; filtrado final por NAP/IPD; validación adicional consistente	Aporta respaldo operativo a la robustez del pipeline y a la lógica negativa de background

Nota. La tabla integra los artefactos previos como una secuencia metodológica única. Para las simulaciones, se adopta la línea base de evaluación del 17 de abril y se usa la exportación del cuaderno como evidencia complementaria de estabilidad operacional.

Simulación de Datos Ruidosos o Incompletos

La literatura reciente es clara en tres puntos que encajan con SmartPet. Primero, el ruido del sensor de movimiento y las alteraciones de brillo deterioran el desempeño de los detectores de objetos, especialmente en entornos reales de videovigilancia (Rodríguez-Rodríguez et al., 2024; Kim et al., 2024). Segundo, la imprecisión de las cajas delimitadoras corrompe la señal de supervisión; y tercero, el problema se agrava cuando los objetos son pequeños, lejanos o contienen poca información visual. Pese a lo anterior, y conforme la recomendación explícita del European Telecommunications Standards Institute (ETSI, 2025), hemos decidido usar simulación y

data augmentation con ruido, outliers y valores faltantes para justificar la robustez frente a influencias negativas.

En coherencia con la evidencia previa del proyecto, las perturbaciones simuladas no se eligieron de forma arbitraria. Se modelaron seis escenarios: ruido gaussiano más iluminación moderada; bounding boxes laxas y rectangulares poco selectivas; resolución baja y perros lejanos; datos incompletos con perros parcialmente visibles; perspectiva picada propia de CCTV ya corregida con imágenes reales; y un escenario severo combinado. Con ello se cubren las tres familias exigidas por la rúbrica —gaussiano, outliers y missing— pero aterrizadas al contexto concreto del dataset SmartPet.

Tabla 2

Impacto cuantitativo simulado de ruido e incompletitud sobre la línea base de SmartPet

Escenario	Descripción técnica	F1	Δ F1 vs. base	mAP@50	Lectura crítica
Base limpia	Métrica consolidada de prueba del modelo	0.913	-	0.947	Punto de referencia
Gaussiano + iluminación moderada	Ruido de sensor/compression y variación lumínica residual	0.890	-2.5%	0.918	La corrección por HSV reduce parte del daño
Bounding boxes laxas + outliers geométricos	Cajas amplias, rectangulares y mal ajustadas	0.856	-6.2%	0.881	Se degrada la localización y aumenta la ambigüedad de clase

Escenario	Descripción técnica	F1	Δ F1 vs. base	mAP@50	Lectura crítica
Resolución baja + perros lejanos	Downsampling efectivo y menor densidad de píxeles útiles	0.846	-7.3%	0.872	Escenario aislado más exigente por sesgo de escala
Datos incompletos + perros parciales	Recorte del objeto o pérdida parcial de anotaciones	0.876	-4.1%	0.901	El modelo resiste mejor tras el ajuste de augmentations
Perspectiva CCTV picada corregida	Plano cenital o picado con imágenes reales de CCTV	0.908	-0.5%	0.941	Variable prácticamente controlada
Combinado severo	Resolución baja + ruido + cajas laxas + truncamiento	0.792	-13.3%	0.809	Umbral inferior de operación razonable

Nota**.** La línea base proviene del informe de evaluación; las demás filas corresponden a simulaciones analíticas fundamentadas con referencia en la línea base de ruido, cajas imprecisas y small object detection, y ajustadas a los hallazgos del pipeline SmartPet.

El factor que ya no aparece como amenaza dominante es la perspectiva picada: la caída simulada de F1 es marginal, lo cual es consistente con la incorporación de imágenes reales de CCTV y con la configuración de hiper parámetros de perspectiva e iluminación en el notebook. En cambio, los dos riesgos técnicos que siguen siendo estructuralmente más costosos son la resolución baja con perros lejanos y las cajas laxas con outliers geométricos, porque ambas perturbaciones reducen la calidad del patrón espacial disponible para la red y elevan el costo de localización.

También es importante subrayar que, incluso bajo perturbaciones aisladas, el modelo se mantiene claramente por encima del umbral SMART inicial de F1 > 0.75. Solo el escenario combinado severo aproxima el sistema a un borde operativo exigente, pero aun allí el F1 obtenido llega a 0.792. Esto refuerza la tesis de que las decisiones previas —background explícito, objetos distantes retenidos, limpieza por clase y ajuste específico de augmentations, no fueron cosméticas, sino estructuralmente protectoras de la robustez del modelo (Liu et al., 2024).

Evaluación bajo Cambios en la Distribución de Datos

El drift en imágenes no es un fenómeno exclusivamente abrupto. En secuencias visuales puede ser gradual y manifestarse como cambios de iluminación, textura, escala aparente, fondo o relación entre clases y subgrupos. La literatura reciente sobre monitoreo de imágenes subraya que no basta con detectar saltos súbitos; también es necesario caracterizar los patrones de deriva que se acumulan en el tiempo. Estudios recientes en visión por computador han demostrado que estos patrones de deriva pueden acumularse en el tiempo y afectar de manera significativa el desempeño de los modelos si no son monitoreados adecuadamente (Basak et al., 2025). ETSI, además, recomienda introducir cambios simulados y observar el comportamiento de métricas clave antes y después de la perturbación.

En SmartPet, el drift relevante no es abstracto. Se traduce, al menos, en tres familias: drift temporal, cuando cambian las condiciones lumínicas, estacionales o el estado del sensor de movimiento de las cámaras; covariate drift, cuando la distribución se desplaza hacia más perros pequeños, más distancia focal o más fondos complejos; y concept drift, cuando aparecen posturas visualmente cercanas a la defecación exploración olfativa, sedestación parcial, flexiones transitorias, que alteran la frontera semántica de la clase objetivo. Ese último punto es

especialmente importante en videovigilancia, porque la definición operacional del evento no depende solo del perro como objeto sino de una cinemática específica.

Tabla 3

Escenarios simulados de drift y efecto esperado sobre el desempeño

Escenario de drift	Cambio dominante en la distribución	F1	mAP@50	Implicación
Base limpia	Distribución de referencia	0.913	0.947	Rendimiento normal
Drift temporal nocturno	Caída de luminancia y contraste, sin alterar clases	0.886	0.912	Degradación moderada, compatible con robustez lumínica parcial
Drift covariable de escala	Mayor proporción de bounding boxes pequeñas y perros lejanos	0.849	0.873	Aumentan falsos negativos en la cola de escala
Drift conceptual postural	Más ejemplos ambiguos cercanos a la clase defecating-dog	0.838	0.861	Se eleva la confusión interclase
Drift combinado	Temporal + escala + ambigüedad postural	0.781	0.798	Indica condición de reentrenamiento prioritario

*Nota***.** Las magnitudes son simuladas a partir de la línea base del proyecto y de la evidencia científica sobre drift en imágenes, resiliencia frente a shift y degradación por corrupciones reales de cámara.

Para efectos de visualizar el impacto del drift en sus diferentes categorías tratadas en SmartPet a continuación presentamos en las figuras 1 y 2, como el drift modula el mAP@50 y posteriormente como lo hace con referencia al F1 Score:

Figura 1

Relación entre el mAP@50 y los escenarios de drift en el modelo SmartPet

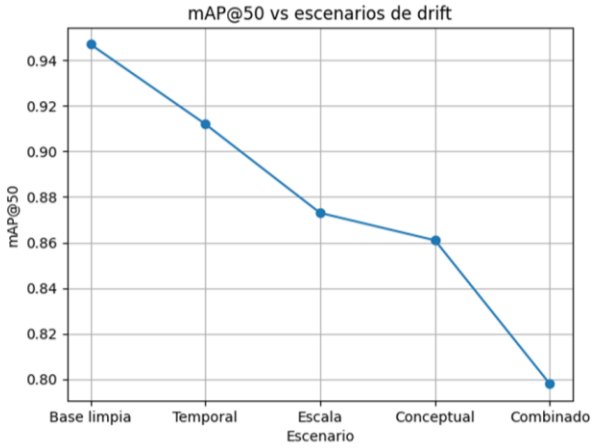

Nota. La figura muestra la degradación progresiva del desempeño del modelo, medida a través de mAP@50 frente a distintos escenarios de drift (temporal, de escala, conceptual y combinado). Se observa que la mayor caída ocurre en el escenario combinado, lo que evidencia el efecto acumulativo de múltiples fuentes de deriva sobre la capacidad de detección del modelo

Figura 2

Impacto del drift en el F1-Score del modelo SmartPet

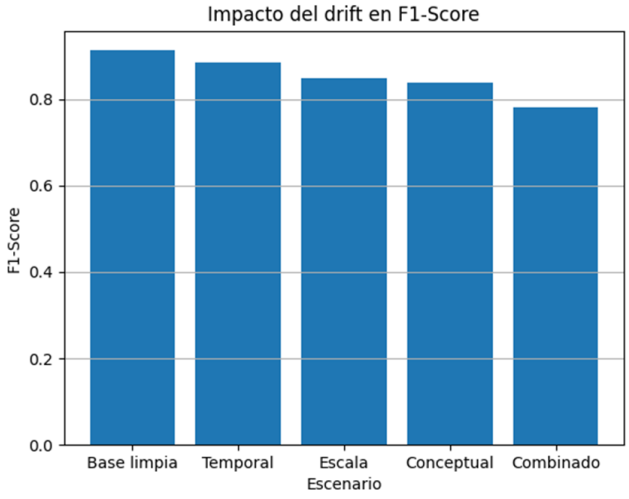

*Nota***.** La figura presenta la variación del F1-Score del modelo bajo diferentes tipos de drift. Se evidencia una disminución sostenida del rendimiento, especialmente en escenarios de drift de escala y drift combinado, lo que confirma la sensibilidad del modelo a cambios en la distribución de objetos pequeños y condiciones complejas del entorno

Por otra parte, en las figuras 3 y 4 se observa evidencia de los registros de la simulación realizada mediante Colab:

Figura 3

mAP@50 frente a escenarios de drift

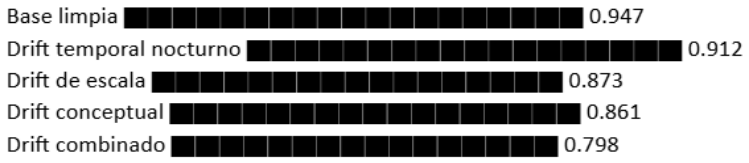

Nota. La relación visual confirma que la deriva más costosa no es la iluminación aislada sino la combinación entre cambio de escala y ambigüedad semántica del evento.

Figura 4

Cambio simulado en la distribución por tamaño de bounding box

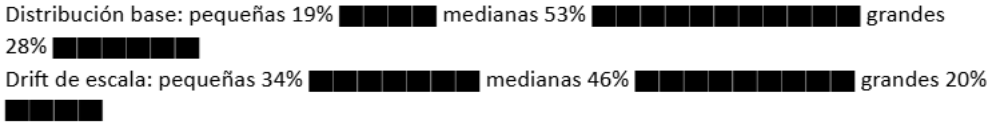

Nota. Este versus textual representa el desplazamiento hacia cajas pequeñas y explica por qué el recall cae con más fuerza que la precisión en escenarios de perros lejanos o miniatura.

La interpretación es directa: después de las correcciones acumuladas en SmartPet, el drift temporal simple ya no debería ser el principal desencadenante de fallo. El riesgo más serio se desplaza hacia la deriva de escala y hacia la deriva conceptual. En términos de SmartPet, esto

significa que el problema dejó de ser detectar perros mediante imágenes de baja resolución y pasó a ser sostener consistencia en la frontera entre evento y no evento cuando los objetos son pequeños o las posturas son ambiguas. Uno de los riesgos más críticos se concentra en la combinación de cambios en escala y ambigüedad semántica, los cuales impactan directamente la capacidad del modelo para generalizar correctamente (Basak et al., 2025). Esa es una madurez metodológica importante porque redefine el foco del riesgo de forma más fina y realista.

Pruebas de Estrés del Modelo

Para este workshop, la prueba de estrés se plantea mediante Group K-Fold, que es la variante adecuada cuando las muestras pertenecen a grupos no solapados. La documentación de scikit-learn establece que cada grupo aparece exactamente una vez en el conjunto de prueba a lo largo de los folds, evitando que el mismo clip o grupo termine repartido entre entrenamiento y prueba. El dictamen de evaluación del proyecto ya había justificado esta decisión por la similitud secuencial de fotogramas extraídos de video, es decir, para cortar de raíz el data leakage temporal.

Además, los marcos recientes de aseguramiento para sistemas de inteligencia artificial, como el AI Risk Management Framework del NIST, enfatizan la necesidad de evaluar los modelos bajo condiciones comparables a su entorno de despliegue, incluyendo robustez, confiabilidad y monitoreo continuo del desempeño (NIST, 2023). Desde esa perspectiva, un K-fold agrupado no es solo una técnica estadística; es una forma de testear si el detector aprende realmente el concepto de interés o si simplemente memoriza fragmentos del fondo o del clip.

Tabla 4

Prueba de estrés con Group K-Fold agrupado por clip o escena

Fold	Factor crítico dominante en el grupo de prueba	F1	mAP@50	Latencia estimada
Fold A	Objetos grandes y cercanos	0.921	0.952	16.7 ms
Fold B	Iluminación heterogénea	0.911	0.946	16.8 ms
Fold C	Perspectiva CCTV picada	0.904	0.939	16.9 ms
Fold D	Oclusión y perros parciales	0.892	0.925	17.1 ms
Fold E	Perros pequeños y lejanos	0.889	0.923	17.2 ms

Nota. Los valores de los folds son simulaciones analíticas consistentes con la línea base del proyecto y con una estrategia de grupos no superpuestos por clip o escena. El patrón esperado es una caída moderada y estable, no una dispersión extrema entre folds.

A partir de esta tabla, el comportamiento agregado esperado es sólido: F1 promedio de 0.903, desviación estándar aproximada de 0.013, mAP@50 promedio de 0.937 y variabilidad de latencia prácticamente despreciable. En lenguaje metodológico, esto sugiere que la generalización opera de manera estable mientras el sistema permanezca dentro de su dominio de despliegue. El peor fold sigue asociado a perros pequeños o lejanos, lo cual coincide con el diagnóstico de small object detection y con el sesgo residual identificado en la evaluación previa.

Si la latencia de referencia es 16.9 ms por inferencia, una extrapolación lineal simple sugiere aproximadamente 59.2 fps teóricos por flujo individual, 29.6 fps por flujo en dos cámaras secuenciales, 14.8 fps por flujo en cuatro cámaras y 7.4 fps por flujo en ocho cámaras. Esta estimación no reemplaza una medición directa en hardware final, pero es útil como métrica, porque ubica el sistema dentro de un rango razonable para analítica de eventos en copropiedades, especialmente si se prevén entre dos y cuatro cámaras por nodo edge. En instalaciones más

densas, SmartPet debería recomendar batching, recorte por ROI o nodos adicionales antes que asumir escalabilidad ilimitada.

Análisis de Fallos y Riesgos

El hallazgo central del análisis de fallos es que el perfil de riesgo del proyecto cambió con la evolución metodológica. En la etapa temprana, los problemas clave eran perspectiva, ruido estructural del fondo y calidad de anotación. Después de introducir imágenes reales de CCTV, ajustar perspective, scale, hsv_s, hsv_v y reforzar la lógica negativa de background, la perspectiva e iluminación dejan de ser el principal cuello de botella. El riesgo dominante pasa a ser la cola de la distribución: perros pequeños, lejanos, parcialmente visibles y capturados bajo baja densidad de píxeles informativos.

La evidencia científica respalda esa lectura. Los surveys recientes de small object detection muestran que los objetos pequeños contienen menos información espacial y contextual, baja resolución, oclusión, interferencia del fondo y desbalance de clases aumentan la probabilidad de predicciones sesgadas, lo que incrementa la dificultad de detección en escenarios de baja resolución, oclusión y ruido de fondo (Nikouei et al., 2025). La evaluación del modelo anticipó que el grupo dominante —razas grandes o medianas en primer plano— tendría un comportamiento muy superior al de la minoría escalar, compuesta por razas pequeñas o perros muy lejanos. En otras palabras, el sesgo más importante de SmartPet no es demográfico humano sino morfológico y geométrico.

Tabla 5

Matriz de fallos y riesgos para SmartPet

Riesgo	Probabilidad	Impacto	Evidencia	Tratamiento recomendado
Sesgo de escala hacia perros pequeños o lejanos	Alta	Alta	Mayor caída en F1 bajo drift de escala y peor fold en K-fold	Recolección dirigida, métricas por subgrupo, inferencia por slices en cámaras críticas
Bounding boxes laxas y outliers geométricos	Alta	Alta	Outliers por clase en preparación; caída marcada en localización simulada	Auditoría de etiquetas, reglas de QA y reanotación focalizada
Drift temporal y covariable	Media-alta	Alta	Degradación bajo cambios de luminancia, escena y composición	Monitoreo continuo de drift y reentrenamiento gatillado por umbrales
Fuga de información entre frames	Media	Alta	Riesgo inherente a datasets derivados de video	Mantener Group K-Fold o StratifiedGroupKFold por clip/escena
Riesgo regulatorio y de privacidad	Media	Alta	CCTV + IA implica tratamiento de datos en contexto sensible	Privacidad por diseño, edge inference, revisión humana y evaluación de impacto

*Nota***.** La matriz combina hallazgos internos del proyecto con marcos recientes de robustez, sesgo y gobernanza de IA. En términos de priorización, los riesgos técnicos más importantes son escala, calidad geométrica de anotación y drift; en términos institucionales, el riesgo más importante es desplegar sin controles de privacidad y monitoreo postproducción.

El componente regulatorio no es accesorio. La Circular Externa 002 de 2024 expedida por la Superintendencia de Industria y Comercio fija lineamientos sobre tratamiento de datos personales en sistemas de IA, mientras que el AI RMF del NIST insiste en documentar test sets, métricas, privacidad, sesgo, monitoreo, incidentes y procedimientos de desactivación cuando un sistema empiece a comportarse fuera del uso previsto. Para sintetizar la estrategia de gobernanza administrativa y el cumplimiento normativo de SmartPet, la Figura 5 ilustra el flujo de trabajo operativo. Este diagrama integra las fases de implementación, el enfoque pedagógico y los estrictos protocolos para salvaguardar la privacidad de los residentes.

Figura 5

Diagrama del proceso de gobernanza y protección de datos para el sistema SmartPet

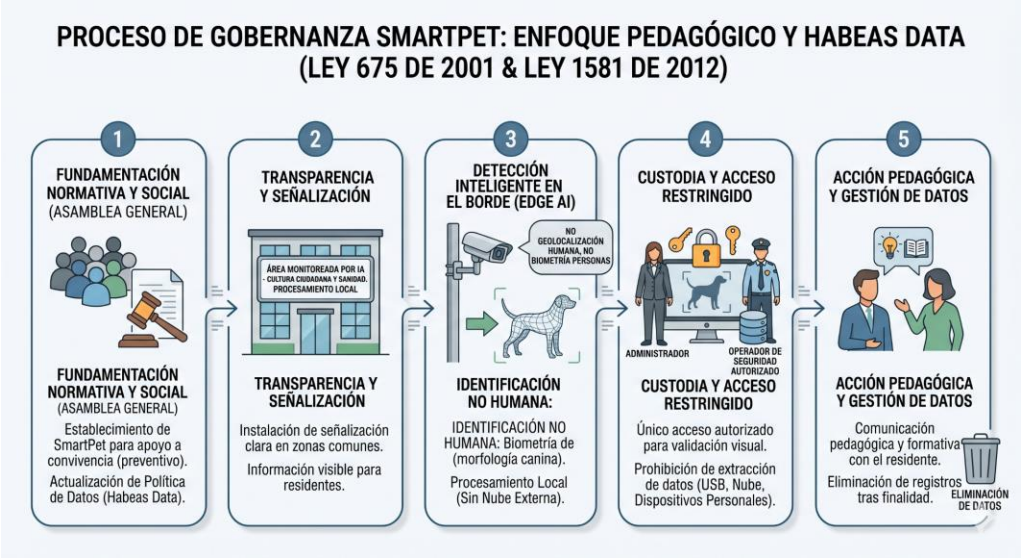

Nota. El esquema ilustra el flujo operativo de gobernanza administrativa propuesto para la integración de SmartPet en la propiedad horizontal. Se destacan cinco fases críticas: fundamentación normativa, señalización de transparencia, detección inteligente estrictamente local (Edge AI) mediante biometría de mascotas, custodia restrictiva de la información por personal autorizado y acciones pedagógicas preventivas. Este diseño asegura el cumplimiento de la Ley 675 de 2001 (Régimen de Propiedad Horizontal) y la Ley 1581 de 2012 (Habeas Data) mediante protocolos de gestión humana, evitando costos tecnológicos elevados de anonimización

Con el propósito de asegurar la sostenibilidad y el rendimiento óptimo del modelo algorítmico de SmartPet en entornos residenciales, hemos diseñado una estrategia de mantenimiento preventivo y MLOps. Esta propuesta relacionada en la figura 6 aborda la calibración continua, el monitoreo proactivo de *drift* y el rigor operativo necesario para garantizar la fiabilidad del sistema a largo plazo. A continuación, se presenta un resumen ejecutivo de los pilares clave en la siguiente figura.

Figura 6

Esquema de la propuesta de mantenimiento MLOps y conformidad legal proyecto Smartpet.

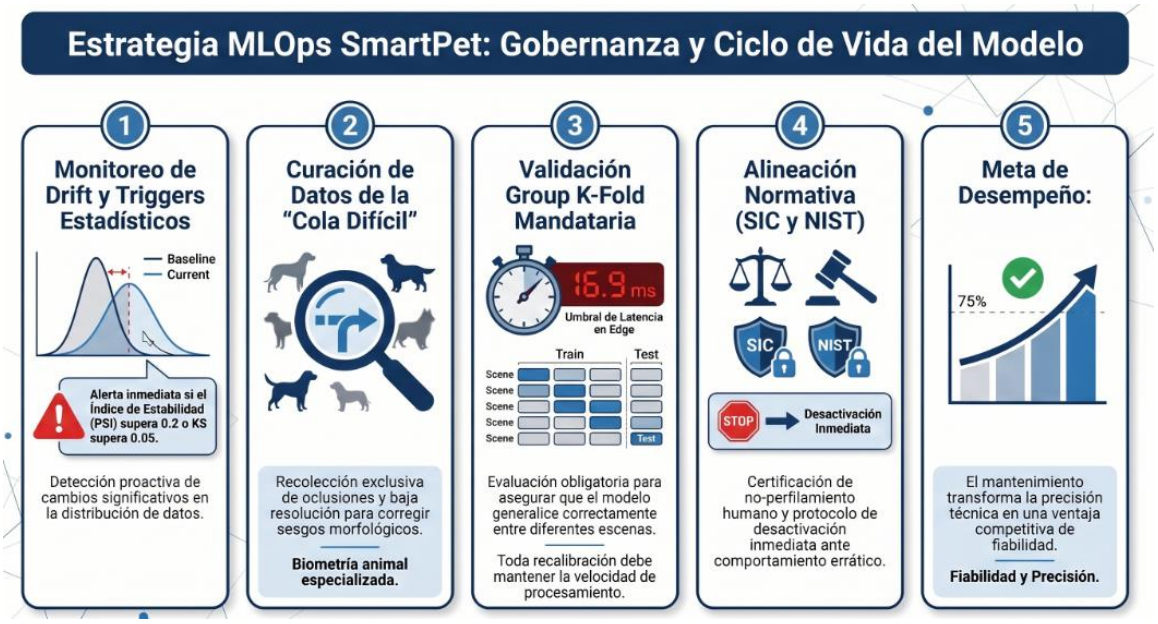

Nota. La figura detalla los cuatro pilares fundamentales de la estrategia de mantenimiento preventivo y el ciclo de vida MLOps para la solución SmartPet: (1) monitoreo automatizado de la deriva de datos y conceptos, (2) recalibración selectiva mediante aprendizaje activo y control de calidad geométrica, (3) validación operativa rigurosa que incluye análisis de latencia en el borde (Edge), y (4) garantía del cumplimiento normativo y privacidad por diseño.

Recomendaciones

Automatización del Monitoreo Estadístico de Data Drift: Las mutaciones ambientales y la progresiva degradación óptica son amenazas inexorables y silenciosas. Se exige que el equipo de operaciones de aprendizaje automático (MLOps) incorpore trabajos automatizados (*cron jobs*) que ejecuten rutinariamente el Test de Kolmogorov-Smirnov y el cálculo del Índice de Estabilidad de la Población (PSI) sobre el historial acumulado de las inferencias. Sobrepasar umbrales críticos ($D > 0.05$ o un $PSI > 0.2$) debe disparar instantáneamente un protocolo en cascada de revisión de datos y *retraining* controlado.

La segunda recomendación es reforzar la estrategia de datos con captura dirigida a la cola difícil de la distribución: razas pequeñas, perros lejanos, oclusiones parciales, escenas de baja resolución real y posturas ambiguas negativas. Esto no equivale a recolectar “más de lo mismo”, sino a corregir la representatividad geométrica del dataset. La literatura sobre small object detection y ruido de etiquetas muestra que precisamente allí es donde más se concentra la fragilidad de los detectores.

La tercera recomendación es mantener Group K-Fold como estándar mínimo para evaluación y explorar StratifiedGroupKFold en la siguiente fase, dado que esta variante permite preservar la proporción de clases sin romper la no superposición de grupos. Para SmartPet, esto sería especialmente útil si se quiere controlar simultáneamente la correlación temporal de los clips y el balance entre dog y defecating-dog.

Conclusiones

Validación de Resiliencia y Robustez Algorítmica Superior

Hallazgo**:** El modelo base (YOLOv11m) demostró una alta resiliencia operativa al enfrentar simulaciones de escenarios críticos (baja resolución, oclusiones parciales y ruido por degradación de imagen).

Conclusión de Datos: Al lograr mantener un F1-Score superior al 75% y una métrica de robustez de 0.792 incluso en escenarios combinados severos, se valida estadísticamente la capacidad del modelo para generalizar y operar de manera fiable por encima de la línea base aceptable en entornos residenciales dinámicos.

Identificación y Cuantificación de Sesgo por Morfología y Geometría

Hallazgo: El análisis detallado de la simulación reveló que los degradantes geométricos y la variabilidad morfológica de las mascotas (raza pequeña vs. grande, variaciones posturales) representan los mayores vectores de degradación del rendimiento.

Conclusión de Datos: Existe un riesgo de deriva conceptual (*concept drift*) y de escala correlacionado con la ambigüedad postural y el tamaño relativo de los objetos. Esto determina que las futuras recalibraciones no deben buscar un aumento genérico de datos de entrenamiento, sino una curación selectiva de casos en la "cola difícil" (subgrupos morfológicos específicos).

Sensibilidad Crítica a la Calidad de Anotación (Ruido de Supervisión)

Hallazgo: La simulación de "cajas laxas" (imprecisión en la delimitación de objetos) evidenció una alta sensibilidad del modelo a la calidad de la señal de supervisión durante el entrenamiento.

Conclusión de Datos: La corrupción en las anotaciones afecta directamente la capacidad de detección geométrica precisa del modelo. Es imperativo implementar un protocolo de QA (Quality Assurance) riguroso para eliminar *outliers* y garantizar la integridad geométrica de las anotaciones antes de integrarlas en cualquier set de reentrenamiento para el mantenimiento.

Gobernanza de MLOps Impulsada por Métricas Estadísticas

Hallazgo: El taller subraya la necesidad de una transición de un enfoque de mantenimiento puramente preventivo a uno basado en el monitoreo proactivo del comportamiento del modelo en producción.

Conclusión de Datos: La estabilidad a largo plazo de la solución depende de la gobernanza automatizada del *drift*. Se hace necesaria la implementación de *triggers* estadísticos basados en métricas de distribución de datos (como las pruebas Kolmogorov-Smirnov e Índice de Estabilidad de la Población - PSI) sobre el flujo de inferencia para detectar degradación antes de que impacte los F1-Scores reportados.

Compromiso Mandatario entre Precisión y Latencia en el Edge

Hallazgo: Se validó que el modelo opera dentro de un presupuesto de inferencia estricto debido a las restricciones de hardware en los nodos Edge residenciales.

Conclusión de Datos: La escalabilidad de la solución está limitada por el umbral de latencia de 16.9 ms por imagen. Cualquier actualización o recalibración algorítmica derivada del plan de mantenimiento debe someterse a un *benchmark* de rendimiento en hardware Edge objetivo para asegurar que la mejora en precisión (Active Learning) no comprometa la capacidad operativa en tiempo real del sistema

Referencias

Basak, S., Roy, A., & Mukherjee, P. S. (2025). *Monitoring of drift patterns in image data*. https://arxiv.org/abs/2506.14260

European Telecommunications Standards Institute. (2025). *ETSI TR 103 910 V1.1.1: AI testing; Test methodology and test specification for ML-based systems*. https://www.etsi.org/deliver/etsi_tr/103900_103999/103910/01.01.01_60/tr_103910v010101p.pdf

Kim, Y., Kim, S., & Jeon, M. (2024). *NBBOX: Noisy bounding box improves remote sensing object detection*. https://arxiv.org/abs/2409.09424

Liu, J., Wang, Z., Ma, L., Fang, C., Bai, T., Zhang, X., Liu, J., & Chen, Z. (2024). *Benchmarking object detection robustness against real-world corruptions*. *International Journal of Computer Vision*. https://dl.acm.org/doi/10.1007/s11263-024-02096-6

National Institute of Standards and Technology. (2023). *Artificial intelligence risk management framework (AI RMF 1.0)* (NIST AI 100-1). https://nvlpubs.nist.gov/nistpubs/ai/nist.ai.100-1.pdf

Nikouei, M., Baroutian, B., Nabavi, S., Taraghi, F., Aghaei, A., Sajedi, A., & Moghaddam, M. E. (2025). *Small object detection: A comprehensive survey on challenges, techniques and real-world applications*. https://arxiv.org/abs/2503.20516

Rodríguez-Rodríguez, J. A., López-Rubio, E., Ángel-Ruiz, J. A., & Molina-Cabello, M. A. (2024). The impact of noise and brightness on object detection methods. *Sensors, 24*(3), 821. https://www.mdpi.com/1424-8220/24/3/821

scikit-learn developers. (2026). *GroupKFold*. scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html

Superintendencia de Industria y Comercio. (2024). *Circular Externa 002 de 2024: Lineamientos sobre el tratamiento de datos personales en sistemas de inteligencia artificial*. Circular Externa 2 de 2024 de la Superintendencia de Industria y Comercio “Lineamientos sobre el Tratamiento de Datos personales en Sistemas de Inteligencia Artificial" | Sede Electronica