Caso de estudio: Proyectos de Inteligencia Artificial Exitosos y Fallidos y Lecciones Aprendidas al Proyecto SmartPet

Juan Miguel Velandia García

Oscar Mauricio Parra Folleco

Maestría en Inteligencia Artificial, Universidad Espíritu Santo

Proyecto Integrador en Inteligencia Artificial

Dra. Alexandra Jacqueline Arciniegas Coral

15 de mayo de 2026

Resumen

El presente documento constituye un escrutinio y una asesoría estratégica estructurada en torno a la implementación de sistemas de inteligencia artificial (IA) en entornos no controlados, orientada específicamente a fortalecer el proyecto SmartPet. Dicho proyecto consiste en una arquitectura de visión por computadora fundamentada en el modelo YOLOv11m, desplegada bajo el paradigma de computación en el borde, cuyo propósito es la detección automatizada de excreción canina en zonas residenciales prohibidas de la ciudad de Bogotá para fomentar la convivencia preventiva sin vulnerar la privacidad ciudadana. A través del análisis profundo de la literatura contemporánea y la disección de casos empíricos de la industria tecnológica, este documento identifica las brechas críticas entre el diseño teórico de los algoritmos de aprendizaje profundo y su viabilidad operativa en el mundo real. Examinaremos dos casos de fracaso paradigmáticos: la división de compra algorítmica de viviendas Zillow Offers y el ecosistema de recomendación clínica IBM Watson for Oncology. Estos colapsos corporativos ilustran errores sistémicos como la sobrecarga técnica, la desconexión entre el problema de negocio y la solución matemática, la adopción de narrativas basadas en expectativas irreales, la ceguera ante la asimetría de información y la escalabilidad prematura sin validación contextual. En contraposición, se analizan dos casos de éxito: el sistema de fumigación de precisión See & Spray de John Deere y la tecnología de fusión de sensores de Amazon Go. Estos despliegues exitosos demuestran el valor de acotar estrictamente el dominio del problema, priorizar el procesamiento perimetral para reducir latencias, y concebir a la inteligencia artificial como un amplificador cognitivo humano en lugar de un sustituto autónomo. Finalmente, se extraen estas lecciones y se analiza su transferencia directamente al ecosistema del proyecto SmartPet. Se argumenta de manera concluyente que la supervivencia operativa del sistema depende de tres pilares innegociables: la consolidación de la inferencia perimetral para cumplir con el marco jurídico del Habeas Data colombiano, la mitigación del sesgo de escala mediante técnicas de Inferencia Hiper-Fragmentada Asistida (SAHI) para garantizar la equidad algorítmica, y la institucionalización de una gobernanza fundamentada en la supervisión humana acoplada a un monitoreo continuo de la

deriva de datos. Este documento trasciende el reduccionismo técnico para ofrecer una visión sociotécnica integral, garantizando que el proyecto no solo sea matemáticamente preciso, sino éticamente responsable y operativamente sostenible a largo plazo.

Introducción

La adopción de tecnologías basadas en inteligencia artificial y aprendizaje profundo ha redefinido los límites de la automatización, prometiendo transformaciones disruptivas en la optimización de procesos industriales, la personalización masiva de servicios y la reducción de costos operativos en un espectro diverso de sectores económicos (Telefónica, 2024). Sin embargo, la transición desde la investigación teórica en entornos de laboratorio controlados hacia el despliegue en infraestructuras de producción en el mundo real está plagada de obstáculos indescifrables. Diversos estudios empíricos y análisis de consultoras globales coinciden en señalar una realidad alarmante: aproximadamente el ochenta por ciento de los proyectos empresariales de inteligencia artificial fracasan antes de alcanzar su máximo potencial o de generar un retorno de inversión que justifique el capital invertido (ORSYS, 2025). Esta elevada tasa de mortandad tecnológica rara vez obedece a deficiencias matemáticas inherentes a las redes neuronales o a la falta de capacidad de procesamiento computacional. Por el contrario, la literatura científica y los análisis de la industria demuestran que el fracaso algorítmico se deriva predominantemente de fracturas estructurales en la conceptualización inicial del problema, la carencia de una gobernanza de datos adecuada, la falta de alineación estratégica con los objetivos del negocio y, de manera crítica, la incapacidad para gestionar el impacto sociotécnico de la herramienta sobre los usuarios finales (Melbourne Business School Centre for Business Analytics, 2024).

En este complicado panorama de innovación y riesgo, emerge SmartPet, una solución de visión por computadora de altísima complejidad técnica y profunda sensibilidad social. El proyecto se articula como una disrupción orientada a mitigar uno de los conflictos vecinales más recurrentes en el régimen de propiedad horizontal en la ciudad de Bogotá: el manejo inadecuado de residuos biológicos caninos en áreas comunes y senderos peatonales. Históricamente, el control de estas contravenciones ha dependido de métodos ineficientes, tales como la vigilancia humana presencial o la revisión manual retrospectiva de los circuitos cerrados de televisión (CCTV), prácticas que resultan propensas a la fatiga visual, altamente reactivas y financieramente insostenibles debido a los

incrementos exponenciales en las tarifas reguladas de seguridad privada (Copropiedades, 2026). SmartPet propone transformar esta infraestructura pasiva en un ecosistema inteligente, proactivo y preventivo mediante la aplicación de algoritmos de visión por computadora de última generación, específicamente la arquitectura convolucional YOLOv11m, operando desde la periferia computacional (Jocher, 2023).

No obstante, el diseño y despliegue de SmartPet enfrenta barreras operativas formidables que van mucho más allá de la optimización del tensor predictivo. A nivel geométrico, el sistema debe lidiar con la distorsión morfológica generada por los ángulos picados (cenitales) de las cámaras de seguridad residenciales, lo que inscribe el desafío directamente en el dominio de la Detección de Objetos Pequeños, un subcampo caracterizado por la escasez crítica de píxeles informativos y la alta vulnerabilidad a la varianza lumínica (Nikouei et al., 2025). A nivel financiero y arquitectónico, el proyecto debe evadir los costos depredadores de los servicios de inteligencia artificial en la nube (AIaaS), los cuales harían inviable el monitoreo ininterrumpido de flujos de video continuo. Finalmente, a nivel regulatorio, el ecosistema debe operar bajo el más estricto cumplimiento del derecho fundamental al Habeas Data, consagrado en la Ley Estatutaria 1581 de 2012 de Colombia, y acatar los recientes lineamientos sobre sistemas de inteligencia artificial estipulados en la Circular Externa 002 de 2024 expedida por la Superintendencia de Industria y Comercio (Congreso de Colombia, 2012; Superintendencia de Industria y Comercio, 2024).

Para asegurar que SmartPet trascienda la fase de prueba de concepto y se consolide como una solución industrialmente viable y socialmente responsable, es un imperativo académico abandonar el reduccionismo puramente algorítmico y nutrir el desarrollo con las lecciones empíricas del mercado global. Este análisis asume dicho reto mediante la extracción de aprendizajes en torno a proyectos de inteligencia artificial comparables. Al diseccionar las arquitecturas, las narrativas empresariales y los fundamentos estratégicos de casos de fracaso paradigmáticos en el sector inmobiliario y médico, contrastándolos con casos de éxito indiscutible en la agricultura de precisión y

el comercio minorista, se busca destilar un compendio de factores críticos. El objetivo final es analizar la aplicación de estas lecciones aprendidas directamente a la estructura de SmartPet, proveyendo un marco de recomendaciones tácticas y estratégicas que blinden al proyecto contra la sobrecarga técnica, la deriva de concepto y la opacidad regulatoria, garantizando un despliegue ético, equitativo y viable tecnológicamente.

Evaluación Multidimensional de Casos de Estudio en Inteligencia Artificial

La comprensión profunda de las dinámicas que determinan el triunfo o el colapso de un modelo de aprendizaje automático en entornos de producción requiere una evaluación forense de implementaciones previas. A continuación, se desarrolla un análisis de cuatro casos de soluciones de inteligencia artificial que consideramos podrían enriquecer el proyecto Smartpet, seleccionados por su relevancia documental, su escala de inversión y la claridad de las lecciones sociotécnicas que aportan. Los casos se desglosan evaluando la sincronía entre el problema y la solución, escrutando la narrativa corporativa que envolvió el despliegue, e identificando los errores sistémicos o las buenas prácticas que determinaron su destino final.

Análisis de Casos Fallidos: El Colapso de la Inteligencia Artificial Mal Dirigida

El fracaso en la inteligencia artificial rara vez es silencioso; suele ir precedido de inmensas inyecciones de capital y promesas de transformación paradigmática. El estudio de los fracasos de Zillow Offers y de IBM Watson for Oncology expone las vulnerabilidades críticas que surgen cuando la complejidad matemática se divorcia del rigor metodológico y del sentido común empresarial.

Caso de Fracaso 1: Zillow Offers y la Ilusión de la Previsión Inmobiliaria

Fundada como una plataforma de medios digitales enfocada en la industria de bienes raíces, Zillow cimentó su dominio del mercado estadounidense ofreciendo a los usuarios acceso a vastas bases de datos de propiedades y a su algoritmo patentado de estimación de precios, el Zestimate (Gudigantala, 2024). Durante años, el Zestimate funcionó de manera eficiente como una

herramienta orientativa para el consumidor, estimando el valor actual de una propiedad con un margen de error reportado del 2.4% frente a viviendas en el mercado activo (Gudigantala, 2024). Sin embargo, en el año dos mil dieciocho, bajo la dirección de su junta ejecutiva, la compañía decidió capitalizar este algoritmo para transformar fundamentalmente su modelo de negocio, incursionando en el mercado del iBuying a través de una nueva división denominada Zillow Offers (Gudigantala, 2024). El concepto consistía en utilizar modelos de aprendizaje automático para presentar ofertas de compra en efectivo de manera casi instantánea a los propietarios, adquirir las viviendas, realizar renovaciones cosméticas y revenderlas rápidamente con un margen de ganancia. La narrativa empresarial era abrumadoramente ambiciosa: el director ejecutivo proyectó que esta división generaría veinte mil millones de dólares en ingresos anuales en un lapso de tres a cinco años, prometiendo instaurar el amanecer del comercio electrónico para los bienes raíces (Gudigantala, 2024; Kiger, 2021).

A pesar del vasto músculo financiero, en el tercer trimestre de dos mil veintiuno, el proyecto colapsó con una celeridad asombrosa. La compañía se vio obligada a clausurar permanentemente Zillow Offers tras reportar una pérdida operativa de cientos de millones de dólares, acumulando un inventario invendible de miles de casas adquiridas por encima de su valor de mercado, lo que resultó en el despido del veinticinco por ciento de su fuerza laboral y una caída catastrófica en su capitalización bursátil (Gudigantala, 2024; causaLens, 2022).

Claridad del Problema y Ajuste de la Solución (Fit Problema-Solución): El análisis forense de este fracaso revela un desajuste profundo e insalvable entre la naturaleza del problema de negocio y la solución algorítmica desplegada. El algoritmo original, el Zestimate, fue diseñado como un modelo predictivo basado en correlaciones históricas y datos espaciales estáticos para calcular el valor presente de un activo (Valor A). Sin embargo, el negocio del iBuying es intrínsecamente un problema de previsión financiera futura; requiere estimar con precisión matemática cuál será el valor de venta de la propiedad tres a seis meses en el futuro (Valor B), integrando variables dinámicas y altamente

volátiles como el costo del capital, fluctuaciones macroeconómicas, cambios súbitos en las tasas de interés hipotecarias y disrupciones en la cadena de suministro de materiales de construcción (Gudigantala, 2024; causaLens, 2022).

La solución de Zillow consistió en utilizar algoritmos de aprendizaje automático correlacionales que asumen que las tendencias pasadas son un indicador fiable del comportamiento futuro. Cuando el mercado inmobiliario experimentó un cambio abrupto (enfriamiento postpandemia), los modelos fueron incapaces de detectar el desplazamiento causal de las variables macroeconómicas. El algoritmo, entrenado en un mercado perpetuamente alcista, continuó prediciendo apreciaciones irreales y ejecutando ofertas agresivas por encima del valor real de los inmuebles, evidenciando que la IA carecía de capacidades de toma de decisiones contextuales frente a mercados no estacionarios (causaLens, 2022; Gudigantala, 2024).

Análisis de la Narrativa Utilizada: Tras el anuncio de la liquidación de la división, la alta dirección estructuró una narrativa defensiva que centralizaba la culpa en la tecnología. El director ejecutivo declaró públicamente que la imprevisibilidad en la proyección de los precios de las viviendas superó con creces lo anticipado por los modelos algorítmicos, justificando el cierre como una medida para evitar la volatilidad en el balance financiero (Kiger, 2021; Gudigantala, 2024). Esta narrativa de la inteligencia artificial falló operó como una fachada discursiva para enmascarar errores gerenciales de proporciones monumentales. Las investigaciones posteriores demostraron que el algoritmo funcionó exactamente como fue diseñado, optimizando las ofertas basándose en el pico histórico reciente; el verdadero fallo residió en la directriz corporativa de priorizar un hiper crecimiento insostenible, ignorando las limitaciones ontológicas del aprendizaje automático frente a la incertidumbre económica (Shackleford, 2026; Gudigantala, 2024).

Identificación de Errores Comunes Sistémicos: El caso de Zillow Offers cristaliza varios errores mortales en la implementación de IA, destacando la falta de enfoque, la sobrecarga técnica ciega y la eliminación de la supervisión humana:

En primer lugar, se identifica una ceguera algorítmica frente a la asimetría de información y la selección adversa. Este fenómeno, fundamentado en la teoría económica del "Problema de los Limones" del premio Nobel George Akerlof, dicta que cuando los compradores no pueden evaluar completamente la calidad de un activo, tienden a ofrecer un precio promedio. En consecuencia, los vendedores con viviendas en excelentes condiciones (cuyo valor real está por encima del promedio) rechazaban las ofertas algorítmicas de Zillow y optaban por el mercado abierto tradicional. Por el contrario, los vendedores con propiedades que ocultaban daños estructurales o problemas de mantenimiento aceptaban rápidamente las ofertas automatizadas. Al carecer de contexto humano cualitativo, el algoritmo de Zillow se dedicó a adquirir sistemáticamente los peores activos del mercado, un error estructural derivado de confiar en métricas de volumen sobre valoraciones cualitativas (Shackleford, 2026).

En segundo lugar, se evidenció una falla crítica en la inteligencia colaborativa (falta de Human-in-the-Loop). Inicialmente, la compañía empleaba analistas humanos de precios para auditar y ajustar las recomendaciones del algoritmo antes de emitir una oferta formal. Sin embargo, presionado por la meta directiva de adquirir quince mil casas por trimestre para sostener el hiper crecimiento, el liderazgo eliminó las barreras de contención humanas. Al permitir que un modelo no probado para fluctuaciones bajistas dictara operaciones financieras masivas de manera autónoma, Zillow transformó un error de cálculo matemático en una catástrofe corporativa, demostrando que la automatización total en dominios de alto riesgo es una negligencia inaceptable (Gudigantala, 2024).

Caso de Fracaso 2: IBM Watson for Oncology y la Opacidad de la Medicina Cognitiva

En la década pasada, IBM Watson cautivó la imaginación global tras su rotundo éxito en concursos de trivia televisados, demostrando capacidades extraordinarias de procesamiento de lenguaje natural (Gavi, 2023). Impulsada por este triunfo mediático, la corporación tecnológica redirigió su inmenso capital hacia uno de los sectores más complejos y lucrativos del mundo: la

atención médica oncológica. El nacimiento de IBM Watson for Oncology se propuso como un hito revolucionario; el sistema fue diseñado para ingerir y analizar millones de páginas de literatura médica, historiales clínicos electrónicos y ensayos genómicos en cuestión de segundos, proporcionando a los oncólogos recomendaciones de tratamiento personalizadas, precisas y basadas en la evidencia más reciente (Kohn, 2014). Para sostener esta visión, IBM invirtió agresivamente más de cuatro mil millones de dólares en la adquisición de vastos repositorios de datos de salud, incluyendo la compra de Marge Healthcare por mil millones y Truven Health Analytics por dos mil seiscientos millones de dólares (Gandhi & Singh, 2023; Dolfing, 2024).

Pese a los formidables recursos desplegados, el sistema fracasó en su intento de adopción clínica a escala global. Instituciones de prestigio cancelaron sus proyectos piloto tras comprobar que las recomendaciones emitidas eran frecuentemente erróneas, divergentes de las prácticas locales e incluso potencialmente inseguras en casos de complicaciones hemorrágicas. El caso más notorio fue el del Centro Oncológico MD Anderson de la Universidad de Texas, que detuvo su proyecto tras agotar aproximadamente sesenta y dos millones de dólares sin lograr integrar la herramienta en un entorno de atención a pacientes reales (Dolfing, 2024; Price, 2026). Finalmente, en dos mil veintidós, IBM liquidó y vendió los activos de Watson Health por una fracción de su inversión original, marcando el fin de su narrativa fundacional (Gavi, 2023).

Claridad del Problema y Ajuste de la Solución (Fit Problema-Solución): El colapso de Watson for Oncology evidenció un déficit epistemológico en la formulación del problema clínico. La medicina oncológica no es un ejercicio de recuperación de información estática; es un proceso dinámico, altamente contextual y dependiente de un sinnúmero de variables no estructuradas, como el estado socioeconómico del paciente, las comorbilidades sutiles anotadas en texto libre por los médicos, y las mutaciones constantes en la disponibilidad regional de terapias (Dolfing, 2024; Price, 2026). La solución de IBM fue construir un sistema que dependía de representaciones estructuradas del conocimiento, operando más como un motor de búsqueda sofisticado regido por

reglas codificadas manualmente que como una verdadera inteligencia artificial capaz de generalizar aprendizaje a partir de datos no estructurados en el mundo real. Este desajuste impidió que el modelo comprendiera la ambigüedad inherente al razonamiento diagnóstico humano (Dolfing, 2024).

Análisis de la Narrativa Utilizada: La narrativa comercial de IBM operó bajo el espectro de la sobre promesa tecnológica (hyper cycle), posicionando a Watson como un médico cognitivo que superaría las capacidades de retención y análisis de los especialistas oncológicos humanos (Gavi, 2023). Esta postura generó expectativas estratosféricas que la tecnología subyacente, aún en fases embrionarias de generalización clínica, era incapaz de satisfacer. Cuando los oncólogos interactuaron con el sistema y descubrieron que sus respuestas carecían de adaptabilidad a las realidades locales, la percepción de la herramienta mutó instantáneamente de ser un asistente revolucionario a convertirse en una carga burocrática e inoperante, destruyendo el componente más valioso en la adopción médica: la confianza clínica (Price, 2026).

Identificación de Errores Comunes Sistémicos: El declive de Watson for Oncology tipifica la sobrecarga técnica acompañada de una débil justificación metodológica en el entrenamiento de los datos, manifestada a través de sesgos institucionales y fallos de gobernanza:

En primera instancia, el sistema sufrió de un sesgo de entrenamiento profundo debido a una dependencia institucional estrecha. En lugar de nutrir al algoritmo con un conjunto de datos verdaderamente global y diverso, Watson fue entrenado predominantemente utilizando casos sintéticos y la experticia específica del Memorial Sloan Kettering Cancer Center (MSK) de Nueva York (Price, 2026; Dolfing, 2024). En consecuencia, el modelo no aprendió las directrices universales de la oncología, sino que codificó y replicó los patrones de prescripción, preferencias de tratamiento y protocolos particulares de los médicos del MSK. Cuando el sistema fue desplegado en hospitales de Asia o Europa, sus recomendaciones chocaron violentamente con la disponibilidad farmacéutica

local, las restricciones de los seguros médicos nacionales y las variaciones genéticas de otras poblaciones, volviéndose inútil fuera de su silo original (Dolfing, 2024; Price, 2026).

En segunda instancia, IBM cometió el error imperdonable de escalar antes de resolver. La directriz corporativa forzó el despliegue global masivo del sistema impulsado por estrategias de marketing y adquisiciones millonarias, ignorando que el producto central aún no había demostrado eficacia empírica robusta en entornos clínicos no controlados. La gobernanza del proyecto estuvo fragmentada entre desarrollo de producto, investigación y consultoría, diluyendo la responsabilidad ejecutiva y permitiendo que la iniciativa cruzara un umbral donde detenerla resultaba más costoso para el prestigio corporativo que continuar financiando su inoperancia (Dolfing, 2024).

Análisis de Casos de Éxito: La Triangulación entre Precisión, Hardware y Contexto

Para contrastar las patologías del fracaso algorítmico, resulta indispensable estudiar implementaciones donde la inteligencia artificial ha logrado amalgamar con éxito la inferencia matemática con las restricciones del entorno físico, generando valor tangible y sostenido. Los casos del sistema agrícola See & Spray de John Deere y la tecnología de visión minorista de Amazon Go ofrecen un catálogo excepcional de buenas prácticas operativas.

Caso de Éxito 1: John Deere See & Spray y la Fumigación de Precisión

La industria agrícola mundial enfrenta presiones convergentes: la necesidad imperiosa de aumentar los rendimientos para alimentar a una población en crecimiento, combinada con la exigencia de reducir drásticamente el impacto ambiental y los costos de los insumos químicos. Históricamente, el control de malezas se ha ejecutado mediante la fumigación de cobertura total, un método ciego que rocía herbicidas uniformemente sobre vastas extensiones de tierra. La ineficiencia de esta práctica es abrumadora; estudios del sector indican que apenas el uno por ciento de los pesticidas aplicados alcanza realmente a la plaga objetivo, mientras que el resto contamina suelos desnudos, afecta cultivos sanos o se disipa en el medio ambiente, representando un gasto global que supera los veinticinco mil millones de dólares anuales (Telang, 2025).

Para erradicar esta ineficiencia, John Deere, tras adquirir la firma de visión artificial Blue River Technology por trescientos cinco millones de dólares, desarrolló e implementó el sistema See & Spray (Telang, 2025). Esta tecnología revolucionaria utiliza un conjunto de cámaras de alta resolución montadas a lo largo de los extensos brazos pulverizadores de los tractores. Apoyado en procesadores de inteligencia artificial incrustados en la maquinaria, el sistema escanea el suelo agrícola, identifica visualmente la maleza entre los cultivos comerciales en fracciones de segundo y activa ráfagas de herbicida a través de boquillas individuales dirigidas exclusivamente a la planta invasora (Dulaney et al., 2023). Los ensayos de campo exhaustivos y el despliegue comercial han validado que la tecnología reduce el volumen total de herbicida utilizado entre un cuarenta y tres y un cincuenta y nueve por ciento en promedio, proporcionando ahorros operativos masivos que amortizan rápidamente la inversión en el equipo de precisión (Lovett, 2025; John Deere, 2022).

Claridad del Problema y Ajuste de la Solución (Fit Problema-Solución): A diferencia de los modelos predictivos vagos y especulativos analizados en los casos de fracaso, John Deere acotó el desafío a un problema de clasificación binaria visual extremadamente concreto y delimitado: distinguir un cultivo deseado (ej. algodón, maíz o soja) de una especie invasora. La solución tecnológica se diseñó a medida para esta tarea, entrenando redes neuronales convolucionales profundas con inmensos bancos de datos fotográficos de malezas y cultivos bajo diversas condiciones de iluminación y crecimiento en campo (Telang, 2025; Hill, 2025).

La brillantez de la solución reside en su arquitectura de despliegue. Reconociendo que los tractores operan en zonas rurales donde la latencia de red y la conectividad a la nube son nulas, John Deere integró potentes unidades de procesamiento gráfico (tales como la arquitectura NVIDIA Jetson Xavier) directamente en los brazos pulverizadores, ejecutando las operaciones matemáticas en el borde (Edge Computing) (Telang, 2025). Esto garantiza que el sistema procese imágenes abarcando más de dos mil cien pies cuadrados por segundo y active los aspersores en milisegundos, operando con fluidez mientras la maquinaria avanza a velocidades de hasta quince millas por hora

(Telang, 2025; Lovett, 2025). El ajuste problema-solución es impecable, uniendo una tarea discreta con la única arquitectura de hardware capaz de sostenerla en un entorno aislado.

Análisis de la Narrativa Utilizada: La narrativa corporativa de John Deere evitó hábilmente la trampa de comercializar el sistema como una entidad autónoma que reemplazaría el conocimiento del agricultor. Por el contrario, See & Spray se posicionó discursivamente como una herramienta de precisión y empoderamiento, diseñada para optimizar los recursos del operador humano y proteger su rentabilidad frente a la escalada en los precios de los agroquímicos y la amenaza de las malezas resistentes (Deere & Company, 2022; Hill, 2025). Esta comunicación centrada en la inteligencia colaborativa facilitó la adopción de la tecnología, transformando la percepción de la IA de una amenaza abstracta a un instrumento táctico indispensable para la supervivencia económica en el campo.

Extracción de Buenas Prácticas: El rotundo éxito operativo de See & Spray aporta lecciones cardinales para el diseño de sistemas visuales en la periferia:

En primer lugar, destaca la priorización absoluta de la inferencia local para misiones críticas. Cuando el tiempo de reacción es el factor determinante del éxito (como rociar una hoja específica a alta velocidad), la transmisión de datos a un servidor central es un lujo prohibitivo y técnicamente inviable. La decisión de incrustar el poder de cómputo en el equipo garantiza la autonomía y la fiabilidad ininterrumpida.

En segundo lugar, se subraya la importancia del diseño modular y la parametrización de la supervisión humana. El sistema See & Spray no impone una decisión dictatorial; permite al agricultor ajustar los umbrales de sensibilidad del algoritmo a través de la interfaz de la cabina (Lovett, 2025; John Deere, 2022). Configurarlo en alta sensibilidad asegura la erradicación total de malezas microscópicas para prevenir futuros bancos de semillas, mientras que una baja sensibilidad ignora brotes menores para maximizar el ahorro químico inmediato (Lovett, 2025). Al ceder la

parametrización del riesgo al operador humano, el sistema absorbe la complejidad del mundo real sin fracturar la confianza del usuario.

Caso de Éxito 2: Amazon Go y la Orquestación de la Fusión de Sensores

El sector minorista presenció una disrupción metodológica sin precedentes con la inauguración de las tiendas Amazon Go. Estas infraestructuras comerciales eliminaron las filas de pago y las cajas registradoras tradicionales, permitiendo a los usuarios ingresar mediante la validación de un código QR en sus dispositivos móviles, tomar los productos deseados de los estantes y simplemente salir del establecimiento, recibiendo automáticamente la factura electrónica en sus cuentas (Alexander, 2018; Green, 2021).

Para lograr esta experiencia de compra sin fricciones, Amazon no dependió de un único algoritmo mágico, sino que orquestó una red densa de inteligencia artificial combinando visión por computadora de última generación, algoritmos de reconocimiento de acciones humanas y sensores de peso integrados en la estantería (Green, 2021; Amazon Web Services, 2023).

Claridad del Problema y Ajuste de la Solución (Fit Problema-Solución): El problema estaba claramente identificado: las filas de pago son el cuello de botella más costoso en tiempo y experiencia del cliente dentro del comercio físico de conveniencia. La solución exigía rastrear de manera inequívoca la asociación entre una identidad digital y un objeto físico en un entorno tridimensional abarrotado. En lugar de sobrecargar una única red de cámaras con la responsabilidad de descifrar oclusiones visuales complejas (por ejemplo, cuando un cliente oculta un producto con su cuerpo), Amazon implementó un modelo de Fusión de Sensores (Milvus, 2025; Green, 2021).

La genialidad técnica radicó en comprender que la visión artificial, por avanzada que sea, es inherentemente falible ante ángulos ciegos. Cuando el algoritmo de seguimiento óptico de las cámaras montadas en el techo disminuye su índice de confianza estadística al intentar identificar qué artículo exacto tomó un cliente, el sistema cruza esa información visual con la telemetría del sensor de peso de la estantería. La disminución de masa física corrobora la extracción del producto,

permitiendo que un modelo probabilístico infiera la acción correcta y actualice el inventario virtual del usuario con una precisión operativa casi perfecta (Alexander, 2018; Milvus, 2025).

Extracción de Buenas Prácticas: El caso de Amazon Go destila una lección invaluable para cualquier arquitectura de monitoreo ambiental: la redundancia meta-característica. Ningún sensor óptico debe operar de manera aislada si el entorno presenta desafíos geométricos severos. La buena práctica consiste en crear heurísticas auxiliares que compensen las debilidades del análisis predictivo principal, garantizando que el sistema escale de manera confiable en el caótico mundo físico sin requerir capturas fotográficas primitivas en cada milisegundo (Milvus, 2025)

Síntesis Comparativa de Casos Externos

La disección metodológica de los casos presentados permite consolidar un marco referencial de atributos que dictaminan la frontera entre el fracaso estrepitoso y el éxito sostenible en la adopción de inteligencia artificial. La Tabla 1 abstrae y contrasta estas dimensiones fundamentales.

Tabla 1

Análisis Comparativo de Factores Estructurales en Implementaciones de Inteligencia Artificial.

Dimensión de Análisis	Patrón de Casos Fallidos (Zillow, IBM Watson)	Patrón de Casos Exitosos (John Deere, Amazon Go)
Arquitectura de Procesamiento	Dependencia dogmática de procesamiento centralizado asíncrono y uso intensivo de APIs que generan cuellos de botella y sesgos sistémicos.	Adopción irrestricta de Computación en el Borde para garantizar procesamiento de ultra baja latencia y autonomía en infraestructuras locales.
Definición del Problema (Enfoque)	Sobre extensión del dominio. Aplicación de modelos para predecir dinámicas abstractas, estacionarias y altamente volátiles (mercados financieros y diagnósticos oncológicos no estructurados).	Delimitación estricta. Reducción del desafío a tareas de clasificación espacial y visual binarias o cerradas dentro de un perímetro físico altamente controlado

Tratamiento de la Supervisión Humana	Erradicación o desprecio por la revisión humana experta. Las barreras de contención se suprimen bajo presiones de hiper crecimiento corporativo.	Paradigma Human-in-the-Loop paramétrico. La inteligencia artificial recomienda o actúa según umbrales de sensibilidad definidos y supervisados directamente por el operador humano.
Narrativa Corporativa	Sobre promesa tecnológica. Se vende el sistema como un sustituto infalible del juicio humano, generando expectativas que fracturan la confianza al primer fallo.	Posicionamiento de la tecnología como un amplificador de capacidades. Se comunica la IA como una herramienta de precisión que optimiza la tarea humana, reduciendo la fricción social.
Manejo de Datos Atípicos y Ruido	Ceguera algorítmica frente a la asimetría de información y selección adversa. El modelo consume datos ruidosos y los procesa como hechos estandarizados.	Implementación de fusión de sensores y meta-características probabilísticas que validan o descartan anomalías visuales en tiempo real para mantener la integridad del modelo.

Nota: La tabla evidencia cómo el éxito en entornos complejos no depende de la sofisticación bruta del algoritmo, sino de decisiones sociotécnicas centradas en el acotamiento de la tarea, la descentralización del cómputo y el respeto irrestricto por la supervisión humana.

Aplicación Estratégica de Lecciones Aprendidas al Proyecto SmartPet

El objetivo fundamental de este análisis es transferir la densidad de conocimiento extraído del análisis corporativo externo hacia la arquitectura de SmartPet. SmartPet, concebido como un ecosistema inteligente fundamentado en la red convolucional YOLOv11m para monitorear el comportamiento de las mascotas y la higiene en los conjuntos residenciales de Bogotá, exhibe asombrosas similitudes arquitectónicas con las soluciones de visión robótica agrícola y el comercio sin fricciones, pero se despliega bajo una presión regulatoria ciudadana notablemente mayor (Congreso de Colombia, 2012).

Las métricas internas del proyecto son formidables; el modelo base ha demostrado alcanzar un F1-Score del 91.3% con una latencia asombrosa de 16.9 milisegundos operando sobre microprocesadores de bajo consumo de la familia NVIDIA Jetson Orin Nano. No obstante, las lecciones destiladas de los fracasos y éxitos externos demuestran que estas métricas estadísticas son efímeras si el sistema no incorpora defensas estructurales contra el entorno físico y las dinámicas

sociales. A continuación, se detalla la integración explícita de los aprendizajes derivados en las cuatro dimensiones operativas del ecosistema SmartPet.

La Inferencia Perimetral como Blindaje Financiero y Regulatorio (Lección de Amazon Go y John Deere)

El análisis del estado del arte comprobó la inviabilidad absoluta de procesar la videovigilancia residencial a través de plataformas comerciales monopólicas basadas en la nube. Soluciones de Inteligencia Artificial como Servicio (AIaaS), tales como AWS Rekognition, imponen costos depredadores que rondan los cuatro dólares por hora de inferencia para transmisiones de video continuo. En un contexto práctico, monitorear un circuito básico de cinco cámaras residenciales las veinticuatro horas del día generaría un gasto mensual superior a los catorce mil dólares, destruyendo inmediatamente la viabilidad económica de la prueba de concepto para cualquier administración de propiedad horizontal.

Siguiendo el éxito operativo de la maquinaria de John Deere y la latencia ultra baja requerida por las tiendas sin cajas registradoras, SmartPet justifica categóricamente su adopción radical del paradigma de Computación en el Borde. Al incrustar el poder analítico localmente en nodos perimetrales equipados con unidades de procesamiento tensorial (GPUs), el proyecto transforma un gasto operativo mensual prohibitivo en una inversión de capital inicial altamente amortizable, operando el monitoreo continuo por una fracción marginal de consumo eléctrico.

Más allá del ámbito financiero, esta decisión arquitectónica resuelve el desafío ético más complejo de la videovigilancia algorítmica. La estricta normativa de la Circular Externa 002 de 2024 de la Superintendencia de Industria y Comercio, aunada a los preceptos de la Ley 1581 de 2012 del Congreso de Colombia sobre Habeas Data, exige a los administradores de sistemas de inteligencia artificial mitigar la circulación indebida de información personal sensible. Si SmartPet transmitiera flujos de video hacia servidores remotos, incurriría en una vulneración masiva de la cadena de custodia. Al confinar el tensor de YOLOv11m en el perímetro del edificio, analizando los píxeles en la

memoria volátil del dispositivo y combinando con procedimientos que aseguran la custodia normativa de los datos, el proyecto materializa el estándar global, acatando cabalmente la ley colombiana mediante la infraestructura misma.

Erradicación del Sesgo de Escala Mediante Intervenciones Hiper-Fragmentadas

Uno de los errores más graves en la adopción de algoritmos, evidenciado en la miopía del modelo predictivo de Zillow frente a la información cualitativa de las viviendas, es ignorar las asimetrías estructurales de los datos de entrada. El diagnóstico interno de SmartPet reveló una vulnerabilidad ética y geométrica profunda: el fenómeno de la Detección de Objetos Pequeños (Nikouei et al., 2025). Debido a que las cámaras de seguridad residenciales operan desde ángulos picados a gran altura, la anatomía de los caninos se comprime severamente. El modelo convolucional beneficia abrumadoramente al grupo dominante (perros de razas grandes cercanos al lente), mientras sufre caídas drásticas de precisión frente a perros de raza miniatura o aquellos que transitan en los bordes lejanos del campo focal, generando una alta tasa de falsos negativos.

A nivel sociológico, esta deficiencia técnica institucionalizaría una fiscalización asimétrica, penalizando rigurosamente a ciertos residentes mientras otorga impunidad algorítmica a otros, destruyendo la equidad y la confianza comunitaria en la herramienta. Para resolver este desafío sin engrosar la red neuronal con parámetros innecesarios, SmartPet debe emular la meticulosidad técnica de la investigación de vanguardia, integrando en su conducto de preprocesamiento el módulo de Inferencia Hiper-Fragmentada Asistida (Akyon et al., 2022).

Al igual que la fusión de sensores de Amazon Go segmenta el espacio físico para validar oclusiones complejas, la técnica SAHI fragmenta el fotograma panorámico de alta definición en una matriz de cuadrículas superpuestas antes de someterlo al tensor de YOLOv11m. Esta fragmentación evita que las delicadas características morfológicas de los perros distantes sean trituradas irreversiblemente por las capas de reducción de dimensionalidad de la red, devolviendo la paridad

predictiva al sistema y asegurando que la fiscalización opere bajo un estándar de justicia geométrica inquebrantable.

Institucionalización del Paradigma Human-in-the-Loop (HITL) (Lección de Zillow e IBM)

El colapso de Zillow Offers por suprimir las revisiones manuales de precios para sostener un hiper crecimiento irreal es la lección definitiva sobre la arrogancia de la automatización descontrolada. De manera paralela, el desprecio que sufrieron los sistemas de IBM Watson cuando intentaron dictar tratamientos médicos por encima del criterio del oncólogo demuestra que el algoritmo no puede usurpar la agencia moral en la toma de decisiones.

Aplicar este conocimiento a SmartPet significa que la inteligencia artificial del proyecto no puede, bajo ninguna circunstancia, operar como una entidad punitiva autónoma. El frágil tejido social de una copropiedad requiere tacto, contexto y debido proceso. La arquitectura de SmartPet debe estructurarse ineludiblemente bajo el paradigma de Inteligencia Colaborativa y Supervisión Humana. El modelo YOLOv11m debe ser degradado conscientemente de juez a herramienta tecnológica para agilizar la toma de decisiones. Cuando el sistema identifique la postura anómala de excreción con un nivel de confianza estadístico predeterminado, emitirá una alerta al correo de la administración.

Corresponderá enteramente al administrado (a) validar el fotograma capturado, determinar si existió intencionalidad o negligencia por parte del residente, descartar falsos positivos ambientales inducidos por sombras caprichosas (evitando la fatiga de alarma), y ejecutar el protocolo de acercamiento pedagógico dictado por el manual de convivencia. Esta desautomatización de la sanción rescata la recomendación ética global: utilizar la inteligencia artificial para amplificar la eficiencia de la seguridad, pero reservar la aplicación del reglamento y la empatía comunitaria estrictamente a los individuos.

Gobernanza MLOps para el Control de la Deriva de Datos

La última barrera de supervivencia para un modelo de aprendizaje automático es su resistencia al paso del tiempo. Las arquitecturas de Zillow e IBM Watson operaron bajo la ilusión de la estática; asumieron que los datos de entrenamiento representarían eternamente la realidad operativa del entorno. La ciencia de datos dictamina que los ecosistemas de videovigilancia sufren procesos crónicos de deriva. Con el avance de las estaciones cambian las sombras proyectadas por la vegetación, la suciedad desgasta los lentes de las cámaras CCTV, y la aparición de nuevas variaciones posturales de los caninos erosiona silenciosamente la exactitud matemática de las fronteras de clase que el modelo YOLOv11m aprendió en el laboratorio.

Para prevenir la obsolescencia discriminatoria, la etapa de posproducción de SmartPet debe incorporar flujos de trabajo automatizados de MLOps. El hardware perimetral deberá programar rutinas analíticas de fondo que ejecuten rutinariamente pruebas de bondad de ajuste estadístico (tales como el test de Kolmogorov-Smirnov) y calculen el Índice de Estabilidad de la Población sobre el flujo de inferencias diarias. La violación de los umbrales de estabilidad dictaminará que el modelo ha comenzado a perder su capacidad de generalización frente a las nuevas condiciones lumínicas o morfológicas, gatillando automáticamente la recopilación de datos de la cola estadística para una futura recalibración. Así, el mantenimiento se transforma de una labor correctiva y manual a un proceso de inmunidad proactiva impulsado por métricas de degradación.

Recomendaciones

Con el propósito de cristalizar las lecciones extraídas de este análisis comparativo y garantizar que el despliegue a producción del proyecto SmartPet preserve su supremacía técnica, mantenga la equidad algorítmica y ostente un blindaje jurídico absoluto frente a las autoridades de control nacional, se dictaminan las siguientes recomendaciones estratégicas de alto nivel:

Implantación Arquitectónica Definitiva de Inferencia Fragmentada (SAHI)

Dado el diagnóstico de vulnerabilidad del sistema ante la Detección de Objetos Pequeños (SOD) exacerbada por las distancias focales del circuito de vigilancia, se instruye la integración mandataria de los módulos de Slicing Aided Hyper Inference (SAHI) en el conducto de preprocesamiento de video en el borde. Seccionar sistemáticamente los fotogramas de alta resolución antes de someterlos a la evaluación del tensor de YOLOv11m es el único mecanismo viable para erradicar el sesgo algorítmico contra las mascotas de razas pequeñas, democratizando la exactitud de la herramienta y previniendo la instauración de una vigilancia asimétrica y discriminatoria entre los residentes.

Modificación del Régimen de Propiedad Horizontal hacia un Enfoque Human-in-the-Loop

Es una necesidad ineludible que la asamblea de copropietarios enmiende los estatutos de convivencia para consagrar el rol del sistema de inteligencia artificial. Se debe establecer por escrito que las alertas predictivas generadas por SmartPet poseen una naturaleza estrictamente probabilística y carecen de valor sancionatorio automático. La revisión contextual del evento anómalo, la determinación de negligencia y el subsecuente acercamiento pedagógico con el residente deben recaer exclusiva e irrevocablemente en el personal humano de administración, blindando a la comunidad frente a fallos sistémicos o falsos positivos ambientales que el modelo pudiese emitir en condiciones límite.

Auditoría Periódica de Impacto de Privacidad (EIP) y Bloqueo de Exfiltración

En acatamiento riguroso de la normativa regulatoria colombiana (Ley 1581 de 2012 y directrices de la Superintendencia de Industria y Comercio), la arquitectura de hardware del proyecto debe mantenerse aislada. Se recomienda documentar anualmente una Evaluación de Impacto de Privacidad que certifique la ausencia de pasarelas de red (gateways) orientadas a extraer, almacenar prolongadamente o transmitir flujos de video a servicios en la nube de terceros.

Institucionalización de Operaciones de Aprendizaje Automático (MLOps) para Control de Deriva

Reconociendo que el entorno óptico de las copropiedades es dinámico (cambios estacionales, erosión de las lentes de vigilancia, aparición de nuevas posturas caninas que diluyen las fronteras de clase aprendidas), se recomienda desplegar instrumentación estadística en el hardware de control. Programar rutinas que monitoreen el Índice de Estabilidad de la Población y ejecuten pruebas de bondad de ajuste en tiempo real permitirá gatillar alertas predictivas de mantenimiento antes de que la eficacia del sistema caiga por debajo de la línea base aceptable del setenta y cinco por ciento de F1-Score. Esta profilaxis operativa asegura la longevidad, la precisión y la relevancia continua del ecosistema SmartPet.

Conclusiones

La evaluación exhaustiva del panorama industrial de la inteligencia artificial, cruzada analíticamente con las especificaciones topológicas y las restricciones sociales del proyecto SmartPet, permite consolidar dictámenes académicos de inestimable valor estratégico para Smartpet. El presente análisis demuestra irrefutablemente que el éxito en el despliegue de sistemas de aprendizaje profundo no se garantiza mediante el despliegue indiscriminado de arquitecturas paramétricas complejas, sino a través de la orquestación meticulosa entre la sofisticación de los tensores matemáticos, las limitaciones del hardware de inferencia y las sensibilidades éticas del entorno humano intervenido.

Se ha comprobado, mediante la autopsia de colapsos corporativos como Zillow Offers e IBM Watson for Oncology, que las iniciativas fracasan cuando prevalece una profunda desconexión entre el diseño del algoritmo y la naturaleza fluida, contextual y asimétrica del mundo real. Las corporaciones que eliminan las salvaguardas de supervisión experta en pos de automatizar decisiones de alto impacto asumen riesgos sistémicos que degradan irreparablemente la confianza en la herramienta.

Por el contrario, los triunfos paradigmáticos de la industria, tipificados en la robótica agrícola de John Deere y la fusión de sensores de Amazon Go, convergen en un principio fundamental: la inteligencia artificial debe circunscribirse a resolver tareas visuales espacialmente acotadas, procesando la información in situ para anular latencias destructivas, y operando siempre bajo un diseño de inteligencia colaborativa que mantenga al operador humano en el centro del bucle de decisión.

Bajo esta óptica metodológica, el proyecto SmartPet evidencia un cimiento arquitectónico robusto. La elección de delegar el núcleo analítico en la arquitectura YOLOv11m ejecutada sobre unidades de procesamiento neuronal NVIDIA Jetson, blindando el ecosistema con técnicas de fragmentación de fotogramas (SAHI), constituye el abordaje tecnológicamente correcto para resolver la anomalía morfológica y la detección de objetos microscópicos en planos picados de CCTV sin colapsar bajo el peso del ruido ambiental.

Asimismo, la confinación radical de la ingesta y el análisis del video en la infraestructura perimetral del edificio (Edge Computing) eleva a SmartPet por encima del debate extractivista. Esta decisión estratégica no solo destruye la letal dependencia financiera hacia el procesamiento en la nube, sino que cumple anticipadamente y a cabalidad con la esencia de la privacidad por diseño estipulada en la Circular Externa 002 de 2024 de la SIC y el derecho al Habeas Data en Colombia, bloqueando cualquier exfiltración de imágenes residenciales, al usar de manera combinada las bondades tecnológicas de la arquitectura propuesta con la rigurosa aplicación de los procedimientos aprobados por la asamblea general de copropietarios.

En definitiva, si SmartPet preserva su marco de gobernanza, resistiendo cualquier presión hacia la automatización punitiva y sosteniendo su compromiso con el monitoreo ininterrumpido de la deriva de datos mediante prácticas MLOps, se erigirá como una disrupción tecnológica escalable y un manifiesto académico insuperable sobre cómo conciliar la vanguardia de la visión por computadora con la ética de la convivencia urbana.

Referencias

Alexander, A. (2018, abril 2). *Computer vision case study: Amazon Go*. Medium. https://medium.com/arren-alexander/computer-vision-case-study-amazon-go-db2c9450ad18

Amazon Web Services. (2023, noviembre 13). *Enhancing the retail experience: The power of computer vision*. https://aws.amazon.com/es/blogs/industries/enhancing-the-retail-experience-the-power-of-computer-vision/

Akyon, F. C., Altinuc, S. O., & Temizel, A. (2022). Slicing aided hyper inference and fine-tuning for small object detection. En 2022 IEEE International Conference on Image Processing (ICIP). IEEE. https://doi.org/10.1109/ICIP46576.2022.9897990

causaLens. (2022). *Zillow—A cautionary tale of machine learning*. https://causalai.causalens.com/resources/blog/zillow-a-cautionary-tale-of-machine-learning/

Congreso de Colombia. (2012). *Ley Estatutaria 1581 de 2012. Por la cual se dictan disposiciones generales para la protección de datos personales*. Diario Oficial No. 48. 43 https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=49981

Copropiedades. (2026). *Tarifas mínimas para la contratación de servicios de vigilancia y seguridad privada vigencia 2026.* Tarifas mínimas para la contratación de servicios de vigilancia y seguridad privada vigencia 2026

Dolfing, H. (2024, diciembre 7). *Case study 20: The $4 billion AI failure of IBM Watson for oncology*. https://www.henricodolfing.ch/en/case-study-20-the-4-billion-ai-failure-of-ibm-watson-for-oncology/

Dulaney, P., Lowe, J. W., Dodds, D., & Speights, C. (2023). *See & spray technology*. Mississippi State University Extension Service. https://extension.msstate.edu/sites/default/files/publications/P3904_web.pdf

Gandhi, P., & Singh, N. (2023, noviembre). *IBM Watson: From healthcare canary to a failed prodigy*. Healthark Insights. https://healthark.ai/wp-content/uploads/2023/11/IBM-Watson-From-healthcare-canary-to-a-failed-prodigy_1.pdf

Gavi, the Vaccine Alliance. (2023, enero 24). *From a "deranged" provocateur to IBM's failed AI superproject: How data has transformed healthcare*. https://www.gavi.org/vaccineswork/deranged-provocateur-ibms-failed-ai-superproject-controversial-story

Green, K. M. (2021). *Super-big market-data: A case study, walkthrough approach to Amazon Go cashierless convenience stores* (Doctoral dissertation, University of Illinois at Chicago). https://doi.org/10.25417/uic.17025902

Gudigantala, N., & Mehrotra, V. (2024). *Teaching case: When strength turns into weakness: Exploring the role of AI in the closure of Zillow Offers*. *Journal of Information Systems Education, 35*(1), 67–72. https://doi.org/10.62273/TRCF3655

Hill, K. (2025, mayo 1). *More farmers are adopting John Deere's See & Spray. Here's why*. CropLife. https://www.croplife.com/smart-tech/more-farmers-are-adopting-john-deeres-see-spray-heres-why/

Jocher, G., Chaurasia, A., & Qiu, J. (2023). YOLO by Ultralytics (Versión 8). GitHub. https://github.com/ultralytics/ultralytics

John Deere. (2022, marzo 1). *Tech@Work: See & Spray™ Ultimate*. *The Furrow*. https://www.deere.com/en/publications/the-furrow/2022/march-2022/tech-at-work-see-and-spray-ultimate/

Kohn, M. S., Sun, J., Knoop, S., Shabo, A., Carmeli, B., Sow, D., & Syed-Mahmood, T. (2014). *IBM's health analytics and clinical decision support*. *Yearbook of Medical Informatics, 9*(1), 154–162. https://doi.org/10.15265/IY-2014-0002

Lovett, J. (2025, marzo 10). *Precision agriculture research measures effectiveness of See & Spray technology*. Arkansas Agricultural Experiment Station. https://aaes.uada.edu/news/see-and-spray-research/

Melbourne Business School Centre for Business Analytics. (2024, agosto). *Why do analytics and AI projects fail?* https://mbs.edu/-/media/PDF/Centres/CfBA/Research/White-Papers/2407_CfBA_Why-do-AI-projects-fail_FINAL.pdf

Milvus. (s. f.). *How is computer vision implemented in Amazon Go?* https://milvus.io/ai-quick-reference/how-is-computer-vision-implemented-in-amazon-go

Nikouei, M., Baroutian, B., Nabavi, S., Taraghi, F., Aghaei, A., Sajedi, A., & Moghaddam, M. E. (2025). Small object detection: A comprehensive survey on challenges, techniques and real-world applications. arXiv. https://arxiv.org/abs/2503.20516

ORSYS. (2025). *IA en la empresa: éxitos y fracasos de los proyectos*. ORSYS Le Mag. https://www.orsys.fr/orsys-lemag/es/ia-empresa-exitos-fracasos-proyectos/

Shackleford, A. (2026). *Zillow offers loss: A $881M study in AI model risk*. Shackleford AI Leadership Insights. https://www.shackleford.coach/ai-leadership-insights/zillow-lost-881-million-the-ai-was-working-perfectly

Superintendencia de Industria y Comercio. (2024). *Circular Externa 002 de 2024. Lineamientos sobre el Tratamiento de Datos Personales en Sistemas de Inteligencia Artificial*. Circular Externa 2 de 2024 de la Superintendencia de Industria y Comercio “Lineamientos sobre el Tratamiento de Datos personales en Sistemas de Inteligencia Artificial" | Sede Electronica

Telang, A. (2025, octubre 13). *Artificial intelligence at John Deere*. Emerj Artificial Intelligence Research. https://emerj.com/artificial-intelligence-at-john-deere/

Telefónica. (2024, noviembre 29). *Factores críticos de éxito en un proyecto de inteligencia artificial*. https://www.telefonica.com/es/sala-comunicacion/blog/factores-criticos-exito-proyecto-inteligencia-artificial/